



**UNIVERSIDADE DO ESTADO DO RIO GRANDE DO NORTE
FACULDADE DE CIÊNCIAS EXATAS E NATURAIS
DEPARTAMENTO DE INFORMÁTICA
CURSO DE CIÊNCIA DA COMPUTAÇÃO**

MATHEUS SOBREIRA BENEVIDES

**CONSTRUÇÃO DE UM PIPELINE REPRODUTÍVEL PARA MONTAGEM E
ANOTAÇÃO AUTOMATIZADA DE MITOGENOMAS: APLICAÇÃO À
ARARA-AZUL-DE-LEAR (*ANODORHYNCHUS LEARI*)**

**NATAL
2026**

MATHEUS SOBREIRA BENEVIDES

**CONSTRUÇÃO DE UM PIPELINE REPRODUTÍVEL PARA
MONTAGEM E ANOTAÇÃO AUTOMATIZADA DE MITOGENOMAS:
APLICAÇÃO À ARARA-AZUL-DE-LEAR (*ANODORHYNCHUS
LEARI*)**

Monografia apresentada à Universidade do
Estado do Rio Grande do Norte – UERN –
como requisito obrigatório para obtenção do
título de Bacharel em Ciência da Computa-
ção.

**Orientador: Prof. Dr. Wilfredo Blanco
Figuerola**

**NATAL
2026**

MATHEUS SOBREIRA BENEVIDES

**CONSTRUÇÃO DE UM PIPELINE REPRODUTÍVEL PARA MONTAGEM E
ANOTAÇÃO AUTOMATIZADA DE MITOGENOMAS: APLICAÇÃO À
ARARA-AZUL-DE-LEAR (*ANODORHYNCHUS LEARI*)**

Monografia apresentada à Universidade do
Estado do Rio Grande do Norte – UERN –
como requisito obrigatório para obtenção do
título de Bacharel em Ciência da Computa-
ção.

Aprovado em: ____/____/____.

Banca examinadora

Prof. Dr. Wilfredo Blanco Figuerola (Orientador)
Universidade do Estado do Rio Grande do Norte – UERN

Prof. Dr. Anderson Abner de Santana Souza
Universidade do Estado do Rio Grande do Norte – UERN

Prof. Dr. Carlos André Guerra Fonseca
Universidade do Estado do Rio Grande do Norte – UERN

Prof. Dr. Jorge Estefano de Santana Souza
Universidade Federal do Rio Grande do Norte – UFRN

Dedico este trabalho

.....

.....

AGRADECIMENTOS

Texto dos agradecimentos.

O autor reconhece o uso de ferramentas de Inteligência Artificial Generativa como apoio durante a elaboração deste trabalho, em conformidade com a Política de Integridade na Atividade Científica do CNPq, conforme detalhado no Apêndice A.

“Texto da epígrafe.”
(Autor da Silva)

RESUMO

Este trabalho apresenta o desenvolvimento e a validação de um pipeline de bioinformática automatizado, reprodutível e portátil para a montagem *de novo* e anotação funcional de genomas mitocondriais, utilizando tecnologias de containerização (Docker) e sistemas de gerenciamento de *workflows* (Nextflow DSL2). O pipeline integra sete etapas sequenciais — análise piloto de qualidade, aquisição de dados do NCBI SRA, controle de qualidade com FastQC, remoção de adaptadores com Trim Galore, montagem com NOVOPlasty, anotação funcional com MITOS2 e compilação automática de 14 categorias de entregáveis, incluindo arquivos em formato GenBank Flat File prontos para submissão. A validação foi realizada com três espécies: *Diploprion bifasciatus* (Perciformes), como espécie-controle; a arara-azul-de-lear (*Anodorhynchus leari*, Psittaciformes), como espécie-alvo; e a arara-azul-grande (*A. hyacinthinus*), em validação cruzada recíproca de sementes. O mitogenoma da arara-azul-de-lear foi reconstruído com 16.986 pares de bases circularizados, cobertura de 176× e o conjunto completo de 37 genes (13 CDS, 22 tRNAs, 2 rRNAs), diferindo em apenas 13 bp do congênera *A. hyacinthinus*. A validação cruzada com *A. hyacinthinus*, montada *de novo* a partir de dados metagenômicos independentes (SRR36400750, cobertura 144×), reproduziu a referência publicada (NCBI OR209186.1) com 99,888% de identidade nucleotídica, fornecendo critério objetivo de aceitação do pipeline. O módulo Pilot QC, juntamente com a extração seletiva via `fastq-dump -X`, permitiu reduzir o volume de dados em aproximadamente 5 milhões de vezes (de 87 GB para 17 KB), viabilizando a execução completa em um notebook com 16 GB de RAM em pouco mais de 30 minutos. O pipeline e o código-fonte estão disponíveis em repositório público no GitHub, como contribuição à ciência aberta e à conservação da biodiversidade brasileira.

Palavras-chave: mitogenoma; pipeline; bioinformática; reprodutibilidade; Nextflow; Docker; arara-azul-de-lear.

ABSTRACT

This work presents the development and validation of an automated, reproducible and portable bioinformatics pipeline for *de novo* assembly and functional annotation of mitochondrial genomes, using containerization technologies (Docker) and workflow management systems (Nextflow DSL2). The pipeline integrates seven sequential stages — pilot quality analysis, NCBI SRA data acquisition, quality control with FastQC, adapter removal with Trim Galore, assembly with NOVOPlasty, functional annotation with MITOS2, and automatic compilation of 14 deliverable categories, including GenBank Flat File format files ready for submission. Validation was performed with three species: *Diploprion bifasciatus* (Perciformes), as a control species; the Lear’s Macaw (*Anodorhynchus leari*, Psittaciformes), as the target species; and the Hyacinth Macaw (*A. hyacinthinus*), in a reciprocal seed cross-validation. The Lear’s Macaw mitogenome was reconstructed with 16,986 circularized base pairs, 176× coverage and the complete set of 37 genes (13 CDS, 22 tRNAs, 2 rRNAs), differing by only 13 bp from the congeneric *A. hyacinthinus*. The cross-validation with *A. hyacinthinus*, assembled *de novo* from independent metagenomic data (SRR36400750, 144× coverage), reproduced the published reference (NCBI OR209186.1) with 99.888% nucleotide identity, providing an objective acceptance criterion for the pipeline. The Pilot QC module, combined with selective extraction via `fastq-dump -X`, reduced the data volume by approximately 5 million times (from 87 GB to 17 KB), enabling complete execution on a notebook with 16 GB of RAM in just over 30 minutes. The pipeline and source code are available in a public GitHub repository, as a contribution to open science and the conservation of Brazilian biodiversity.

Keywords: mitogenome; pipeline; bioinformatics; reproducibility; Nextflow; Docker; Lear’s Macaw.

LISTA DE ILUSTRAÇÕES

- Figura 1 – Estratégia de *shotgun sequencing*: (a) clivagem aleatória do DNA genômico em fragmentos de tamanhos variados (Fragmentos A, B e C); (b) sequenciamento de cada fragmento em leituras curtas e uniformes (~ 150 bp); (c) alinhamento das leituras por posição genômica — as zonas de sobreposição entre fragmentos adjacentes permitem a reconstrução da sequência completa. 26
- Figura 2 – Comparativo das principais tecnologias de sequenciamento: Illumina (leituras curtas, alta acurácia), PacBio HiFi (leituras longas, alta fidelidade) e Oxford Nanopore (leituras ultra-longas, menor acurácia). . . . 27
- Figura 3 – Representação circular esquemática de um genoma mitocondrial típico de vertebrado, mostrando a distribuição dos 37 genes (13 CDS, 22 tRNAs, 2 rRNAs), a região controle (D-loop) e as fitas pesada (H) e leve (L). 30
- Figura 4 – Diagrama ilustrativo da estratégia *seed-and-extend*: (a) sequência semente; (b) extensão iterativa a partir de leituras sobrepostas; (c) circularização quando as extremidades se encontram. 32
- Figura 5 – Conflito de dependências em pipelines bioinformáticos e a solução com containerização Docker. **Esquerda**: instalação manual em que MITOS2 exige Python ≥ 3.8 enquanto o Cutadapt (via Trim Galore) requer Python 2.7, resultando em versões incompatíveis no mesmo sistema operacional. **Direita**: cada ferramenta é empacotada em seu próprio container Docker com dependências isoladas, eliminando conflitos. . . . 35
- Figura 6 – Comparação arquitetural entre Máquina Virtual (VM) e Docker. **Esquerda**: pilha VM com cinco camadas, incluindo um **SO Convidado** completo duplicado por cada VM — overhead de 2–5 GB e inicialização de 1–2 minutos por instância. **Direita**: containers Docker compartilham o SO Host e o Docker Engine; cada ferramenta é isolada em seu próprio container com dependências independentes, e o ciclo de vida (Dockerfile $\rightarrow$ Imagem $\rightarrow$ Container) é definido por um arquivo de texto reproduzível. 37
- Figura 7 – Organização do desenvolvimento em três etapas: Fase 1 (Montagem, *D. bifasciatus*), Fase 2 (Anotação, *A. leari*) e Fase 3 (Validação Cruzada, *A. hyacinthinus*), com indicação das espécies, ciclos iterativos de desenvolvimento e relação recíproca de sementes entre fases. 47

Figura 8 – Fluxograma do pipeline com as 7 etapas: Pilot QC, SRA Download, FastQC, Trim Galore, NOVOPlasty, MITOS2 e Compile Summary. Cores distinguem Fase 1 (montagem, azul) e Fase 2 (anotação, verde).	51
Figura 9 – Fluxo sequencial de dados no pipeline, mostrando os formatos e volumes em cada transição, desde o arquivo <code>.sra</code> (11 GB) até os 14 entregáveis finais (1,6 MB). Destacam-se a redução de 87 GB para 17 KB e os dois pontos de decisão automática.	59
Figura 10 – Diagrama de atividade mostrando os dois pontos de decisão automática do pipeline: (1) Pilot QC — determina o volume de dados; (2) Filtro de Circularização — condiciona a anotação à obtenção de genoma circularizado.	61
Figura 11 – Fluxograma de decisão do Pilot QC: análise de Q30%, taxa de adaptadores e fração mitocondrial estimada para cálculo automático do número ideal de leituras, com caps entre 5M e 25M.	76
Figura 12 – Diagrama da lógica iterativa de k-mers: tentativa com k=39 (alta especificidade) seguida de <i>fallback</i> para k=33 (maior sensibilidade) quando a circularização não é alcançada.	79
Figura 13 – Três camadas de reprodutibilidade do pipeline: (1) código-fonte no GitHub, (2) ambiente isolado via Docker com versões fixadas, (3) orquestração via Nextflow DSL2.	83
Figura 14 – Redução de volume em cada etapa do pipeline para <i>A. leari</i> : tamanho dos arquivos por etapa (esquerda) e composição de bases após trimming (direita).	85
Figura 15 – Relatórios FastQC da leitura R1 (<i>A. leari</i>): qualidade <i>per-base</i> (acima) e conteúdo de adaptadores (abaixo).	88
Figura 16 – Relatórios FastQC da leitura R2 (<i>A. leari</i>): qualidade <i>per-base</i> (acima) e conteúdo de adaptadores (abaixo).	89
Figura 17 – Tempo de execução por etapa do pipeline para <i>A. leari</i> , com anotação da porcentagem do tempo total e classificação por tipo de operação (I/O-bound vs CPU-bound).	96
Figura 18 – Gráfico radar comparando as ferramentas analisadas em cinco eixos: completude do fluxo, reprodutibilidade, acessibilidade computacional, automação e generalidade taxonômica. A pontuação de cada eixo segue os critérios da Tabela 13.	105

Figura 19 – Mapa circular de polimorfismos de <i>A. hyacinthinus</i> (montagem vs. referência NCBI OR209186.1). Círculos vermelhos indicam SNPs na D-loop (11/19) e azuis em regiões codificantes (8/19). O triângulo amarelo (≈ 15.730) destaca a única ambiguidade detectada (NCBI=T, montagem=Y). A concentração de variantes na D-loop é consistente com a elevada taxa evolutiva característica dessa região.	108
Figura 20 – Mapa da distribuição geográfica de <i>Anodorhynchus leari</i> no nordeste do Brasil. Em roxo: área de ocorrência durante o ano todo; em amarelo: registros em passagem.	112
Figura 21 – <i>Anodorhynchus leari</i> fotografada em seu ambiente natural em Canudos, Bahia, Brasil.	113
Figura 22 – Mapa circular do mitogenoma de <i>A. leari</i> (16.986 bp), com a posição dos 37 genes coloridos por categoria funcional. Gerado automaticamente pelo pipeline via Biopython GenomeDiagram.	115
Figura 23 – Diagrama esquemático do <i>frameshift</i> do gene ND3: a inserção de um nucleotídeo na posição 174 desloca o quadro de leitura em +1, dividindo o gene em dois ORFs (<i>nad3_0</i> e <i>nad3_1</i>).	121
Figura 24 – Estruturas secundárias em trevo dos 22 tRNAs e 2 rRNAs do mitogenoma de <i>A. leari</i> , preditas pelo MITOS2/RNAplot. O tRNA-Ser(AGY) carece do braço DHU, conformação amplamente observada em metazoários.	124
Figura 25 – Diagrama de sintenia comparando os mitogenomas de <i>A. leari</i> (16.986 bp) e <i>A. hyacinthinus</i> (16.999 bp). Os blocos coloridos representam genes proporcionais ao seu comprimento no genoma; os trapézios translúcidos conectam regiões homólogas entre as duas espécies. O painel inferior compara o D-loop (OH_0) das duas espécies em escala, evidenciando uma diferença de 81 bp na região controle total, concentrada principalmente no segmento OH_0 (65 bp dos 81). . .	127
Figura 26 – Infográfico-resumo do trabalho: do problema inicial (87 GB de dados brutos), passando pelas 7 etapas do pipeline, até o resultado final (16.986 bp circularizado, 37 genes, GenBank-ready) e as 6 contribuições originais. A validação cruzada com <i>A. hyacinthinus</i> (99,888% de identidade com a referência NCBI) reforça a confiabilidade da abordagem.	132

LISTA DE TABELAS

Tabela 1 – Comparação entre ferramentas de montagem de organelas e o pipeline proposto.	43
Tabela 2 – Dicionário de dados do pipeline: arquivos intermediários, tipos, volumes e consumidores.	55
Tabela 3 – Arquitetura modular do pipeline: módulos, scripts e suas responsabilidades.	62
Tabela 4 – Versões fixadas dos componentes do pipeline.	64
Tabela 5 – Imagens Docker utilizadas no pipeline.	70
Tabela 6 – Categorias de entregáveis gerados automaticamente pelo pipeline. . . .	81
Tabela 7 – Parâmetros de execução do pipeline para as três espécies analisadas. .	84
Tabela 8 – Elementos visuais dos painéis FastQC e seu significado.	87
Tabela 9 – Métricas de montagem do mitogenoma para as três espécies analisadas.	91
Tabela 10 – Conteúdo gênico do mitogenoma de <i>A. leari</i> anotado pelo MITOS2. . .	93
Tabela 11 – Métricas de desempenho por etapa do pipeline (execução <i>A. leari</i> , 25M spots; 50M reads paired-end).	96
Tabela 12 – Cascata de redução de dados ao longo do pipeline.	99
Tabela 13 – Critérios de pontuação do gráfico radar comparativo (escala 1–5). . . .	104
Tabela 14 – Comparação nucleotídeo a nucleotídeo entre a montagem do pipeline e a referência NCBI para <i>A. hyacinthinus</i>	107
Tabela 15 – Composição nucleotídica do mitogenoma de <i>A. leari</i>	113
Tabela 16 – Conteúdo gênico do mitogenoma de <i>A. leari</i>	114
Tabela 17 – Códon de início e parada dos genes codificadores de proteínas de <i>A. leari</i> .	117
Tabela 18 – Genes de tRNA do mitogenoma de <i>A. leari</i> . As linhas em azul claro correspondem a tRNAs codificados na fita pesada (H, 14 genes) e as linhas em laranja claro a tRNAs codificados na fita leve (L, 8 genes). .	122
Tabela 19 – Comparação entre os mitogenomas de <i>A. leari</i> e <i>A. hyacinthinus</i>	125

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
BED	<i>Browser Extensible Data</i>
BLAST	<i>Basic Local Alignment Search Tool</i>
bp	Pares de bases (<i>base pairs</i>)
CDS	Sequência codificante (<i>Coding Sequence</i>)
CEMAVE	Centro Nacional de Pesquisa e Conservação de Aves Silvestres
CPU	Unidade central de processamento (<i>Central Processing Unit</i>)
CSB	Bloco de sequência conservado (<i>Conserved Sequence Block</i>)
D-loop	Alça de deslocamento (<i>Displacement Loop</i>) — região controle do mtDNA
DHU	Di-hidrouridina — braço estrutural do tRNA
DNA	Ácido desoxirribonucleico
dN/dS	Razão entre substituições não sinônimas e sinônimas (= Ka/Ks)
DSL2	<i>Domain Specific Language</i> versão 2 (Nextflow)
EN	<i>Endangered</i> — Em Perigo (categoria IUCN)
FAIR	<i>Findable, Accessible, Interoperable, and Reusable</i>
FASTA	Formato de arquivo para sequências biológicas (<i>FAST-All</i>)
FASTQ	Formato FASTA com escores de qualidade (<i>FASTA with Quality</i>)
GFF	<i>General Feature Format</i>
HPC	Computação de Alto Desempenho (<i>High Performance Computing</i>)
HTML	<i>HyperText Markup Language</i>
ICMBio	Instituto Chico Mendes de Conservação da Biodiversidade
I/O	Entrada/Saída (<i>Input/Output</i>)
IUCN	União Internacional para a Conservação da Natureza

IUPAC	<i>International Union of Pure and Applied Chemistry</i>
MAFFT	<i>Multiple Alignment using Fast Fourier Transform</i>
mRNA	RNA mensageiro
mtDNA	DNA mitocondrial
NCBI	<i>National Center for Biotechnology Information</i>
NGS	Sequenciamento de Nova Geração (<i>Next-Generation Sequencing</i>)
NUMTs	Inserções nucleares de DNA mitocondrial (<i>Nuclear Mitochondrial DNA segments</i>)
OGDRAW	<i>OrganelleGenomeDRAW</i>
ORF	Quadro aberto de leitura (<i>Open Reading Frame</i>)
PAN	Plano de Ação Nacional (para a conservação)
PCGs	Genes codificantes de proteínas (<i>Protein-Coding Genes</i>)
PDF	<i>Portable Document Format</i>
QC	Controle de qualidade (<i>Quality Control</i>)
RAM	Memória de acesso aleatório (<i>Random Access Memory</i>)
RNA	Ácido ribonucleico
rRNA	RNA ribossomal
RSCU	<i>Relative Synonymous Codon Usage</i>
SALVE	Sistema de Avaliação do Risco de Extinção da Biodiversidade (ICMBio)
SNP	Polimorfismo de nucleotídeo único (<i>Single Nucleotide Polymorphism</i>)
SRA	<i>Sequence Read Archive</i>
SSD	Unidade de estado sólido (<i>Solid State Drive</i>)
SVG	Gráficos vetoriais escaláveis (<i>Scalable Vector Graphics</i>)
tRNA	RNA transportador
UFRN	Universidade Federal do Rio Grande do Norte
VM	Máquina virtual (<i>Virtual Machine</i>)
WGS	Sequenciamento de genoma total (<i>Whole Genome Sequencing</i>)

SUMÁRIO

1	INTRODUÇÃO	18
1.1	Contextualização e Tema	18
1.2	Problema de Pesquisa	20
1.3	Objetivos	20
1.3.1	Objetivo Geral	20
1.3.2	Objetivos Específicos	20
1.4	Justificativa	21
1.5	Metodologia	23
1.6	Estrutura do Trabalho	23
2	REFERENCIAL TEÓRICO	25
2.1	Montagem <i>De Novo</i> de Genomas e a Análise Mitocondrial	25
2.2	Reprodutibilidade em Ciência Computacional	33
2.3	Tecnologia de Containerização com Docker	36
2.4	Sistemas de Gerenciamento de Workflows Científicos	38
3	TRABALHOS RELACIONADOS	40
3.1	MitoHiFi: Montagem com Leituras Longas	40
3.2	GetOrganelle: Montagem Baseada em Grafos	41
3.3	NOVOPlasty: Montagem <i>Seed-and-Extend</i> de Mitogenomas	41
3.4	MToolBox: Foco em Genomas Mitocondriais Humanos	42
3.5	MITObim: Estratégia de <i>Baiting and Iterative Mapping</i>	42
3.6	Análise Comparativa	43
4	METODOLOGIA	45
4.1	Processo de Desenvolvimento de Software	45
4.1.1	Validação por Espécie-Controle	46
4.1.2	Validação Cruzada por Congênere	47
4.1.3	Tratamento de Erros e Correções Iterativas	48
4.1.4	Aderência às Boas Práticas de Computação Científica	49
4.2	Visão Geral do Pipeline	49
4.2.1	Fluxo de Dados e Interfaces entre Containers	50
4.2.1.1	Interfaces de Dados: De Processo a Processo	51
4.2.1.2	Estrutura de Diretórios e Armazenamento Intermediário	53
4.2.1.3	Dicionário de Dados: Tipos, Estruturas e Semântica	55
4.2.1.4	Mecanismo de Orquestração: Nextflow como Maestro	56

4.2.1.5	Implicações para Reprodutibilidade e Publicação	57
4.3	Fluxo de Execução do Pipeline	57
4.3.1	Pré-requisitos e Preparação do Ambiente	57
4.3.2	Comando de Execução e Resiliência	58
4.3.3	Fluxo de Dados e Decisões Automáticas	58
4.3.4	Extensibilidade para Novas Espécies	60
4.4	Arquitetura Modular e Scripts do Pipeline	62
4.5	Ferramentas e Tecnologias Utilizadas	63
4.5.1	SRA-Toolkit	64
4.5.2	FastQC	65
4.5.3	Cutadapt e Trim Galore	66
4.5.4	NOVOPlasty	68
4.5.5	MITOS2	69
4.5.6	Docker	70
4.5.7	Nextflow	71
4.5.8	GitHub	72
4.6	Aquisição e Preparo dos Dados	73
4.7	Análise Piloto de Qualidade (Pilot QC)	73
4.7.1	Etapa 1 — Leituras Mitocondriais Necessárias	74
4.7.2	Etapa 2 — Leituras Totais a Baixar	75
4.8	Controle de Qualidade e Pré-processamento	77
4.9	Montagem do Mitogenoma	78
4.10	Anotação Funcional	80
4.11	Compilação dos Entregáveis	81
4.12	Automação e Reprodutibilidade	82
5	RESULTADOS E DISCUSSÃO	84
5.1	Execuções Realizadas	84
5.2	Aquisição e Preparo dos Dados	85
5.3	Controle de Qualidade e Pré-processamento	86
5.4	Montagem do Mitogenoma	91
5.5	Anotação Funcional	92
5.5.1	Caso Especial — Frameshift do ND3	93
5.6	Compilação dos Entregáveis e Formato GenBank	94
5.7	Análise de Desempenho e Eficiência Computacional	95
5.7.1	Gargalo de I/O: Download e Conversão SRA	97
5.7.2	Eficiência do Pré-processamento	97
5.7.3	Consumo de Memória do NOVOPlasty	98
5.7.4	Cascata de Redução de Dados	98

5.7.5	Pico de Armazenamento e Custo Computacional	99
5.7.6	Caminho Crítico e Otimização Implementada	100
5.7.7	Síntese da Análise de Desempenho	101
5.8	Discussão sobre a Robustez da Abordagem	102
5.8.1	Análise Comparativa Quantitativa: Radar de Desempenho	104
5.9	Validação Cruzada com <i>Anodorhynchus hyacinthinus</i>	106
5.9.1	Desafio: Dataset Metagenômico de Grande Escala	106
5.9.2	Comparação com a Referência NCBI	107
5.9.3	Otimização do Módulo de Download para Datasets de Grande Escala . . .	109
5.9.4	Significado da Validação Cruzada	109
6	O MITOGENOMA DA ARARA-AZUL-DE-LEAR	111
6.1	A Espécie	111
6.2	Caracterização Geral do Mitogenoma	113
6.3	Genes Codificadores de Proteínas	116
6.3.1	Análise Ka/Ks	117
6.3.2	Uso de Códon (RSCU)	118
6.3.3	O <i>Frameshift</i> do ND3: Uma Assinatura Evolutiva Conservada	119
6.3.3.1	Descoberta	119
6.3.3.2	Mecanismo Molecular	119
6.3.3.3	Distribuição Taxonômica	120
6.3.3.4	Resultado em <i>A. leari</i>	122
6.4	RNAs Transportadores e Ribossomais	122
6.5	Organização Gênica e Comparação com <i>A. hyacinthinus</i>	125
6.5.1	O D-loop como Marcador Diferencial	126
6.6	Perspectivas para a Genética de Conservação	128
6.6.1	Identificação Forense	128
6.6.2	Avaliação de Diversidade Genética	129
6.6.3	Filogeografia e Evolução do Gênero	129
6.6.4	Aplicabilidade a Outras Espécies Ameaçadas	130
6.7	Disponibilidade dos Dados	130
7	CONSIDERAÇÕES FINAIS	132
	REFERÊNCIAS	137

APÊNDICES	143
------------------	------------

APÊNDICE A – DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL GENERATIVA	144
---	------------

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO E TEMA

Os genomas mitocondriais — também denominados **mitogenomas** — constituem o conjunto completo de material genético contido na mitocôndria, **organela** (estrutura subcelular com função especializada) responsável pela produção de energia nas **células eucarióticas** (células que possuem núcleo delimitado por membrana — categoria que inclui animais, plantas e fungos, em oposição aos procariotos: bactérias e arqueias). Essas moléculas de DNA ocupam uma posição central na biologia evolutiva, genética de populações e sistemática, uma vez que oferecem informações valiosas sobre parentesco, variação intra e interespecífica e processos de conservação. O DNA mitocondrial, por suas características estruturais e funcionais — como a **herança geralmente materna** (transmissão predominante pela linhagem feminina), a baixa ocorrência de **recombinação** em comparação ao genoma nuclear e a elevada taxa evolutiva em relação a muitos marcadores nucleares —, tornou-se um marcador molecular amplamente utilizado em diferentes contextos biológicos (BOORE, 1999; EKBLOM; WOLF, 2014).

A amplitude das aplicações do mapeamento mitogenômico justifica a relevância desta linha de pesquisa para muito além de um único táxon. Na literatura, os mitogenomas são empregados principalmente em estudos de filogenia, identificação molecular de espécies, genética de populações, filogeografia e conservação, em razão de seu tamanho compacto, alta disponibilidade em cópias celulares e padrão de herança predominantemente materno (AQUADRO; GREENBERG, 1983; BOORE, 1999; HEBERT et al., 2003; EKBLOM; WOLF, 2014). No contexto humano, a sequência completa do mitogenoma foi descrita com aproximadamente 16,6 kb (16.569 bp) (ANDERSON et al., 1981). Na bioinformática, por seu tamanho reduzido e organização relativamente conservada em muitos metazoários, o mitogenoma constitui um modelo útil para o desenvolvimento e validação de estratégias de montagem *de novo* e anotação automática. O presente trabalho posiciona-se na interseção entre biologia da conservação e bioinformática aplicada.

O avanço das tecnologias de sequenciamento de nova geração (*Next-Generation Sequencing* — NGS) ampliou o acesso a grandes volumes de dados, favorecendo a obtenção de mitogenomas completos e de alta qualidade. No entanto, a reconstrução dessas moléculas a partir de dados brutos permanece um desafio técnico, especialmente no caso de **leituras curtas** (*reads* — os fragmentos individuais de sequência de DNA produzidos pelo sequenciador, tipicamente com 100 a 300 pares de bases), que exigem algoritmos capazes de lidar com cobertura variável, regiões repetitivas e ambiguidades de **montagem** — o processo computacional de reconstruir a sequência original do genoma a partir desses

fragmentos sobrepostos (MILLER; KOREN; SUTTON, 2010; EKBLÖM; WOLF, 2014). Nesse cenário, ferramentas especializadas, como o NOVOPlasty, têm desempenhado papel fundamental ao implementar estratégias de *seed-and-extend* capazes de recuperar genomas de organelas de forma eficiente a partir de dados de genoma total (DIERCKXSENS; MARDULYN; SMITS, 2017).

Embora a diversidade de softwares tenha contribuído para avanços significativos na montagem de organelas, a ausência de padronização metodológica ainda compromete a reprodutibilidade das análises. A multiplicidade de versões, dependências e configurações de ambiente gera obstáculos práticos para replicar experimentos, fenômeno amplamente conhecido como *dependency hell* (GRÜNING et al., 2018). Esse problema se insere no contexto mais amplo da crise de reprodutibilidade científica (BAKER, 2016), que tem motivado a adoção, na bioinformática, de práticas da engenharia de software, como a containerização de ambientes computacionais com Docker (MERKEL, 2014) e a orquestração de fluxos com sistemas de gerenciamento de *workflows*, a exemplo do Nextflow (Di Tommaso et al., 2017).

Além da montagem propriamente dita, a anotação funcional dos genes mitocondriais constitui uma etapa igualmente relevante, que permite identificar os genes codificadores de proteínas, RNAs transportadores e RNAs ribossômicos presentes na molécula reconstruída. Ferramentas como o MITOS2 automatizam essa tarefa (DONATH et al., 2019); contudo, em muitos fluxos práticos, a anotação ainda é realizada como uma etapa separada da montagem, frequentemente por meio de interfaces web externas, criando uma descontinuidade no fluxo analítico.

Soma-se a esses desafios computacionais uma barreira de infraestrutura frequentemente subestimada. Datasets de sequenciamento de genoma total alcançam dezenas a centenas de gigabytes — o dataset da arara-azul-de-lear (*Anodorhynchus leari*) utilizado neste trabalho, disponível no NCBI SRA sob o acesso SRR28399504, contém 118,5 milhões de *spots* (unidade do SRA correspondente, em bibliotecas *paired-end*, a um par de leituras) e totaliza aproximadamente 87 GB quando convertido para FASTQ descomprimido (Iridian Genomes, 2024). Processar esse volume na íntegra exigiria armazenamento temporário substancial — considerando-se também os arquivos intermediários gerados pelas etapas seguintes — e memória RAM significativa para a construção das estruturas de dados utilizadas pelos montadores, recursos indisponíveis em computadores pessoais típicos de estudantes e pequenos laboratórios. Sem estratégias inteligentes de redução de dados, a montagem de mitogenomas a partir de dados públicos ficaria restrita a grupos com acesso a servidores dedicados.

1.2 PROBLEMA DE PESQUISA

Diante do cenário apresentado — marcado pela fragmentação das ferramentas de montagem e anotação, pela ausência de padronização metodológica que compromete a reprodutibilidade, pela desconexão entre etapas analíticas que obriga o uso de interfaces web manuais, e pela barreira computacional imposta pelo volume dos dados de sequenciamento —, este trabalho busca responder à seguinte questão:

De que maneira é possível integrar, em um único fluxo de trabalho automatizado, as etapas de aquisição, controle de qualidade, montagem *de novo*, anotação funcional e preparação para submissão ao GenBank de genomas mitocondriais, garantindo reprodutibilidade, portabilidade e viabilidade computacional em hardware doméstico?

1.3 OBJETIVOS

1.3.1 Objetivo Geral

Desenvolver e validar um pipeline de bioinformática automatizado, reprodutível e portátil para a montagem *de novo* e anotação funcional de genomas mitocondriais, utilizando tecnologias de containerização (Docker) e sistemas de gerenciamento de *workflows* (Nextflow).

1.3.2 Objetivos Específicos

- a) Containerizar, por meio de Dockerfiles com versões fixadas, cada uma das ferramentas bioinformáticas necessárias ao pipeline (SRA-Toolkit, FastQC, Trim Galore, NOVOPlasty e MITOS2).
- b) Desenvolver o script de orquestração do pipeline utilizando Nextflow DSL2, definindo os processos, suas entradas, saídas e interdependências em módulos independentes.
- c) Integrar os containers Docker ao *workflow*, garantindo que cada etapa da análise seja executada em seu próprio ambiente isolado e pré-configurado.
- d) Implementar um módulo de análise piloto de qualidade (Pilot QC) capaz de determinar automaticamente o volume ideal de dados a serem processados, com base na qualidade das leituras e na fração mitocondrial estimada.
- e) Integrar a anotação funcional automatizada (MITOS2) ao pipeline, incluindo a geração de estruturas secundárias de tRNAs e rRNAs via ViennaRNA.

- f) Automatizar a geração de entregáveis em formato GenBank Flat File, com tratamento adequado de particularidades gênicas como o *frameshift* do ND3 em aves, tartarugas e crocodilianos.
- g) Validar o pipeline automatizado por meio de estudos de caso com dados públicos de sequenciamento de pelo menos duas espécies de grupos **taxonômicos** distintos — isto é, de posições diferentes na classificação biológica hierárquica (espécie, gênero, família, ordem, etc.) —, comparando os genomas montados e, quando aplicável, anotados com resultados de referência.
- h) Disponibilizar o pipeline completo e sua documentação em repositório público no GitHub, assegurando sua acessibilidade e reprodutibilidade pela comunidade científica.

1.4 JUSTIFICATIVA

A análise de mitogenomas representa um componente relevante para a biologia evolutiva, a genética de populações e a sistemática, dado que essas moléculas fornecem informações úteis sobre relações de parentesco, variação intra e interespecífica e processos de conservação. Sua relevância científica foi consolidada em trabalhos que destacaram o papel estrutural e evolutivo dos mitogenomas animais como marcadores moleculares (BOORE, 1999) e em contribuições mais recentes que ampliaram a obtenção automatizada de mitogenomas em contextos específicos, como leituras PacBio HiFi (ULIANO-SILVA et al., 2023).

Embora a obtenção de mitogenomas completos tenha sido amplamente favorecida pelo advento do NGS, a execução de pipelines de montagem ainda enfrenta desafios técnicos significativos. A diversidade de ferramentas, versões e dependências envolvidas gera um cenário de difícil replicação, conhecido como *dependency hell*, que compromete a reprodutibilidade e a padronização das análises (SANDVE et al., 2013; BAKER, 2016; GRÜNING et al., 2018).

Esse problema se torna especialmente relevante quando aplicado ao estudo de espécies ameaçadas de extinção, nas quais a disponibilidade de amostras biológicas é limitada e a confiabilidade dos resultados genômicos é crucial para fundamentar decisões de conservação. É o caso da **arara-azul-de-lear** (*Anodorhynchus leari*), ave endêmica da Caatinga nordestina do Brasil, classificada como “Em Perigo” (EN) pela ficha oficial do Sistema de Avaliação do Risco de Extinção da Biodiversidade (SALVE/ICMBio) (ARAÚJO et al., 2023). O censo simultâneo conduzido em 2022 pelo CEMAVE/ICMBio contabilizou 2.273 indivíduos na natureza — 2.254 no Raso da Catarina (BA) e 19 no Boqueirão da Onça —, refletindo tendência populacional crescente atribuída a mais de duas décadas de ações de conservação coordenadas (FAVORETTO, 2022). Apesar do quadro favorável

recente, a espécie ainda depende de dados genômicos acessíveis e validáveis para subsidiar programas de manejo, reprodução em cativeiro e monitoramento populacional. Embora uma reconstrução preliminar do mitogenoma da espécie tenha sido realizada em contexto acadêmico não publicado, esse procedimento ocorreu de forma manual, sem padronização metodológica e sem disponibilização pública do fluxo de trabalho — o que limita sua verificação e replicação por outros pesquisadores.

Um desafio adicional — e particularmente relevante para o presente trabalho — reside na **completude** dos pipelines existentes. A maioria das ferramentas e *workflows* disponíveis na literatura concentra-se em uma única etapa do ciclo analítico — tipicamente a montagem — sem integrar a anotação funcional, a geração de estruturas secundárias dos RNAs, nem a preparação dos arquivos para submissão a bancos de dados públicos como o GenBank. Como consequência prática, o pesquisador precisa intercalar etapas automatizadas com procedimentos manuais: copiar arquivos entre ferramentas com formatos distintos, recorrer a interfaces web externas para a anotação (e.g., MITOS2 via UseGalaxy) e converter manualmente os resultados para os formatos exigidos pelo NCBI. Cada uma dessas operações manuais introduz pontos de falha, etapas não rastreáveis e, sobretudo, dificuldade de reprodução por terceiros, comprometendo o ciclo analítico em sua totalidade. O pipeline aqui proposto endereça diretamente essa lacuna ao integrar, em um único fluxo automatizado, todas as etapas — desde a aquisição seletiva dos dados brutos no SRA até a geração dos arquivos prontos para submissão ao GenBank.

Adicionalmente, este trabalho apresenta como **contribuição original** o módulo **Pilot QC**, mecanismo de dimensionamento automático do volume de dados a ser processado a partir de uma estimativa empírica da fração mitocondrial nas leituras. Tal funcionalidade — desenvolvida no escopo deste TCC e até onde se verificou na literatura consultada não disponível nas ferramentas comparadas no Capítulo 3 — viabiliza a execução do pipeline em hardware doméstico ao evitar o processamento de centenas de gigabytes desnecessários quando uma fração reduzida do conjunto bruto já é suficiente para a montagem do mitogenoma.

Nesse contexto, torna-se necessário o desenvolvimento de soluções que conciliem robustez biológica, consistência computacional e acessibilidade de hardware. A adoção de práticas modernas da engenharia de software, como a containerização e os sistemas de gerenciamento de *workflows*, tem se mostrado fundamental para superar limitações de reprodutibilidade, além de permitir que fluxos analíticos sejam portáteis, escaláveis e transparentes (Di Tommaso et al., 2017; EWELS et al., 2020).

Assim, este trabalho justifica-se pela proposta de construir um pipeline automatizado e reprodutível que cubra o ciclo completo — desde a aquisição dos dados brutos até a geração de arquivos prontos para submissão ao GenBank (banco de dados público mantido pelo NCBI para depósito de sequências genéticas) —, unindo boas práticas de ciência aberta e engenharia computacional à relevância biológica dos mitogenomas. A apli-

cação ao caso concreto da arara-azul-de-lear demonstra não apenas a viabilidade técnica da abordagem, mas também sua contribuição direta para a conservação de uma espécie ameaçada da biodiversidade brasileira.

1.5 METODOLOGIA

O presente trabalho adota uma abordagem de pesquisa aplicada, de natureza experimental, com desenvolvimento iterativo e incremental de software (LARMAN; BASILI, 2003; SOMMERVILLE, 2016). O pipeline foi concebido a partir da experiência adquirida na disciplina Tópicos Especiais em Bioinformática A, ministrada pelo Prof. Jorge Estefano de Santana Souza, na qual um fluxo análogo de montagem mitogenômica foi utilizado de forma manual e não padronizada. O presente TCC formaliza, automatiza e expande substancialmente esse fluxo, integrando-o em um pipeline reprodutível implementado em Nextflow DSL2 e containerizado com Docker, seguindo boas práticas de engenharia de software científico (WILSON et al., 2014).

A validação foi realizada por meio de três estudos de caso com dados públicos do NCBI Sequence Read Archive (SRA) (LEINONEN; SUGAWARA; SHUMWAY, 2011): (i) *Diploprion bifasciatus* (Perciformes — peixe-sabão barrado), com dados do acesso SRR36182901 e mitogenoma de referência PZ143763.1, como espécie-controle para verificação funcional do pipeline; (ii) arara-azul-de-lear (*Anodorhynchus leari*, Psittaciformes — aves), com dados do acesso SRR28399504 (Iridian Genomes, 2024), como espécie-alvo para a aplicação final; e (iii) arara-azul-grande (*Anodorhynchus hyacinthinus*), com dados do acesso SRR36400750 e mitogenoma de referência OR209186.1, utilizada em validação cruzada recíproca com a espécie-alvo. Em todos os casos, os mitogenomas foram montados *de novo* a partir de leituras Illumina e comparados com referências disponíveis no GenBank.

O pipeline integra sete etapas sequenciais automatizadas: (1) análise piloto de qualidade para dimensionamento do volume de dados; (2) download e extração seletiva dos dados do SRA; (3) controle de qualidade com FastQC; (4) remoção de adaptadores e bases de baixa qualidade com Trim Galore; (5) montagem *de novo* com NOVOPlasty; (6) anotação funcional com MITOS2; e (7) compilação automática de 14 categorias de entregáveis, incluindo arquivos em formato GenBank Flat File prontos para submissão. Os detalhes de cada etapa, incluindo ferramentas, parâmetros e versões utilizadas, são apresentados no Capítulo 4.

1.6 ESTRUTURA DO TRABALHO

O presente trabalho está organizado em sete capítulos. Este primeiro capítulo apresentou a contextualização do tema, o problema de pesquisa, os objetivos, a justificativa e

um breve resumo metodológico.

O **Capítulo 2** reúne o referencial teórico, abordando os fundamentos da montagem *de novo* de genomas, as especificidades do DNA mitocondrial, a crise de reprodutibilidade em ciência computacional, a tecnologia de containerização com Docker e os sistemas de gerenciamento de *workflows* científicos.

O **Capítulo 3** analisa os trabalhos relacionados, revisando as principais ferramentas disponíveis para montagem de organelas — MitoHiFi, MITObim, GetOrganelle, MToolBox e NOVOPlasty — e apresenta uma análise comparativa entre elas.

O **Capítulo 4** detalha a metodologia, descrevendo o processo de desenvolvimento de software adotado, a visão geral e o fluxo de execução do pipeline, sua arquitetura modular, as ferramentas e tecnologias utilizadas, e cada uma das sete etapas da análise.

O **Capítulo 5** apresenta os resultados obtidos nas execuções do pipeline e a discussão, incluindo as métricas de montagem e anotação para as espécies analisadas, a análise de desempenho computacional e uma avaliação da robustez da abordagem.

O **Capítulo 6** é dedicado integralmente à arara-azul-de-lear, apresentando a caracterização detalhada de seu mitogenoma, a análise dos genes codificadores de proteínas, RNAs transportadores e ribossomais, a comparação com a espécie congênere *Anodorhynchus hyacinthinus* e as implicações dos resultados para a conservação da espécie.

O **Capítulo 7** encerra o trabalho com as considerações finais, sintetizando as contribuições alcançadas e indicando perspectivas para trabalhos futuros.


2 REFERENCIAL TEÓRICO

O presente capítulo reúne os fundamentos conceituais necessários para compreender a proposta metodológica deste trabalho. São abordados, inicialmente, os princípios da montagem *de novo* de genomas e as especificidades do DNA mitocondrial, que justificam sua relevância como objeto de estudo. Em seguida, discute-se a questão da reprodutibilidade em ciência computacional e as soluções contemporâneas oferecidas pela engenharia de software, com destaque para a tecnologia de containerização. Por fim, apresentam-se os sistemas de gerenciamento de *workflows* científicos, cuja integração com containers constitui a base para a construção de pipelines modernos, portáteis e reprodutíveis.

2.1 MONTAGEM *DE NOVO* DE GENOMAS E A ANÁLISE MITOCONDRIAL

Em bioinformática, a **montagem de genomas** (*genome assembly*) consiste no processo computacional de reconstruir a sequência original de DNA a partir de fragmentos obtidos por tecnologias de Sequenciamento de Nova Geração (NGS). O conceito é análogo à reconstrução de um texto completo a partir de milhões de trechos sobrepostos — cada trecho sendo uma **leitura** (*read*), um fragmento curto de sequência gerado pelo sequenciador. O método mais amplamente utilizado para gerar esses fragmentos é o *shotgun sequencing*, no qual o DNA genômico é clivado aleatoriamente em milhões de pequenos pedaços que, posteriormente, são sequenciados. Essa estratégia permite obter alta **cobertura** do genoma, dependendo da profundidade de sequenciamento — isto é, cada posição do DNA pode ser representada por múltiplas leituras, tipicamente dezenas a centenas de vezes —, mas resulta em dados fragmentados que precisam ser cuidadosamente alinhados e sobrepostos para permitir a reconstrução da sequência completa (EKBLÖM; WOLF, 2014). A Figura 1 ilustra esquematicamente esse processo. A complexidade computacional dessa tarefa motivou o desenvolvimento de algoritmos especializados, baseados em técnicas como grafos de De Bruijn — estrutura em que, em uma formulação comum, cada nó representa uma subsequência de k nucleotídeos consecutivos (denominada **k-mer**), e cada aresta representa sobreposições entre k-mers adjacentes — e estratégias de sobreposição-layout-consenso (MILLER; KOREN; SUTTON, 2010).

Figura 1 – Estratégia de *shotgun sequencing*: (a) clivagem aleatória do DNA genômico em fragmentos de tamanhos variados (Fragmentos A, B e C); (b) sequenciamento de cada fragmento em leituras curtas e uniformes (~ 150 bp); (c) alinhamento das leituras por posição genômica — as zonas de sobreposição entre fragmentos adjacentes permitem a reconstrução da sequência completa.



Fonte: Elaborado pelo autor (2026).

Conforme ilustrado na Figura 1, o processo envolve três estágios principais. No painel (a), o DNA genômico é fragmentado aleatoriamente em milhões de pedaços de tamanhos variados (representados pelos Fragmentos A, B e C), assegurando cobertura uniforme do genoma sem viés posicional. No painel (b), cada fragmento é sequenciado em paralelo na plataforma Illumina, gerando milhões de leituras curtas e uniformes (~ 150 bp), todas no mesmo formato e prontas para análise computacional. No painel (c), as leituras são alinhadas computacionalmente por posição genômica: as zonas de sobreposição entre fragmentos adjacentes permitem reconstruir, gradualmente, a sequência original completa. É essa última etapa — a **montagem** — que constitui o desafio computacional central abordado neste trabalho.

Na montagem genômica, fragmentos sobrepostos são inicialmente agrupados em **contigs** (*contiguous sequences* — sequências contínuas reconstruídas a partir do alinhamento de leituras sobrepostas, análogas a blocos de texto já montados). Quando existe informação adicional que permite inferir a ordem relativa entre diferentes contigs — como dados de **leituras pareadas** (*paired-end reads*: pares de leituras gerados a partir das duas extremidades do mesmo fragmento de DNA, com distância conhecida entre elas) —, esses podem ser organizados em estruturas mais amplas chamadas **scaffolds**. Assim, enquanto os contigs representam sequências consolidadas diretamente a partir das leituras, os scaffolds constituem hipóteses mais abrangentes sobre a organização genômica, servindo como passo intermediário até a obtenção de montagens completas e anotadas.

As tecnologias de NGS diferem substancialmente no comprimento das leituras produzidas. Sequenciadores Illumina, por exemplo, geram leituras curtas de alta acurácia (50 a 300 pares de bases), que exigem algoritmos sofisticados para lidar com regiões repetitivas. Em contrapartida, tecnologias de leituras longas, como PacBio e Oxford Nanopore, produzem leituras que podem alcançar milhares de pares de bases em uma única sequência, favorecendo a continuidade da montagem (EKBLOM; WOLF, 2014). A Figura 2 resume as principais características dessas plataformas.

Figura 2 – Comparativo das principais tecnologias de sequenciamento: Illumina (leituras curtas, alta acurácia), PacBio HiFi (leituras longas, alta fidelidade) e Oxford Nanopore (leituras ultra-longas, menor acurácia).

Comparação das tecnologias de sequenciamento de DNA

Tecnologia	Leitura	Acurácia	Rendimento	Custo/Gb
Illumina	50-300 bp	~99,9%	Muito alto	Baixo
PacBio HiFi	>10.000 bp	~99,9%	Moderado	Alto
Oxford Nanopore	>100.000 bp	~95-99%	Variável	Moderado

Fonte: Elaborado pelo autor (2026).

Como evidenciado na Figura 2, a escolha da tecnologia de sequenciamento envolve um compromisso entre comprimento das leituras, acurácia e custo. O presente trabalho utiliza dados Illumina (leituras curtas de alta acurácia), que estão amplamente representados em bases públicas de sequenciamento e são a entrada padrão das ferramentas de montagem de organelas mais utilizadas.

O DNA mitocondrial (mtDNA) reúne um conjunto de particularidades que o tornam um alvo privilegiado para a montagem *de novo*. Antes de descrevê-las, convém definir conceitos fundamentais da biologia molecular que serão recorrentes ao longo deste trabalho.


Gene é um trecho de DNA que contém as instruções para a síntese de uma molécula funcional — geralmente uma **proteína**, macromolécula que executa a maioria das funções celulares (catálise enzimática, transporte de substâncias, estrutura celular). O DNA é composto por uma sequência de **nucleotídeos**, unidades químicas identificadas pelas letras A (adenina), T (timina), G (guanina) e C (citosina). Dois nucleotídeos complementares em fitas opostas (A com T, G com C) formam um **par de bases** (bp, do inglês *base pair*), a unidade de medida padrão para comprimento de sequências genômicas. A informação genética contida no DNA é lida em blocos de três nucleotídeos consecutivos chamados **códons**: cada códon especifica um **aminoácido**, os “blocos de construção” das proteínas (existem 20 aminoácidos padrão, como fenilalanina, valina, isoleucina, entre outros). Um gene que codifica uma proteína possui um **códon de início** (tipicamente ATG, que sinaliza onde a tradução deve começar) e um **códon de término** ou **códon de parada** (como TAA, TAG ou TGA, que sinaliza onde a tradução deve parar). O fluxo da informação genética segue o chamado **dogma central da biologia molecular**: o DNA é transcrito em **RNA mensageiro** (mRNA), que por sua vez é traduzido em proteína pelos **ribossomos** — complexos macromoleculares compostos por proteínas e **RNA ribossomal** (rRNA). Nesse processo de tradução, cada códon do mRNA é reconhecido por uma molécula de **RNA transportador** (tRNA), que carrega o aminoácido correspondente e o posiciona no ribossomo para ser incorporado à cadeia proteica em crescimento. A região do tRNA que reconhece o códon é chamada **anticódon** — uma sequência de três nucleotídeos complementar ao códon do mRNA (ALBERTS et al., 2022).

Em metazoários (animais multicelulares), o mtDNA corresponde a uma molécula **circular** de fita dupla — diferentemente dos **cromossomos** nucleares (estruturas lineares de DNA compactado localizadas no núcleo da célula, que carregam a maior parte da informação genética), que são lineares, o DNA mitocondrial forma um anel contínuo sem extremidades —, com tamanho geralmente entre 12 e 22 mil pares de bases, codificando tipicamente 37 genes: 13 genes codificadores de proteínas associadas à **fosforilação oxidativa** (o conjunto de reações bioquímicas que a mitocôndria utiliza para produzir ATP, a molécula de energia da célula), 22 tRNAs e 2 rRNAs (ANDERSON et al., 1981; ASAKAWA et al., 1995; BOORE, 1999). Em sua revisão seminal, Boore (1999) observou que, embora a economia extrema de tamanho seja aparente em muitos casos, essa visão — até então quase axiomática — é refutada por mitogenomas com grandes quantidades de sequência não codificante descobertos em alguns artrópodes, moluscos e nematódeos, demonstrando que as pressões seletivas sobre o tamanho do mtDNA variam substancialmente entre linhagens. O sequenciamento completo do genoma mitocondrial humano

por Anderson et al. (1981) representou um marco histórico, estabelecendo o modelo de referência para a organização gênica mitocondrial dos metazoários. A Figura 3 apresenta a organização típica de um mitogenoma de vertebrado.

Figura 3 – Representação circular esquemática de um genoma mitocondrial típico de vertebrado, mostrando a distribuição dos 37 genes (13 CDS, 22 tRNAs, 2 rRNAs), a região controle (D-loop) e as fitas pesada (H) e leve (L).

Organização típica do genoma mitocondrial de vertebrados




Na Figura 3, observa-se a distribuição dos 37 genes ao longo das duas fitas da molécula circular: a fita pesada (H, externa) codifica a maioria dos genes, enquanto a fita leve (L, interna) contém o gene ND6 e oito tRNAs. A região controle (D-loop), que não codifica proteínas, costuma ser o principal segmento não codificante de tamanho significativo em mitogenomas típicos de vertebrados, responsável pela regulação da replicação e transcrição do mtDNA (BOORE, 1999).

A ausência de **íntrons** (segmentos não codificantes que, nos genes nucleares, intercalam as regiões codificantes e precisam ser removidos antes da tradução), a estrutura compacta e a elevada taxa de cópias por célula tornam o mtDNA especialmente acessível, facilitando sua recuperação mesmo em experimentos voltados ao genoma nuclear, nos quais ele aparece como subproduto. Além disso, características funcionais como a herança predominantemente materna, a baixa ocorrência de recombinação e a taxa evolutiva frequentemente superior à de muitos marcadores nucleares ampliam sua utilidade em estudos biológicos (BOORE, 1999). Essas propriedades explicam sua ampla aplicação em análises de genética de populações, **filogeografia** (estudo da distribuição geográfica de linhagens genéticas), sistemática e conservação da biodiversidade.

Para explorar essas vantagens, foram desenvolvidos algoritmos específicos de montagem. Uma das abordagens mais empregadas é a *seed-and-extend* (semente-e-extensão), em que uma sequência inicial conhecida (*seed* — semente) — que pode ser um gene ou até mesmo um fragmento de organela de espécie próxima — serve como ponto de partida para estender iterativamente a montagem até que a molécula circular seja reconstruída. Quando as extremidades da sequência em construção se sobrepõem, indicando que o genoma forma um anel contínuo, diz-se que a montagem foi **circularizada** — forte indício de que o genoma mitocondrial completo foi recuperado com sucesso. O NOVOPlasty é um dos principais programas baseados nessa estratégia, destacando-se pela eficiência na recuperação de genomas mitocondriais e cloroplastidiais a partir de dados de genoma total, conforme ilustrado na Figura 4 (DIERCKXSENS; MARDULYN; SMITS, 2017). Avanços recentes, como o pipeline MitoHiFi, exploram leituras longas de alta fidelidade, evidenciando a constante evolução das ferramentas voltadas à montagem de organelas (ULIANO-SILVA et al., 2023).

Figura 4 – Diagrama ilustrativo da estratégia *seed-and-extend*: (a) sequência semente; (b) extensão iterativa a partir de leituras sobrepostas; (c) circularização quando as extremidades se encontram.



Fonte: Elaborado pelo autor (2026).

A Figura 4 evidencia os três estágios do algoritmo. No painel (a), define-se a **sequência semente** — tipicamente o gene *cox1* de uma espécie filogeneticamente próxima, escolhido por sua conservação interespecífica e ampla disponibilidade em bancos públicos. A semente serve como âncora para todo o processo: o algoritmo a usa como ponto de partida fixo, a partir do qual a montagem cresce em ambas as extremidades.

No painel (b), ocorre o **ciclo iterativo de extensão**. A cada iteração, o algoritmo: (i) examina as bases nas extremidades 5' e 3' da sequência montada até o momento; (ii) busca, no conjunto de leituras pré-processadas, aquelas cujo k-mer terminal coincide com a extremidade em construção; (iii) avalia o consenso entre as leituras candidatas para decidir qual base anexar; (iv) estende a sequência incorporando a base mais bem suportada. O ciclo se repete até atingir uma de três condições de parada: **(1)** circularização (descrita a seguir); **(2)** ausência de novas leituras compatíveis com as extremidades; ou **(3)** extrapolação do tamanho máximo de genoma esperado, definido pelo parâmetro `genome_range`.

Por fim, no painel (c), ocorre a **circularização** — a condição ideal de parada. Ela é detectada quando as duas extremidades em extensão produzem leituras que se sobrepõem mutuamente, indicando que a molécula foi reconstruída por completo e forma um anel fechado. Quando essa condição não é alcançada, o algoritmo entrega uma sequência linear (*contig*), sinalizando montagem incompleta — situação que o pipeline trata por meio da estratégia de *fallback* de k-mer descrita no Capítulo 4.

Complementarmente à montagem, a **anotação funcional** dos genes mitocondriais

permite identificar e classificar os elementos codificantes da molécula reconstruída — ou seja, determinar quais genes estão presentes, suas posições exatas e suas funções biológicas. Para metazoários, ferramentas como o MITOS2 combinam evidências de homologia e modelos específicos para genes codificadores de proteínas com modelos de covariância, como os utilizados pelo Infernal, para a predição de tRNAs e rRNAs, produzindo anotações em formatos padronizados como **GFF3** (*General Feature Format version 3* — formato tabular que especifica a localização e o tipo de cada gene no genoma) (DONATH et al., 2019). A integração da etapa de anotação em pipelines automatizados de montagem permanece, contudo, uma lacuna em muitas soluções disponíveis na literatura. O emprego do MITOS2 como ferramenta primária de anotação em estudos recentes abrangendo vertebrados (ZHAN et al., 2024; KUNDU et al., 2024) e invertebrados (SHI et al., 2024; TAO et al., 2024) indica sua ampla utilização pela comunidade científica e reforça a pertinência de sua integração em fluxos automatizados.

2.2 REPRODUTIBILIDADE EM CIÊNCIA COMPUTACIONAL

A reprodutibilidade é um pilar do método científico, consistindo na capacidade de um pesquisador independente replicar um experimento, com os mesmos materiais e métodos, e obter resultados consistentes. Em pesquisas computacionais, isso se traduz na possibilidade de executar o mesmo código e software sobre os mesmos dados e chegar ao mesmo resultado (PENG, 2011; SANDVE et al., 2013).


Contudo, a ciência moderna enfrenta o que tem sido amplamente denominado como uma “crise de reprodutibilidade”. Em uma pesquisa abrangente com 1.576 pesquisadores de diversas áreas, Baker (2016) revelou que 90% dos entrevistados reconhecem a existência dessa crise — sendo que 52% a consideram significativa e 38% a classificam como leve. Uma barreira crítica identificada por Peng (2011) é que, em muitos casos, o código computacional utilizado nas análises simplesmente não está mais disponível: softwares iterativos frequentemente não registram as ações dos usuários de forma concreta, e mesmo quando scripts são utilizados, a combinação de múltiplos pacotes raramente é preservada de modo reprodutível. No domínio da bioinformática, essa crise é particularmente acentuada devido à alta complexidade dos pipelines de análise. Um único pipeline pode envolver dezenas de ferramentas de software distintas, cada uma desenvolvida por diferentes grupos, em diferentes linguagens de programação e com um conjunto único e, por vezes, conflitante de dependências de bibliotecas e do próprio sistema operacional. A tarefa de instalar e configurar manualmente esse ecossistema de software para replicar uma análise é extremamente suscetível a erros, uma condição frequentemente descrita como *dependency hell* (inferno de dependências) (GRÜNING et al., 2018).

Pequenas variações na versão de uma ferramenta ou de uma biblioteca subjacente podem levar a resultados drasticamente diferentes, comprometendo a validade e a

confiabilidade da pesquisa. Essa barreira técnica não apenas dificulta a verificação dos resultados, mas também impede a reutilização e a adaptação de métodos computacionais, contrariando os princípios FAIR (*Findable, Accessible, Interoperable, and Reusable*), que visam maximizar o valor dos dados e das análises científicas ao enfatizar, em particular, a capacidade de máquinas encontrarem e utilizarem dados automaticamente (SANDVE et al., 2013; WILKINSON et al., 2016; GRÜNING et al., 2018).

A resposta da comunidade científica a esse problema tem sido a adoção da **containerização** — técnica que encapsula uma ferramenta junto com todas as suas dependências (bibliotecas, intérpretes, configurações e até parte do sistema operacional base) em uma unidade autocontida e portátil chamada **container**. A plataforma de referência para essa abordagem é o **Docker** (MERKEL, 2014), que se tornou padrão de fato em bioinformática moderna por permitir isolamento confiável entre ferramentas com requisitos conflitantes, sem o *overhead* associado a máquinas virtuais tradicionais. Os detalhes técnicos da arquitetura Docker — imagens, containers, Dockerfiles e a relação com o sistema operacional hospedeiro — são apresentados na Seção 2.3. A Figura 5 contrasta visualmente as duas realidades aqui descritas: de um lado, a instalação manual com conflitos de versões (cenário do “inferno de dependências”); de outro, a solução containerizada em que cada ferramenta opera em seu próprio ambiente isolado.

Figura 5 – Conflito de dependências em pipelines bioinformáticos e a solução com containerização Docker. **Esquerda:** instalação manual em que MITOS2 exige Python ≥ 3.8 enquanto o Cutadapt (via Trim Galore) requer Python 2.7, resultando em versões incompatíveis no mesmo sistema operacional. **Direita:** cada ferramenta é empacotada em seu próprio container Docker com dependências isoladas, eliminando conflitos.



Fonte: Elaborado pelo autor (2026).

O painel esquerdo da Figura 5 ilustra o cenário típico de instalação manual, em que diferentes ferramentas exigem versões conflitantes das mesmas bibliotecas, tornando a configuração do ambiente um obstáculo frequentemente intransponível para pesquisadores sem formação em TI. O painel direito mostra a solução containerizada, na qual cada ferramenta é encapsulada em seu próprio ambiente isolado, eliminando conflitos de

dependências e favorecendo execução consistente em diferentes máquinas.


2.3 TECNOLOGIA DE CONTEINERIZAÇÃO COM DOCKER

A containerização introduzida na seção anterior pode ser tecnicamente classificada como uma forma de **virtualização em nível de sistema operacional** (*OS-level virtualization*), distinta da **virtualização tradicional** baseada em *hypervisor* (utilizada por máquinas virtuais como VirtualBox e VMware). Enquanto a virtualização tradicional emula uma máquina inteira — incluindo um sistema operacional convidado completo executado sobre o *hypervisor* —, a virtualização em nível de SO aproveita mecanismos do próprio kernel do hospedeiro (como *cgroups* e *namespaces* no Linux) para isolar processos em ambientes independentes, sem a necessidade de duplicar o sistema operacional. Containers Docker são, portanto, processos isolados que compartilham o kernel do hospedeiro, mas enxergam ambientes de execução independentes uns dos outros. Essa distinção arquitetural é a razão pela qual containers iniciam em segundos (e não em minutos como VMs) e ocupam ordens de magnitude menos disco (MERKEL, 2014; GRÜNING et al., 2018).

O funcionamento do Docker baseia-se em dois conceitos centrais: a imagem e o container. A imagem é um template estático e imutável, construído a partir de um arquivo de texto com instruções sequenciais chamado Dockerfile. Esse arquivo serve como uma “receita” que define o sistema operacional base, as dependências a serem instaladas e os comandos a serem executados, criando um ambiente de software completo e auto-contido. O container, por sua vez, é uma instância executável e isolada de uma imagem. Ao contrário de máquinas virtuais tradicionais, os containers compartilham o kernel do sistema operacional hospedeiro, o que os torna leves e eficientes para iniciar (MERKEL, 2014).

Essa arquitetura favorece que um software containerizado se comporte de maneira consistente entre diferentes ambientes que possuam o Docker instalado — seja em computadores pessoais, servidores de produção ou ambientes de nuvem — resolvendo de forma eficaz o problema da inconsistência de ambientes e sendo um passo fundamental para a criação de pipelines científicos portáteis e reproduzíveis (Di Tommaso et al., 2017). A Figura 6 compara a arquitetura de containers Docker com a de máquinas virtuais tradicionais.

Figura 6 – Comparação arquitetural entre Máquina Virtual (VM) e Docker. **Esquerda:** pilha VM com cinco camadas, incluindo um **SO Convidado** completo duplicado por cada VM — overhead de 2–5 GB e inicialização de 1–2 minutos por instância. **Direita:** containers Docker compartilham o SO Host e o Docker Engine; cada ferramenta é isolada em seu próprio container com dependências independentes, e o ciclo de vida (Dockerfile → Imagem → Container) é definido por um arquivo de texto reprodutível.



Fonte: Elaborado pelo autor (2026).

A diferença fundamental evidenciada na Figura 6 reside na ausência da camada de sistema operacional convidado nos containers: enquanto cada máquina virtual embarca um sistema operacional completo (Guest OS), os containers compartilham o kernel do hospedeiro, resultando, em geral, em imagens menores e tempos de inicialização mais

rápidos do que máquinas virtuais tradicionais. Essa eficiência torna a containerização particularmente adequada para pipelines de bioinformática, nos quais dezenas de ferramentas distintas precisam ser executadas sequencialmente.

2.4 SISTEMAS DE GERENCIAMENTO DE WORKFLOWS CIENTÍFICOS

A containerização resolve a questão do ambiente de software, mas não a orquestração das múltiplas etapas que compõem uma análise bioinformática. A execução manual e sequencial de cada container é ineficiente e propensa a erros. Para gerenciar essa complexidade, foram desenvolvidos Sistemas de Gerenciamento de Workflows (*Workflow Management Systems*), como o Nextflow (Di Tommaso et al., 2017) e o Snakemake (KöSTER; RAHMANN, 2012). Essas plataformas permitem que os pesquisadores definam pipelines computacionais complexos por meio de linguagens de alto nível.

Nesses sistemas, um *workflow* é decomposto em uma série de processos ou regras interconectadas. Cada processo define uma tarefa computacional discreta, especificando seus comandos, suas entradas (arquivos ou variáveis) e suas saídas. O gerenciador de *workflow* é então responsável por monitorar o estado dos dados e executar os processos na ordem correta, automatizando o fluxo de informação entre as etapas.

A principal vantagem dessas ferramentas reside na abstração da camada de execução. Elas integram-se nativamente com tecnologias como Docker, permitindo que cada processo seja executado em seu próprio container pré-configurado. Além disso, são compatíveis com diversos ambientes de execução, desde computadores pessoais até clusters de computação de alto desempenho (HPC) e plataformas de nuvem. Isso confere ao pipeline características essenciais para a ciência moderna: portabilidade, escalabilidade e retomada automática (*resumability*) em caso de falhas, evitando o reprocessamento de etapas já concluídas.

Para tornar concreta a noção de “prática de reprodutibilidade”, considere um cenário ilustrativo. Um pesquisador deseja replicar, três anos após a publicação, a montagem mitocondrial de uma espécie. Sem as práticas aqui descritas, ele precisaria localizar o autor para obter os scripts originais (frequentemente dispersos ou perdidos), tentar instalar manualmente versões específicas de cinco a sete ferramentas distintas (algumas possivelmente indisponíveis nos repositórios atuais) e, ainda assim, correria o risco de obter resultados ligeiramente diferentes devido a atualizações implícitas de bibliotecas do sistema. Com um pipeline containerizado, versionado e orquestrado por Nextflow, a réplica reduz-se a um único comando (`nextflow run <pipeline> -profile <espécie>`): o gerenciador obtém automaticamente as imagens Docker fixadas nas versões originais e produz resultados idênticos aos publicados, independentemente do hardware, do sistema operacional

ou do intervalo decorrido. Essa transição — de procedimento informal e dependente de pessoas para artefato versionado e auto-executável — é o que se entende, na prática, por reprodutibilidade computacional.

A combinação de um gerenciador de *workflows* com a containerização consolidou-se como uma prática recomendada para o desenvolvimento de pipelines de bioinformática, sendo a base de iniciativas comunitárias como o nf-core, que busca padronizar e compartilhar pipelines que seguem as melhores práticas de reprodutibilidade (EWELS et al., 2020).

O referencial teórico expõe os conceitos fundamentais que dão suporte à proposta deste trabalho, abordando desde os princípios de montagem *de novo* de genomas até as soluções contemporâneas de reprodutibilidade, como a containerização e os sistemas de gerenciamento de *workflows*. Esses conceitos fornecem a base conceitual sobre a qual se apoiam os trabalhos relacionados, discutidos no Capítulo 3, que permitem situar a presente proposta no estado da arte da bioinformática aplicada à montagem de mitogenomas.

3 TRABALHOS RELACIONADOS

Nesta seção, são apresentados e analisados trabalhos recentes da literatura que, assim como este projeto, propõem soluções computacionais para a montagem de genomas de organelas. O objetivo desta análise comparativa é contextualizar a presente proposta no estado da arte da área, identificando as abordagens metodológicas existentes e destacando os diferenciais e a contribuição original do pipeline desenvolvido neste trabalho.

3.1 MITOHIFI: MONTAGEM COM LEITURAS LONGAS

Um trabalho relevante na área é o MitoHiFi, um pipeline desenvolvido para a montagem de genomas mitocondriais a partir de dados de **leituras longas** de alta fidelidade (PacBio HiFi — tecnologia que produz leituras de milhares de pares de bases com alta precisão, em contraste com as leituras curtas de 100–300 bp geradas pela plataforma Illumina). Proposto por Uliano-Silva et al. (2023), o objetivo principal era criar um método que aproveitasse a extensão e a precisão deste tipo de dado para gerar mitogenomas completos e corretamente circularizados com maior eficiência. A metodologia do MitoHiFi integra ferramentas como o *hifiasm* (CHENG et al., 2021) para montagem e rotinas de identificação, circularização, escolha da sequência representativa e anotação do mitogenoma, com dependências gerenciadas por ambientes de software específicos — tipicamente **Conda** (gerenciador de pacotes consolidado no ecossistema Python e bioinformática) ou **containers** (genéricos e independentes de linguagem, como Docker), conforme a forma de instalação escolhida pelo usuário.

A abordagem do MitoHiFi é recente e voltada ao aproveitamento de leituras PacBio HiFi. Seus resultados são relevantes: o pipeline foi utilizado para montar 374 mitogenomas (368 Metazoa e 6 Fungi) em projetos como o **Darwin Tree of Life** (DARWIN TREE OF LIFE PROJECT CONSORTIUM, 2022), o **Vertebrate Genomes Project** (RHIE et al., 2021) e o Aquatic Symbiosis Genome Project ¹, além de identificar automaticamente variantes decorrentes de heteroplasmia e inserções nucleares de sequências mitocondriais (NUMTs) (ULIANO-SILVA et al., 2023). No entanto, por depender de um conjunto próprio de scripts e opções de instalação, sua portabilidade e reprodutibilidade podem variar conforme o ambiente de execução quando comparadas a fluxos integralmente declarados em um gerenciador de *workflows* DSL2 com containers versionados em todas as etapas. O diferencial do presente TCC reside precisamente neste ponto: enquanto o MitoHiFi prioriza dados de leituras longas, nossa proposta foca em uma arquitetura de software

¹ Disponível em <<https://www.aquaticsymbiosisgenomics.org/>>.

voltada à reprodutibilidade, utilizando Docker e Nextflow, para favorecer que o pipeline de montagem baseado em leituras curtas seja reprodutível e portátil.

3.2 GETORGANELLE: MONTAGEM BASEADA EM GRAFOS

O GetOrganelle, proposto por Jin et al. (2020), é uma ferramenta recente e amplamente utilizada para montagem de organelas. Ele utiliza **grafos de montagem** (estruturas matemáticas em que os nós representam fragmentos de sequência e as arestas representam sobreposições entre eles) derivados de dados de NGS para isolar e reconstruir genomas de organelas, oferecendo resultados robustos tanto para mitocôndrias quanto para cloroplastos (organelas fotossintetizantes de plantas). Em uma avaliação sistemática com 50 datasets publicados de plantas, o GetOrganelle foi capaz de remontar plastomas circulares em 47 dos 50 casos — uma taxa de sucesso superior à do NOVOPlasty nesse conjunto de plastomas de plantas. Além disso, a avaliação por mapeamento de reads demonstrou que os plastomas montados pelo GetOrganelle são geralmente mais acurados que os publicados originalmente ou remontados pelo NOVOPlasty (JIN et al., 2020). A ferramenta tem se destacado também por sua capacidade de gerar todas as configurações possíveis quando os genomas apresentam configurações *flip-flop* ou outros isômeros mediados por repetições, oferecendo resultados consistentes mesmo em organismos com maior complexidade genômica.

No entanto, assim como outras ferramentas tradicionais, o GetOrganelle depende de um ambiente de software adequado para ser executado, geralmente configurado manualmente pelo usuário ou via gerenciadores como Conda, o que ainda pode limitar sua reprodutibilidade plena em diferentes contextos computacionais.

3.3 NOVOPLASTY: MONTAGEM *SEED-AND-EXTEND* DE MITOGENOMAS

O NOVOPlasty, proposto por Dierckxsens, Mardulyn e Smits (2017), é um montador especializado em organelas baseado na estratégia *seed-and-extend* apresentada no Capítulo 2. A partir de uma única sequência semente — tipicamente um gene mitocondrial conservado, como o *cox1*, de uma espécie filogeneticamente próxima —, o algoritmo recruta iterativamente leituras curtas que se sobrepõem às extremidades da montagem em construção, estendendo a sequência até que as duas pontas se encontrem e a molécula circular seja reconstruída. Essa abordagem dispensa a montagem prévia do genoma total e a construção de grafos globais, resultando em consumo de memória e tempo de execução significativamente menores do que ferramentas baseadas em montagem completa do genoma nuclear.

Embora ferramentas mais recentes, como o GetOrganelle, apresentem taxas de sucesso superiores em plastomas de plantas, a literatura indica que o NOVOPlasty permanece amplamente empregado para a montagem de mitogenomas de metazoários, sendo adotado, por exemplo, em estudo filogenômico recente da ordem Squamata baseado em 213 mitogenomas, com foco em Anguimorpha (ZHAN et al., 2024). Essa adoção sustentada, somada ao baixo requisito computacional e à adequação a leituras curtas Illumina — tecnologia utilizada neste trabalho —, justifica sua escolha como montador primário do pipeline proposto.

3.4 MTOOLBOX: FOCO EM GENOMAS MITOCONDRIAIS HUMANOS

O MToolBox, apresentado por Calabrese et al. (2014), foi um dos primeiros pipelines integrados voltados especificamente para o estudo de genomas mitocondriais humanos. Ele combina reconstrução do mtDNA, anotação/priorização de variantes e análise funcional em um único fluxo, permitindo identificar **variantes mitocondriais** (alterações pontuais na sequência de DNA que distinguem indivíduos ou populações) relevantes para estudos biomédicos e populacionais.

Apesar de sua contribuição para o campo, o MToolBox é fortemente orientado ao contexto humano e tem aplicabilidade limitada a outros organismos. Além disso, por ter sido desenvolvido antes da adoção massiva de containers e *workflows*, não incorporava originalmente recursos de portabilidade e reprodutibilidade presentes em soluções mais modernas.

3.5 MITOBIM: ESTRATÉGIA DE *BAITING AND ITERATIVE MAPPING*

O MITObim, desenvolvido por Hahn, Bachmann e Chevreux (2013), foi um dos primeiros métodos amplamente utilizados para montagem de organelas a partir de dados de NGS. Sua estratégia de *baiting and iterative mapping* (captura e mapeamento iterativo) consiste em iniciar o processo com uma sequência guia (um fragmento do genoma alvo ou de uma espécie próxima) e, a partir dela, recuperar leituras homólogas (isto é, leituras suficientemente similares à sequência guia para corresponderem ao genoma mitocondrial), refinando o alinhamento de forma iterativa até a montagem completa do mitogenoma.

Em testes com dados reais de NGS, o MITObim demonstrou capacidade de recuperar mitogenomas completos com acurácia superior a 99,5% em menos de 24 horas utilizando um computador desktop padrão (HAHN; BACHMANN; CHEVREUX, 2013). Apesar desses resultados e de sua relevância histórica como pioneiro na abordagem, o

MITObim apresenta limitações em termos de eficiência computacional e escalabilidade, especialmente quando aplicado a conjuntos de dados maiores ou de maior complexidade, passando a coexistir com ferramentas mais recentes, como o NOVOPlasty e o GetOrganelle.

3.6 ANÁLISE COMPARATIVA

A Tabela 1 sintetiza as características das ferramentas e pipelines analisados, confrontando-as com a proposta deste trabalho. A comparação considera critérios relevantes para a reprodutibilidade, portabilidade e completude do fluxo analítico.

Tabela 1 – Comparação entre ferramentas de montagem de organelas e o pipeline proposto.

Critério	MitoHiFi	GetOrganelle	NOVOPlasty	MToolBox	MITObim	Este trabalho
Tipo de dado	<i>Long reads</i> (HiFi)	<i>Short/Long reads</i>	<i>Short reads</i>	<i>Short reads</i>	<i>Short reads</i>	<i>Short reads</i>
Montagem	✓	✓	✓	✓	✓	✓
Anotação funcional	✓	—	—	✓ (humano)	—	✓ (metazoários)
Visualização (mapa circular)	—	—	—	—	—	✓ (Biopython)
GenBank Flat File	✓	—	—	—	—	✓
Containerização	Parcial/variável	Conda	—	—	—	Docker (5 imagens)
Workflow manager	—	—	—	—	—	Nextflow DSL2
Pilot QC automático	—	—	—	—	—	✓
Estrutura secundária RNA	—	—	—	—	—	✓ (ViennaRNA)
Execução em laptop	HPC/servidor conforme dados	Desktop/servidor	Desktop	Desktop/servidor	Desktop/servidor	✓ (notebook 16 GB)
Código aberto	✓	✓	✓	✓	✓	✓

A análise comparativa evidencia que, embora cada ferramenta contribua com inovações relevantes para domínios específicos, nenhuma das soluções analisadas reúne, no mesmo fluxo, aquisição seletiva de dados públicos, redução prévia do volume, montagem, anotação funcional, geração de entregáveis em formato GenBank e orquestração por Docker/Nextflow. Adicionalmente, mecanismos como o Pilot QC e a extração seletiva via

`fastq-dump -X` não aparecem como componentes centrais nas ferramentas comparadas, o que pode manter a execução dependente de maior capacidade de armazenamento e memória em datasets volumosos. A proposta deste trabalho preenche essas lacunas ao combinar montagem, anotação funcional, geração de entregáveis, práticas de reprodutibilidade e acessibilidade computacional em um único pipeline modular, executável em computadores pessoais.

A análise dos trabalhos relacionados permitiu identificar diferentes abordagens para a montagem de organelas, incluindo pipelines baseados em leituras longas, estratégias iterativas e montadores especializados como o NOVOPlasty. Embora cada solução apresente contribuições relevantes, permanecem lacunas quanto à padronização, portabilidade, completude do fluxo analítico e reprodutibilidade. Nesse contexto, o Capítulo 4 descreve a metodologia adotada neste trabalho, detalhando a concepção do pipeline proposto e as ferramentas que o compõem.

4 METODOLOGIA

Nesta seção, é apresentado o plano metodológico para o desenvolvimento do pipeline de montagem de mitogenomas. A concepção deste pipeline teve como ponto de partida o fluxo de análise mitogenômica utilizado na disciplina Tópicos Especiais em Bioinformática A, ministrada pelo Prof. Jorge Estefano de Santana Souza na Universidade Federal do Rio Grande do Norte (UFRN). Naquela disciplina, as etapas de download, controle de qualidade, montagem e anotação eram executadas manualmente, sem padronização de versões ou ambiente computacional. O presente trabalho parte dessa experiência para projetar uma solução automatizada e reprodutível, formalizando cada etapa em módulos containerizados e orquestrados. A abordagem combina etapas de análise bioinformática com práticas consolidadas de engenharia de software, seguindo um processo de desenvolvimento sistemático descrito na seção 4.1, antes de detalhar a arquitetura do pipeline e suas etapas constituintes.

4.1 PROCESSO DE DESENVOLVIMENTO DE SOFTWARE

O desenvolvimento do pipeline seguiu uma abordagem de **desenvolvimento iterativo e incremental**, metodologia consolidada na engenharia de software em que o sistema é construído em ciclos sucessivos, cada um produzindo uma versão funcional e testável do produto (LARMAN; BASILI, 2003). Essa abordagem se contrapõe ao modelo cascata (*waterfall*), no qual todas as fases — levantamento de requisitos, projeto, implementação e teste — são executadas sequencialmente e o produto só é validado ao final. No contexto de software científico, em que os requisitos frequentemente evoluem à medida que os resultados são analisados, o modelo iterativo é amplamente recomendado (WILSON et al., 2014).

O ciclo de desenvolvimento foi organizado em três etapas: duas fases iterativas de desenvolvimento funcional e uma execução de validação cruzada:

- a) **Fase 1 — Montagem:** implementação dos módulos de download (SRA-Toolkit), controle de qualidade (FastQC, Trim Galore) e montagem (NOVOPlasty), com containerização em Docker e orquestração via Nextflow. Ao final desta fase, o pipeline já era capaz de produzir mitogenomas completos e circularizados a partir de um acesso SRA;
- b) **Fase 2 — Anotação e entregáveis:** adição dos módulos de análise piloto de qualidade (Pilot QC), anotação funcional (MITOS2), geração de estruturas secundárias de RNA (ViennaRNA/RNAPlot), produção de arquivos para submissão ao Gen-

Bank (GenBank Flat File) e compilação automática de entregáveis. A espécie-alvo desta fase foi *Anodorhynchus leari*, cujo mitogenoma era inédito;

- c) **Fase 3 — Validação Cruzada:** execução do pipeline para *Anodorhynchus hyacinthinus* (SRR36400750, dataset metagenômico de 145,8M spots), utilizando como semente o gene *cox1* extraído da montagem de *A. leari* produzida na Fase 2 — configuração recíproca: se na Fase 2 a semente de *A. leari* provinha do mitogenoma de *A. hyacinthinus*, na Fase 3 o caminho se inverte. A existência de um mitogenoma de referência independente para *A. hyacinthinus* no GenBank (OR209186.1, 16.999 bp) possibilitou validação quantitativa nucleotídeo a nucleotídeo, servindo como critério objetivo de aceitação do pipeline como ferramenta generalizável.

Cada fase produziu um pipeline funcional e independente. A Fase 1 foi preservada como branch separada no repositório Git (**fase1-montagem**), permitindo uso e validação independente por terceiros — uma prática de controle de versão que favorece a rastreabilidade e facilita a manutenção (SOMMERVILLE, 2016). A Figura 7 sintetiza essa organização em fases.

Conforme representado na Figura 7, as Fases 1 e 2 constituem ciclos iterativos de desenvolvimento–teste–correção–validação, cada uma produzindo uma entrega funcional independente. A Fase 3, por sua vez, representa uma execução de validação cruzada em que a saída da Fase 2 (*cox1* de *A. leari*) é empregada como semente para um organismo congênere com referência conhecida, verificando a generalidade do pipeline em condições objetivamente mensuráveis. A separação permite que a Fase 1 seja utilizada independentemente por pesquisadores interessados apenas na montagem, enquanto a Fase 2 adiciona as funcionalidades de anotação e geração de entregáveis sobre a base já validada.


4.1.1 Validação por Espécie-Controle

Um elemento central da estratégia de verificação e validação (V&V) foi o emprego de uma **espécie-controle** com mitogenoma previamente depositado em banco de dados público. Antes de aplicar o pipeline à espécie-alvo (*A. leari*), cuja sequência mitocondrial era inédita, o sistema foi integralmente validado com *Diploprion bifasciatus*, cujo mitogenoma de referência (PZ143763.1) está depositado no GenBank. Essa estratégia permitiu comparar a montagem obtida pelo pipeline com a sequência de referência conhecida, verificando a correção funcional do sistema em condições controladas antes de aplicá-lo a dados sem referência prévia.

No desenvolvimento de software científico, a validação com dados de referência conhecida é considerada uma das práticas mais importantes para garantir a confiabilidade dos resultados computacionais (WILSON et al., 2014). Essa abordagem é análoga ao

Figura 7 – Organização do desenvolvimento em três etapas: Fase 1 (Montagem, *D. bifasciatus*), Fase 2 (Anotação, *A. leari*) e Fase 3 (Validação Cruzada, *A. hyacinthinus*), com indicação das espécies, ciclos iterativos de desenvolvimento e relação recíproca de sementes entre fases.

Fases do desenvolvimento e validação do pipeline



Fonte: Elaborado pelo autor (2026).

conceito de *oracle testing* na engenharia de software, em que uma fonte externa de verdade é utilizada para validar as saídas do sistema sob teste (SOMMERVILLE, 2016).

4.1.2 Validação Cruzada por Congêneres

Além da validação com espécie-controle, o pipeline foi submetido a uma etapa de **validação cruzada** com uma terceira espécie: *Anodorhynchus hyacinthinus* (arara-azul-grande), congênere da espécie-alvo. A estratégia explorou a relação recíproca de sementes entre as duas espécies do gênero *Anodorhynchus* disponíveis no estudo: se na Fase 2 a se-

mente de *A. leari* provinha do mitogenoma publicado de *A. hyacinthinus* (NC_082165.1), na Fase 3 a semente de *A. hyacinthinus* foi extraída da montagem de *A. leari* produzida na etapa anterior. Essa inversão testa simultaneamente: (i) a capacidade do pipeline de operar com sementes de espécies congêneres em ambas as direções; (ii) a qualidade da montagem de *A. leari* como fonte de semente; e (iii) a robustez do pipeline frente a dados metagenômicos de grande volume (145,8M spots, SRR36400750).

A escolha de *A. hyacinthinus* não foi arbitrária: o mitogenoma desta espécie está depositado no GenBank (OR209186.1, 16.999 bp), possibilitando comparação quantitativa nucleotídeo a nucleotídeo entre a montagem produzida pelo pipeline e uma sequência obtida por metodologia e amostras inteiramente independentes. Esse critério — identidade acima de 99% com referência externa independente — foi adotado como critério de aceitação final do sistema, análogo ao conceito de *acceptance test* na engenharia de software (SOMMERVILLE, 2016). Os resultados desta validação são detalhados na Seção 5.9.

4.1.3 Tratamento de Erros e Correções Iterativas

O modelo iterativo também se manifestou na resolução de problemas técnicos encontrados durante a execução do pipeline. Exemplos concretos incluem:

- a) **Incompatibilidade do SRA-Toolkit:** a descoberta de que o `fasterq-dump` do SRA-Toolkit 3.x não implementa o flag `-X` para limitação de leituras na origem. Inicialmente, a solução adotada foi a truncagem pós-conversão via `head`, mas a execução com o dataset metagenômico de *A. hyacinthinus* (145,8M spots, ~124 GB de FASTQ) revelou que essa abordagem é inviável para grandes volumes. A correção definitiva substituiu o `fasterq-dump` pelo `fastq-dump -X` quando `sra_max_reads` está definido, extraindo diretamente apenas os primeiros N spots sem gravar o dataset completo (Seção 5.9.3);
- b) **Flag do RNAPlot:** a incompatibilidade do flag `--output-format=svg` na versão empacotada do ViennaRNA, corrigida para a sintaxe `-f svg` aceita pela versão instalada;
- c) **Frameshift do gene ND3:** a detecção, durante a análise dos resultados do MITOS2, de que o gene ND3 apresenta um *frameshift* biologicamente real e documentado em aves, tartarugas e crocodilianos (MINDELL; SORENSON; DIMCHEFF, 1998), levando à implementação de uma lógica de unificação (`join`) nos scripts de conversão para GenBank.

Cada correção foi implementada, testada e integrada antes do avanço para a próxima etapa, em conformidade com o princípio de retroalimentação rápida (*fail fast, fix immediately*) característico de metodologias ágeis (SOMMERVILLE, 2016).

4.1.4 Aderência às Boas Práticas de Computação Científica

A adoção das práticas descritas acima situa este trabalho no contexto das boas práticas para computação científica sistematizadas por Wilson et al. (2014), que recomendam:

- a) **Controle de versão** para todo código-fonte — implementado via Git com histórico completo de commits descritivos e branches para marcos significativos;
- b) **Automação de tarefas repetitivas** — implementada via Nextflow, que orquestra todas as etapas sem intervenção manual;
- c) **Testes com dados conhecidos** — implementados pela validação com espécie-controle (*D. bifasciatus*) e pela validação cruzada com *A. hyacinthinus* (OR209186.1), cobrindo dois níveis hierárquicos de verificação;
- d) **Registro de dependências e ambientes** — implementado via Dockerfiles com versões explicitamente fixadas para todas as ferramentas;
- e) **Documentação do propósito e das decisões de design** — implementada no repositório (README, guia de execução) e neste documento.

Essa abordagem metodológica não é apenas uma decisão de conveniência, mas uma necessidade reconhecida na literatura: estudos demonstram que a falta de práticas formais de engenharia de software em projetos científicos é uma das principais causas de irreprodutibilidade computacional (BAKER, 2016; PENG, 2011).

4.2 VISÃO GERAL DO PIPELINE

O pipeline proposto neste trabalho foi concebido para realizar a montagem e anotação de genomas mitocondriais a partir de dados de sequenciamento de nova geração (NGS), integrando ferramentas bioinformáticas consolidadas em um ambiente de execução automatizado, reprodutível e portátil. A arquitetura segue uma estrutura modular, em que cada etapa corresponde a uma fase distinta do processamento dos dados, sendo encapsulada em containers Docker para garantir consistência na execução (MERKEL, 2014) e integrada por meio do gerenciador de *workflows* Nextflow (Di Tommaso et al., 2017).

De forma geral, o pipeline é composto por sete macroetapas principais, organizadas em uma cadeia de redução progressiva de dados que transforma dezenas de gigabytes de leituras brutas em um mitogenoma anotado de ~17 kb (~17 KB no arquivo FASTA) — podendo viabilizar, nos cenários avaliados, a execução em computadores pessoais sem necessidade de servidores. A primeira é a **análise piloto de qualidade (Pilot QC)**,

um estágio opcional que analisa automaticamente uma subamostra dos dados para determinar o volume ideal de leituras a serem processadas, evitando downloads desnecessários em datasets grandes. A segunda etapa é a **aquisição e preparo dos dados**, responsável por obter datasets públicos em repositórios como o Sequence Read Archive (SRA) do NCBI (LEINONEN; SUGAWARA; SHUMWAY, 2011) via SRA-Toolkit. A terceira e quarta etapas constituem o **controle de qualidade e pré-processamento**, que envolve a avaliação das leituras por meio do FastQC (ANDREWS, 2010) e a remoção de adaptadores e bases de baixa qualidade utilizando o Trim Galore (Babraham Bioinformatics, 2019), que por sua vez utiliza o Cutadapt (MARTIN, 2011) internamente.

A quinta etapa corresponde à **montagem do mitogenoma**, realizada com o NOVOPlasty, ferramenta especializada que utiliza a estratégia *seed-and-extend* para reconstruir a molécula circular completa a partir de leituras curtas (DIERCKXSENS; MARDULYN; SMITS, 2017). A sexta etapa, de **anotação funcional**, identifica os genes do genoma montado, utilizando o MITOS2 (DONATH et al., 2019) para a predição de genes codificadores de proteínas, rRNAs e tRNAs, com geração de estruturas secundárias previstas via ViennaRNA (LORENZ et al., 2011). A sétima e final etapa consiste na **compilação dos entregáveis**, em que um script automatizado reúne todos os produtos da análise em uma pasta organizada, incluindo arquivos no formato GenBank Flat File para submissão ao NCBI. Cada uma dessas etapas é implementada como um módulo independente, containerizado com Docker (MERKEL, 2014) e orquestrado via Nextflow (Di Tommaso et al., 2017) para garantir reprodutibilidade e portabilidade.


A visão geral do pipeline, representada em formato de fluxograma na Figura 8, ilustra o encadeamento das etapas e destacando a integração entre análise bioinformática e práticas de engenharia de software. Deve-se observar que a lógica condicional do pipeline permite que a etapa de anotação (MITOS2) seja executada apenas quando o banco de dados de referência estiver disponível, tornando a Fase 1 (montagem) independente da Fase 2 (anotação). Adicionalmente, o *workflow* aplica um **filtro de circularização**: apenas montagens cujo nome de arquivo inicia com `Circularized_assembly` são encaminhadas ao MITOS2 e à compilação de entregáveis. Quando o NOVOPlasty não obtém circularização (produzindo apenas contigs parciais), a anotação é automaticamente omitida, evitando análises sobre montagens incompletas que poderiam gerar resultados biologicamente incorretos. Essa decisão de design garante que os entregáveis finais representem exclusivamente genomas mitocondriais completos e circulares.

4.2.1 Fluxo de Dados e Interfaces entre Containers

Embora o fluxograma anterior ilustre a sequência de processos, é fundamental compreender como os **dados transitam** entre os containers Docker, uma vez que cada etapa é encapsulada em um ambiente isolado. A orquestração desse fluxo é uma das

Figura 8 – Fluxograma do pipeline com as 7 etapas: Pilot QC, SRA Download, FastQC, Trim Galore, NOVOPlasty, MITOS2 e Compile Summary. Cores distinguem Fase 1 (montagem, azul) e Fase 2 (anotação, verde).

Fluxograma do pipeline mitogenômico



Fonte: Elaborado pelo autor (2026).

contribuições centrais deste trabalho, permitindo que ferramentas independentes operem de forma integrada e automatizada.

4.2.1.1 Interfaces de Dados: De Processo a Processo

Cada etapa do pipeline consome dados produzidos pela etapa anterior e gera dados para a próxima etapa. Diferentemente de pipelines monolíticos — em que todo o código reside em um único ambiente —, este pipeline segue um modelo de **componentes**

descentralizados, em que cada ferramenta (SRA-Toolkit, FastQC, Trim Galore, NOVOPlasty, MITOS2) executa dentro do seu próprio container Docker, com versões fixadas e dependências isoladas. A comunicação entre esses containers ocorre exclusivamente por meio de **volumes compartilhados no sistema de arquivos**, orquestrados pelo Nextflow.

A sequência de troca de dados é a seguinte:

- a) **Pilot QC** → produz o relatório `pilot_report.txt` e comunica os valores `recommended_reads` e `read_length` ao **SRA_DOWNLOAD** por meio de **variáveis de ambiente Nextflow** (`env RECOMMENDED_READS`, `env READ_LENGTH`), sem geração de arquivo JSON intermediário;
- b) **SRA_DOWNLOAD** → produz dois arquivos FASTQ não comprimidos (`<acesso>_1.fastq` e `<acesso>_2.fastq`) que são simultaneamente consumidos por **FastQC** e **Trim Galore**;
- c) **FastQC** → gera relatórios HTML e arquivos ZIP (`*_fastqc.html`, `*_fastqc.zip`) utilizados apenas para verificação do usuário, sem impacto direto no fluxo (não são consumidos por etapas posteriores);
- d) **Trim Galore** → produz FASTQs trimados não comprimidos (`*_val_1.fq`, `*_val_2.fq`) que são consumidos exclusivamente por **NOVOPlasty**;
- e) **NOVOPlasty** → gera um arquivo FASTA de montagem (`Circularized_assembly.fasta` ou `Contigs_1.fasta`) que, caso circularizado, é consumido por **MITOS2**;
- f) **MITOS2** → produz anotações em formato GFF3 (`result.gff`), sequências dos genes (`result.fas`, `result.faa`) e estruturas secundárias de RNA em SVG (`structure_svgs/*.svg`) que são consumidas por **Compile Summary**;
- g) **Compile Summary** → reúne todos os produtos intermediários e gera os 14 entregáveis finais, incluindo GenBank Flat File (`*.gbk`), mapas circulares (SVG/PDF) e relatório compilado.

Essa arquitetura garante que não haja **acoplamento desnecessário**: cada etapa apenas conhece a localização dos arquivos de entrada e o formato esperado dos dados de saída, permitindo que modificações internas de uma ferramenta não quebrem as demais. Por exemplo, se uma versão futura do MITOS2 alterasse seu formato de saída, seria necessário apenas atualizar o script de leitura em Compile Summary, sem tocar nos módulos anteriores.

4.2.1.2 Estrutura de Diretórios e Armazenamento Intermediário

O pipeline organiza os arquivos em uma hierarquia bem definida, viabilizando rastreabilidade e reutilização via `-resume`:

```
<projeto>/
+-- work/
|   |-- <especie>/
|       |-- <timestamp>/          <- workDir dinamico (nextflow.config)
|           +-- a2/d13fb0.../      <- diretorio da task SRA_PILOT (hash)
|               | +-- pilot_report.txt
|               | +-- recommended_reads.txt
|               | |-- read_length.txt
|           +-- f4/e3e648.../      <- task SRA_DOWNLOAD
|               | +-- <acesso>_1.fastq
|               | |-- <acesso>_2.fastq
|           +-- 92/de1581.../      <- task FASTQC
|               | +-- *_fastqc.html
|               | |-- *_fastqc.zip
|           +-- 45/65476c.../      <- task TRIM_GALORE
|               | +-- *_val_1.fq
|               | |-- *_val_2.fq
|           +-- 22/390d92.../      <- task NOVOPLASTY
|               | |-- Circularized_assembly_1_<acesso>.fasta
|           +-- c2/98f02b.../      <- task MITOS2
|               | |-- <acesso>/
|               |         +-- result.gff
|               |         +-- result.fas
|               |         +-- result.faa
|               |         |-- structure_svgs/
|           |-- 4b/4b1cc7.../      <- task COMPILE_SUMMARY
|
+-- results/
|   |-- <especie>/
|       +-- qc/
|           | +-- pilot/
|           | | |-- pilot_report.txt
|           | +-- fastqc_raw/
|           | | +-- *_fastqc.html
|           | | |-- *_fastqc.zip
|           | |-- trim_galore/
|           | |-- *_trimming_report.txt
|       +-- assembly/
```

```

|         |   +-- Circularized_assembly_1_<acesso>.fasta
|         |   +-- log_<acesso>.txt
|         |   \-- config.txt
|       +-- annotation/
|         |   \-- mitos2/
|         |         \-- <acesso>/
|         |               +-- result.gff
|         |               +-- result.fas
|         |               +-- result.faa
|         |               \-- structure_svgs/
|       \-- summary/
|         \-- deliverables/
|               +-- 01_genome_assembly.fasta
|               +-- 02_coding_genes_nt.fasta
|               +-- ...
|               +-- 10_annotation.gff
|               \-- genbank_submission/
|                     +-- <especie>.gbk
|                     +-- <especie>.tbl
|                     \-- <especie>.fsa
|
+-- .nextflow/
\-- logs/
    \-- <especie>_<timestamp>.log

```

O diretório `work/` é gerenciado exclusivamente pelo Nextflow e contém dados intermediários que **não devem ser editados manualmente**. Sua preservação permite retomar execuções interrompidas via `-resume`. O diretório `results/` contém os entregáveis finais, adequados para apresentação, publicação e submissão a bancos de dados como GenBank.

Um aspecto crítico para **reprodutibilidade e rastreabilidade** é o arquivo `.nextflow/trace`, gerado automaticamente pelo Nextflow, que registra:

- a) timestamp de execução de cada etapa;
- b) tempo decorrido (*wall-clock time* e *CPU time*);
- c) consumo de memória RAM;
- d) volume de I/O (leitura/escrita em disco);
- e) hash do container Docker utilizado;
- f) status de sucesso ou falha.

Esse arquivo é essencial para auditorias computacionais e para reproduzir exatamente as mesmas condições em execuções futuras.

4.2.1.3 Dicionário de Dados: Tipos, Estruturas e Semântica

A tabela a seguir descreve os dados-chave produzidos por cada etapa, seus tipos, volumes aproximados e consumidores:

Tabela 2 – Dicionário de dados do pipeline: arquivos intermediários, tipos, volumes e consumidores.

Arquivo	Tipo	Volume	Produzido por	Consumido por
<code>pilot_report.txt</code>	Texto	<10 KB	Pilot QC	Verificação manual; <code>recommended_reads</code> e <code>read_length</code> via canais Nextflow (<code>env</code>)
<code><acesso>_1.fastq</code> , <code><acesso>_2.fastq</code>	FASTQ	~7–15 GB	SRA Download	FastQC, Trim Galore
<code>*_fastqc.html</code> , <code>*_fastqc.zip</code>	HTML/ZIP	~5–10 MB	FastQC	Verificação manual (usuário)
<code>*_val_1.fq</code> , <code>*_val_2.fq</code>	FASTQ	~3–7 GB	Trim Galore	NOVOPlasty
<code>Circularized_ assembly_1_ <acesso>.fasta</code>	FASTA	~17 KB	NOVOPlasty	MITOS2, Compile Summary
<code>result.gff</code>	GFF3	~50–100 KB	MITOS2	Compile Summary, scripts de conversão
<code>result.fas</code> , <code>result.faa</code>	FASTA	~50–200 KB	MITOS2	Compile Summary
<code>structure_svgs/*.svg</code>	SVG/XML	~1–5 MB	MITOS2/RNAplot	Compile Summary
<code><especie>.gbk</code>	GenBank Flat File	~50–100 KB	Compile Summary	Submissão NCBI
<code>*.pdf</code> , <code>*.svg</code> (mapas)	PDF/SVG	~500 KB– 2 MB	Compile Summary (Biopython)	Publicação, apresentação

Todos os dados intermediários são **formatos padrão da bioinformática**: FASTQ para sequências brutas e trimadas, GFF3 para anotações, FASTA para sequências montadas e anotadas. Essa padronização facilita a integração com ferramentas externas e a análise manual quando necessária.

4.2.1.4 Mecanismo de Orquestração: Nextflow como Maestro

O Nextflow funciona como o orquestrador central, responsável por:

- a) **Inicialização de containers:** para cada etapa, o Nextflow inicia um container com a imagem Docker apropriada, montando volumes para acesso aos dados;
- b) **Passagem de dados:** dados de saída de um container são disponibilizados como entrada para o próximo, através de **channels** (canais) do Nextflow;
- c) **Controle de dependências:** o Nextflow verifica que etapa A foi concluída antes de iniciar etapa B;
- d) **Tratamento de paralelismo:** etapas que podem rodar em paralelo (e.g., FastQC e Trim Galore) são executadas simultaneamente, melhorando eficiência;
- e) **Recuperação de falhas:** se uma etapa falhar, o Nextflow reporta claramente o erro e permite retomar via **-resume**;
- f) **Rastreamento de proveniência:** todos os passos, suas entradas, saídas e parâmetros são registrados no arquivo **.nextflow/trace**.

No código Nextflow (**main.nf**), a passagem de dados é explícita:

```
// Fluxo de dados em main.nf (simplificado)
workflow {
    accession_ch = Channel.value(params.sra_accession)
    seed_file    = file(params.seed)

    // Pilot QC: envia max_reads e read_length via canais de ambiente
    SRA_PILOT(accession_ch, seed_file)
    max_reads_ch  = SRA_PILOT.out.recommended_reads
    read_length_ch = SRA_PILOT.out.read_length

    SRA_DOWNLOAD(accession_ch, max_reads_ch)
    FASTQC(SRA_DOWNLOAD.out.reads)           // paralelo com TRIM_GALORE
    TRIM_GALORE(SRA_DOWNLOAD.out.reads)

    NOVOPLASTY(TRIM_GALORE.out.reads, seed_file, read_length_ch)

    // Fase 2 ativada apenas quando params.mitos2_db estiver definido
    if (params.mitos2_db) {
        // Filtra montagens circularizadas antes de anotar
        circularized_ch = NOVOPLASTY.out.assembly
        .flatten()
    }
}
```

```

        .filter { f -> f.name.startsWith('Circularized_assembly') }
        .map      { f -> tuple(f.baseName.replaceAll(...), f) }

MITOS2(circularized_ch, file(params.mitos2_db))
COMPILE_SUMMARY(circularized_ch.join(MITOS2.out.annotation))
    }
}

```

Essa estrutura garante que **dados fluxam explicitamente** do início ao fim do pipeline, sem vazamento entre etapas não-consecutivas, e que cada etapa sabe exatamente qual dado espera receber e qual deve produzir.

4.2.1.5 Implicações para Reprodutibilidade e Publicação

A padronização desse fluxo de dados oferece benefícios diretos para a **reprodutibilidade científica**:

- a) **transparência**: qualquer pesquisador compreende exatamente qual dado flui para onde e em qual formato;
- b) **reutilização**: dados intermediários em formatos padrão (FASTQ, GFF3, FASTA) permitem análises complementares;
- c) **auditoria**: o arquivo de *trace* permite verificar versão exata de cada ferramenta e parâmetros utilizados;
- d) **comunicação em artigos**: figuras mostrando fluxo de dados facilitam comunicação com revisores, que compreenderão a arquitetura rapidamente.

Essa ênfase na estrutura de dados, aliada à containerização e orquestração, diferencia este pipeline de soluções anteriores que focavam apenas no sequenciamento de processos, não na comunicação explícita de dados entre eles.

4.3 FLUXO DE EXECUÇÃO DO PIPELINE

Esta seção descreve o fluxo completo de execução do pipeline, desde os pré-requisitos até a obtenção dos resultados finais, detalhando as decisões automáticas tomadas pelo sistema e o caminho percorrido pelos dados em cada etapa.

4.3.1 Pré-requisitos e Preparação do Ambiente

Antes da primeira execução, três preparações são necessárias:

- a) **Construção das imagens Docker** — o repositório inclui cinco Dockerfiles (SRA-Toolkit, FastQC, Trim Galore, NOVOPlasty e MITOS2), cada um com versões fixadas de todas as dependências. A construção é realizada por um script automatizado (`build_images.ps1` / equivalente Bash), que gera as imagens localmente sem necessidade de registro externo;
- b) **Download do banco de dados MITOS2** — o banco RefSeq89m (~20 MB compactado) é obtido do Zenodo e extraído em `data/databases/`. Esse passo é necessário apenas uma vez, pois o banco é reutilizado entre execuções;
- c) **Configuração do perfil da espécie** — cada espécie requer um arquivo de configuração em `conf/` definindo o acesso SRA (`sra_accession`), a semente (`seed`), o intervalo de tamanho esperado (`genome_range`), os k-mers a serem tentados (`novoplasty_kmers`), o código genético (`genetic_code`) e o nome científico (`organism`).

4.3.2 Comando de Execução e Resiliência

A execução é iniciada por um único comando:

```
nextflow run main.nf -profile <especie>
```

Onde `<especie>` corresponde ao nome do perfil definido em `nextflow.config` (e.g., `a_leari`, `test`). Para execuções de longa duração — típicas em bioinformática, onde o download de dados do SRA pode levar dezenas de minutos e a conversão dos FASTQs pode exceder uma hora —, o pipeline inclui um script wrapper (`run_pipeline.sh`) que encapsula a execução com `nohup`, permitindo que o terminal seja fechado ou a conexão SSH seja interrompida sem afetar o pipeline. Os logs são automaticamente direcionados para `logs/<perfil>_<timestamp>.log`, possibilitando acompanhamento assíncrono via `tail -f`.


Para retomar uma execução interrompida, o Nextflow oferece o mecanismo `-resume`, que reutiliza os resultados de etapas já concluídas armazenados no diretório `work/`. O pipeline organiza esse diretório por espécie e timestamp (`work/<especie>/<timestamp>/`), permitindo identificar e gerenciar execuções individuais. Para retomar uma execução específica, basta indicar o diretório correspondente:

```
nextflow run main.nf -profile <especie> -resume -w work/<especie>/<timestamp>
```

4.3.3 Fluxo de Dados e Decisões Automáticas

A Figura 9 apresenta o percurso completo dos dados através do pipeline, indicando os formatos e volumes em cada transição.

Figura 9 – Fluxo sequencial de dados no pipeline, mostrando os formatos e volumes em cada transição, desde o arquivo `.sra` (11 GB) até os 14 entregáveis finais (1,6 MB). Destacam-se a redução de 87 GB para 17 KB e os dois pontos de decisão automática.



Fonte: Elaborado pelo autor (2026).

Como evidenciado na Figura 9, o pipeline implementa uma estratégia de redução progressiva: o dado original de 87 GB (FASTQ bruto) é reduzido em mais de cinco milhões de vezes até a montagem final de 17 KB. Essa redução não é uniforme — o maior salto ocorre na etapa de montagem, quando o NOVOPlasty seleciona apenas leituras mitocondriais dentre milhões de leituras genômicas. Os dois pontos de decisão automática assinalados no diagrama (Pilot QC e Filtro de Circularização) são detalhados a seguir.

O pipeline incorpora dois pontos de decisão automática que não requerem intervenção do usuário:

Decisão 1 — Pilot QC (volume de dados). Quando o parâmetro `sra_max_reads` não é definido no perfil da espécie, o pipeline ativa automaticamente o módulo Pilot QC (seção 4.7), que baixa uma subamostra de 500.000 leituras, analisa sua qualidade e calcula o número ideal de leituras para a execução principal. Quando o parâmetro é explicitamente definido (e.g., via `--sra_max_reads 20000000`), o Pilot QC é pulado e o valor fornecido é utilizado diretamente. Essa lógica condicional é implementada no *workflow* principal (`main.nf`) por meio de operadores Nextflow de branching.

Decisão 2 — Filtro de Circularização (qualidade da montagem). Após a montagem pelo NOVOPlasty, apenas arquivos cujo nome corresponde ao padrão `Circularized_assembly_*` são encaminhados ao MITOS2. Montagens parciais (contigs não circularizados) são automaticamente descartados do fluxo de anotação, evitando que genomas incompletos recebam anotações potencialmente incorretas (e.g., genes truncados nas extremidades de contigs lineares). O pipeline reporta essas montagens parciais no log para que o pesquisador possa investigar manualmente a causa da não-circularização (cobertura insuficiente, semente inadequada, ou regiões repetitivas complexas). A Figura 10 formaliza esses dois pontos de decisão em um diagrama de atividades.

O diagrama da Figura 10 explicita que ambas as decisões são binárias e automáticas, dispensando intervenção do usuário. Na Decisão 1, o Pilot QC avalia a qualidade das leituras e estima a fração mitocondrial para determinar o volume ideal; na Decisão 2, o filtro de circularização verifica o nome do arquivo produzido pelo NOVOPlasty — apenas montagens com prefixo `Circularized_assembly` prosseguem para anotação, garantindo que entregáveis incompletos não sejam gerados.


4.3.4 Extensibilidade para Novas Espécies

A adição de uma nova espécie ao pipeline requer apenas a criação de um arquivo de configuração e a obtenção da semente correspondente, sem modificação de código-fonte. Os passos são:

- a) Identificar no NCBI SRA um dataset de sequenciamento de genoma total para a espécie-alvo;
- b) Localizar o mitogenoma de uma espécie **congênere** — isto é, pertencente ao mesmo gênero taxonômico — (ou filogeneticamente próxima) no NCBI e extrair o gene `cox1` como semente;
- c) Criar um arquivo `conf/<especie>.config` definindo os parâmetros específicos (acesso SRA, semente, `genome_range`, `k-mers`, código genético e nome);
- d) Registrar o novo perfil em `nextflow.config`;
- e) Executar: `nextflow run main.nf -profile <especie>`.

O pipeline é, por design, agnóstico ao táxon dentro de **Metazoa**, podendo ser aplicado a qualquer animal cujo mitogenoma seja recuperável a partir de leituras curtas Illumina, desde que haja uma sequência-semente `cox1` de espécie congênere ou filogeneticamente próxima disponível. A título de exemplo, o repositório (`data/seeds/`) inclui sementes pré-configuradas para aves, peixes, insetos e nematódeos — quatro grupos representativos que ilustram essa generalidade taxonômica, mas não esgotam as possibilidades:

Figura 10 – Diagrama de atividade mostrando os dois pontos de decisão automática do pipeline: (1) Pilot QC — determina o volume de dados; (2) Filtro de Circularização — condiciona a anotação à obtenção de genoma circularizado.



Fonte: Elaborado pelo autor (2026).

o mesmo procedimento aplica-se a mamíferos, répteis, anfíbios, moluscos, crustáceos e demais clados de Metazoa.

4.4 ARQUITETURA MODULAR E SCRIPTS DO PIPELINE

A organização do código segue a convenção de projetos Nextflow DSL2, em que cada etapa do pipeline corresponde a um **módulo** independente (arquivo `.nf` no diretório `modules/`), e os scripts auxiliares residem no diretório `scripts/`. Essa separação permite que cada componente seja desenvolvido, testado e mantido de forma isolada. A Tabela 3 apresenta a relação completa dos módulos, scripts e suas responsabilidades.

Tabela 3 – Arquitetura modular do pipeline: módulos, scripts e suas responsabilidades.

Arquivo	Tipo	Função
<code>main.nf</code>	Workflow	Orquestração geral: define a ordem de execução, lógica condicional (Pilot QC, MITOS2) e passagem de dados entre módulos
<code>modules/ sra_download.nf</code>	Módulo	Download do SRA via <code>prefetch</code> + conversão condicional (<code>fastq-dump -X</code> ou <code>fasterq-dump</code>)
<code>modules/fastqc.nf</code>	Módulo	Controle de qualidade das leituras brutas via FastQC
<code>modules/ trim_galore.nf</code>	Módulo	Remoção de adaptadores e trimming de qualidade via Trim Galore
<code>modules/ novoplasty.nf</code>	Módulo	Montagem iterativa com múltiplos k-mers e re-seeding automático
<code>modules/mitos2.nf</code>	Módulo	Anotação funcional via MITOS2 + geração de SVGs com RNAplot
<code>scripts/pilot_qc.sh</code>	Script Bash	Análise piloto: calcula Q30%, taxa de adaptador, fração mitocondrial e recomenda <code>max_reads</code>
<code>scripts/ compile_summary.py</code>	Script Python	Compila 14 categorias de entregáveis a partir das saídas dos módulos
<code>scripts/ gff2genbank.py</code>	Script Python	Converte GFF3 → feature table (<code>.tbl</code>) + FASTA formatado (<code>.fsa</code>) para GenBank, com tratamento do frameshift ND3
<code>scripts/ generate_genbank.py</code>	Script Python	Gera GenBank Flat File (<code>.gbk</code>) e mapa circular (SVG/PDF) via Biopython

Tabela 3 – Arquitetura modular do pipeline (continuação).

Arquivo	Tipo	Função
<code>nextflow.config</code>	Config.	Parâmetros globais, perfis por espécie, configuração de containers Docker
<code>conf/*.config</code>	Config.	Perfis específicos por espécie (acesso SRA, semente, k-mers, banco MITOS2)

Essa arquitetura modular permite que novos módulos sejam adicionados (e.g., análise filogenética, BLAST) sem alterar os existentes — basta criar o arquivo `.nf`, o Dockerfile correspondente e registrar a chamada no `main.nf`.

4.5 FERRAMENTAS E TECNOLOGIAS UTILIZADAS

A implementação de um pipeline bioinformático demanda não apenas a escolha de algoritmos adequados, mas também a definição criteriosa de ferramentas que sejam estáveis, bem documentadas e amplamente utilizadas pela comunidade científica. Nesse contexto, a seleção de softwares para este trabalho foi orientada por três princípios fundamentais: (i) funcionalidade biológica, garantindo que cada ferramenta seja apropriada para a etapa que executa, desde a aquisição dos dados até a anotação final do genoma; (ii) confiabilidade e validação prévia, privilegiando programas consolidados na literatura e em uso corrente em pesquisas genômicas; e (iii) compatibilidade com práticas modernas de engenharia de software, assegurando que cada aplicação possa ser encapsulada em containers e integrada a sistemas de gerenciamento de *workflows*.

Um aspecto central da engenharia deste pipeline é a **fixação de versões**. Todas as ferramentas foram encapsuladas em containers Docker com versões explicitamente fixadas, tanto para as imagens base quanto para os softwares instalados. Essa decisão, embora impeça o uso automático de atualizações, favorece que o pipeline produza resultados consistentes e reproduzíveis independentemente do momento ou do ambiente em que for executado, reduzindo uma das principais fontes de irreprodutibilidade em bioinformática. A Tabela 4 apresenta as versões de cada componente utilizado.

Tabela 4 – Versões fixadas dos componentes do pipeline.

Componente	Versão	Imagem base
SRA-Toolkit	3.0.10	ubuntu:22.04
FastQC	0.12.1	ubuntu:22.04
Trim Galore	0.6.10	ubuntu:22.04
Cutadapt	4.6	(dentro do Trim Galore)
NOVOPlasty	4.3.1	ubuntu:22.04
MITOS2	2.1.9	continuumio/miniconda3:24.1.2-0
ViennaRNA	(via conda)	(dentro do MITOS2)
Nextflow	DSL2 (25.x)	—

As cinco imagens Docker correspondentes às ferramentas listadas (SRA-Toolkit, FastQC, Trim Galore, NOVOPlasty e MITOS2) são publicadas no **GitHub Container Registry (GHCR)** — registro público de imagens de container integrado ao GitHub e gratuito para projetos abertos. Cada imagem é identificada por uma tag de versão explícita (1.0), no formato `ghcr.io/matheus-sobreira/mitogenome-pipeline/<ferramenta>:1.0`, e referenciada diretamente nas diretivas `container` do arquivo `nextflow.config`. Essa estratégia de distribuição complementa a fixação de versões internas: além de cada container conter softwares com versões fixadas (Tabela 4), a própria imagem é obtida de um endereço imutável publicado em um registro persistente, eliminando a possibilidade de *drift* silencioso entre execuções separadas no tempo ou entre máquinas distintas. Na primeira execução em um novo ambiente, o Nextflow puxa automaticamente as imagens do GHCR; nas execuções subsequentes, elas ficam armazenadas localmente no *cache* do Docker, dispensando rede.

Além de atender a esses critérios, as ferramentas escolhidas refletem o estado da arte em bioinformática aplicada ao estudo de organelas, cobrindo desde utilitários básicos, como o SRA-Toolkit para acesso a bancos de dados, até plataformas mais complexas, como o NOVOPlasty para montagem especializada de mitogenomas. Da mesma forma, tecnologias transversais como Docker e Nextflow foram incorporadas não pelo papel biológico que desempenham, mas pela sua relevância em assegurar portabilidade, escalabilidade e reprodutibilidade, elementos indispensáveis para a robustez metodológica do pipeline.

Assim, a seguir neste capítulo é descrito de forma integrada as principais ferramentas e tecnologias que compõem o pipeline de montagem de genomas mitocondriais.

4.5.1 SRA-Toolkit

O SRA-Toolkit é o pacote oficial de utilitários do NCBI para manipulação de dados depositados no Sequence Read Archive (SRA), o principal repositório público de dados de sequenciamento de alto rendimento (LEINONEN; SUGAWARA; SHUMWAY, 2011). No pipeline desenvolvido, dois utilitários do SRA-Toolkit são empregados em sequência: o

`prefetch`, que realiza o download eficiente do arquivo `.sra` compactado, e um dos conversores para formato FASTQ paired-end — `fasterq-dump` ou `fastq-dump` — selecionado automaticamente conforme as condições de execução.

Uma decisão de implementação relevante diz respeito à estratégia de redução de dados. Em datasets de grande volume — como o utilizado para *A. leari*, com 118,5 milhões de pares de leituras (SRR28399504) —, o processamento integral seria desnecessário e computacionalmente oneroso, dado que o genoma mitocondrial de aves tem cerca de 17 kb (BOORE, 1999) e apenas uma fração diminuta das leituras ($\sim 0,17\%$) corresponde ao mtDNA. O pipeline implementa duas estratégias condicionais de redução:

- a) **quando `sra_max_reads` está definido**: utiliza o `fastq-dump` com a flag `-X`, que extrai diretamente apenas os primeiros N spots do arquivo `.sra` sem necessidade de conversão integral. Embora o `fastq-dump` seja single-thread e mais lento que o `fasterq-dump`, a redução drástica do volume processado compensa amplamente — por exemplo, extrair 25M spots de um dataset de 145,8M processa apenas 17% dos dados, com uso de disco proporcional;
- b) **quando `sra_max_reads` não está definido**: utiliza o `fasterq-dump`, que é multi-threaded e substancialmente mais rápido que o `fastq-dump` em datasets grandes (NCBI — National Center for Biotechnology Information, 2023), convertendo o arquivo integralmente para FASTQ.

Essa abordagem condicional foi adotada após a execução com o dataset metagenômico de *A. hyacinthinus* (145,8M spots) revelar que a estratégia original — conversão integral pelo `fasterq-dump` seguida de truncamento por `head` — era inviável para grandes volumes, por gerar ~ 124 GB de arquivos FASTQ intermediários (Seção 5.9.3).

4.5.2 FastQC

O FastQC é uma das ferramentas mais utilizadas na etapa de controle de qualidade de dados de sequenciamento de nova geração (NGS). Desenvolvido pelo Babraham Institute, tornou-se referência para avaliação inicial de leituras em formato FASTQ, sendo amplamente empregado em pipelines de bioinformática devido à sua rapidez, robustez e facilidade de interpretação (ANDREWS, 2010).

Do ponto de vista técnico, o FastQC processa os arquivos de entrada em formato FASTQ e gera como saída relatórios em HTML interativo e arquivos compactados (`.zip`), contendo gráficos e estatísticas sobre diferentes aspectos das sequências. Entre os módulos mais relevantes estão:

- a) *per base sequence quality*, que avalia a distribuição da qualidade das bases em cada posição do read;

- b) *per sequence quality scores*, que identifica leituras com baixa qualidade geral;
- c) *per base GC content*, que compara a distribuição de GC observada com a esperada;
- d) *overrepresented sequences*, que detecta possíveis contaminantes ou adaptadores;
- e) *sequence duplication levels*, que informa o grau de redundância entre leituras;
- f) *adapter content*, que indica a presença de adaptadores de sequenciamento não removidos.

Entre as principais vantagens do FastQC estão: (i) a rapidez de execução mesmo em grandes conjuntos de dados, (ii) a geração de relatórios de fácil interpretação, e (iii) a capacidade de identificar múltiplos problemas em uma única execução. No entanto, o programa possui limitações: por ser uma análise pré-alinhamento, não oferece informações sobre a qualidade do mapeamento ou sobre a distribuição de leituras no genoma de referência. Além disso, os resultados devem ser interpretados com cautela, já que pequenas variações em métricas, como o conteúdo GC, podem refletir características biológicas legítimas e não necessariamente artefatos técnicos.

Cabe registrar que o FastQC convive com outras ferramentas para controle de qualidade de leituras de sequenciamento, cada uma com ênfases distintas. Entre as alternativas mais relevantes destacam-se: o **fastp**, que unifica em uma única execução a inspeção de qualidade, o *trimming* e a filtragem de leituras, com vantagens de desempenho em datasets muito grandes; o **MultiQC**, que agrega os relatórios de FastQC, Trim Galore e outras dezenas de ferramentas em um painel HTML único, particularmente útil para inspeção comparativa entre múltiplas amostras; e o **NanoPlot**, especializado em leituras longas geradas por plataformas PacBio e Oxford Nanopore.

A escolha pelo FastQC neste trabalho privilegia três fatores: (i) seu papel de *de facto standard* em pipelines de leituras curtas Illumina, presente em praticamente todos os fluxos publicados na última década; (ii) sua integração nativa com o Trim Galore — a ferramenta utilizada na etapa seguinte do pipeline, que consulta o output do FastQC para tomar decisões automáticas de *trimming*; e (iii) a familiaridade da comunidade científica com seus relatórios, que facilita a verificação dos resultados por revisores e leitores. Dessa forma, o FastQC atua como ponto de controle essencial para assegurar a confiabilidade das análises subsequentes.

4.5.3 Cutadapt e Trim Galore

Após a avaliação inicial da qualidade das leituras, pode ser necessário realizar etapas de filtragem para remover **adaptadores** residuais e **bases de baixa qualidade**. Para compreender essas operações, é necessário esclarecer dois conceitos fundamentais.

Adaptadores são sequências sintéticas curtas (tipicamente 30–60 nucleótidos) que são quimicamente ligadas às extremidades dos fragmentos de DNA durante a preparação da biblioteca de sequenciamento. Funcionam como “âncoradouros” que permitem ao sequenciador reconhecer e processar cada fragmento. Após o sequenciamento, essas sequências artificiais não fazem parte do genoma do organismo e precisam ser removidas antes da montagem, pois sua presença geraria sobreposições falsas entre leituras, comprometendo a reconstrução do genoma.

Bases de baixa qualidade referem-se a nucleótidos cuja identificação pelo sequenciador apresenta baixa confiança. A qualidade de cada base é expressa pela **pontuação Phred** (Q), uma escala logarítmica em que:

$$Q = -10\log_{10}(P) \quad (4.1)$$

sendo P a probabilidade de erro (EWING et al., 1998). Assim, $Q = 20$ indica 1% de probabilidade de erro (99% de acerto), enquanto $Q = 30$ indica 0,1% de erro (99,9% de acerto). Bases com $Q < 20$ são geralmente consideradas de baixa qualidade e removidas no processo de **trimming** (corte) — a operação de remoção sistemática de adaptadores e bases de baixa qualidade das extremidades das leituras.

Nesse contexto, duas ferramentas complementares são utilizadas no pipeline: Cutadapt e Trim Galore.

O Cutadapt é um programa desenvolvido por Martin (2011) especificamente para identificar e remover sequências de adaptadores em dados de alto rendimento. As leituras geradas por tecnologias como Illumina frequentemente contêm fragmentos de adaptadores ligados durante a preparação da biblioteca, que, se não forem removidos, podem comprometer a montagem ou o mapeamento subsequente. O Cutadapt utiliza algoritmos de busca eficiente para detectar esses fragmentos nas extremidades das leituras e removê-los, além de permitir o corte de bases de baixa qualidade de acordo com pontuações Phred. Como entrada, o programa recebe arquivos **FASTQ** — formato de texto que armazena tanto a sequência de cada leitura quanto a qualidade Phred de cada base individual, representada por caracteres ASCII —, e como saída gera novos FASTQ já filtrados, prontos para análises subsequentes.

O Trim Galore é um wrapper que automatiza a execução do Cutadapt em conjunto com o FastQC, simplificando o processo de trimming e tornando-o mais acessível ao usuário (Babraham Bioinformatics, 2019). Com ele, é possível remover adaptadores mesmo quando a sequência exata não é previamente conhecida, o que é particularmente útil em experimentos com bibliotecas de origem diversa. Além disso, o Trim Galore aplica rotinas de filtragem por qualidade e integra relatórios do FastQC para avaliar o impacto do corte.

Entre as principais vantagens do Cutadapt e do Trim Galore estão: (i) a remoção precisa de adaptadores, prevenindo erros de montagem, (ii) a flexibilidade de configuração de parâmetros, e (iii) a integração automatizada que reduz a intervenção manual. Suas

limitações incluem a necessidade de escolher cuidadosamente os limiares de qualidade, já que cortes excessivos podem resultar em perda de informação biológica relevante, enquanto cortes insuficientes podem deixar contaminantes residuais.

A escolha por essas ferramentas neste trabalho se justifica pelo seu amplo uso na comunidade científica e pela confiabilidade de seus resultados. A integração de Cutadapt e Trim Galore garante que as leituras que avançam para a montagem apresentem qualidade adequada, reduzindo o risco de artefatos e aumentando a robustez dos resultados obtidos pelo pipeline.

4.5.4 NOVOPlasty

O NOVOPlasty é um montador especializado desenvolvido para reconstrução de genomas de organelas, como mitocôndrias e cloroplastos, a partir de dados de sequenciamento de genoma total. Publicado por Dierckxsens, Mardulyn e Smits (2017), tornou-se uma das ferramentas mais amplamente utilizadas para esse fim devido à sua eficiência e facilidade de uso.

Do ponto de vista técnico, o NOVOPlasty baseia-se na estratégia *seed-and-extend*. O processo de montagem é iniciado a partir de uma sequência fornecida pelo usuário — denominada seed — que pode ser um fragmento do genoma da organela em estudo, uma sequência de uma espécie próxima ou até mesmo uma sequência completa de organela de outro organismo. A partir dessa seed, o software realiza uma extensão bidirecional, identificando leituras sobrepostas e construindo gradualmente a sequência circular completa do genoma. Para acelerar o processo, o programa utiliza tabelas de hash, que permitem buscas rápidas por sobreposições entre as leituras.

O NOVOPlasty recebe como entrada arquivos FASTQ contendo leituras pareadas, bem como um arquivo FASTA com a sequência seed. A saída consiste em um arquivo FASTA representando o genoma circularizado, acompanhado de arquivos de log e, em alguns casos, múltiplas opções de montagem (quando diferentes caminhos são possíveis no grafo de montagem).

Entre as principais vantagens do NOVOPlasty destacam-se: (i) sua alta eficiência na recuperação de genomas completos de organelas mesmo a partir de dados de genoma total, (ii) a baixa exigência de parâmetros complexos, o que o torna acessível a usuários com diferentes níveis de experiência, e (iii) a capacidade de lidar com diferentes tipos de sementes, permitindo flexibilidade em estudos de espécies com genomas pouco conhecidos. No entanto, como limitações, pode-se destacar: (i) a dependência da qualidade e da escolha adequada da seed, que influencia diretamente o sucesso da montagem, e (ii) o risco de circularizações incorretas em casos de regiões altamente repetitivas ou coberturas desbalanceadas.

No pipeline implementado, o módulo NOVOPlasty incorpora uma lógica iterativa

com re-seeding automático: caso a primeira execução não resulte em circularização, o maior contig obtido é automaticamente utilizado como nova semente em uma segunda tentativa, e múltiplos valores de k-mer são experimentados em sequência. Essa estratégia aumenta a taxa de sucesso da montagem sem requerer intervenção manual do usuário.

4.5.5 MITOS2

O MITOS2 é uma ferramenta desenvolvida para a anotação funcional de genomas mitocondriais em metazoários. Apresentada por Donath et al. (2019), constitui a evolução da primeira versão do MITOS, oferecendo maior precisão na predição de genes, integração com bases de dados atualizadas e maior flexibilidade de execução.

Tecnicamente, o MITOS2 combina métodos de homologia (comparação com sequências conhecidas) e algoritmos de predição *ab initio* (a partir da própria sequência, sem referência externa) para identificar as principais classes de genes presentes em genomas mitocondriais. O sistema utiliza alinhamentos com modelos de substituição específicos para proteínas codificadas por mitocôndrias, além de perfis de RNA para identificar rRNAs e tRNAs por meio de modelos de covariância (Infernal). As entradas consistem em um arquivo FASTA contendo a sequência do genoma mitocondrial a ser anotado, e as saídas incluem: (i) arquivos tabulares com as coordenadas dos genes anotados, (ii) representações gráficas do genoma mostrando a organização gênica, e (iii) arquivos de anotação em formatos padrão, como GFF3 e BED (formato tabular simplificado com coordenadas genômicas). É relevante notar que, conforme relatado por Donath et al. (2019), anotações do RefSeq podem apresentar inconsistências — em particular, atribuições implausíveis de posições de códons de início e parada, além de anotações incompletas que identificam apenas fragmentos de genes codificadores de proteínas. O MITOS2 demonstrou que uma anotação totalmente automática com alta acurácia é possível, representando uma melhoria relevante em relação à determinação manual de fronteiras gênicas.

A versão empregada neste trabalho (v2.1.9) foi instalada via Conda em um container Docker baseado em Miniconda 24.1.2-0, utilizando o banco de dados RefSeq89m obtido do Zenodo (DONATH et al., 2019). Essa abordagem garante que a ferramenta, normalmente executada via interface web, funcione de forma autônoma em linha de comando e completamente integrada ao *workflow* Nextflow.

Como extensão funcional, o pipeline integra automaticamente a geração de representações visuais da estrutura secundária dos tRNAs e rRNAs preditos. Para isso, o módulo MITOS2 extrai as sequências e estruturas dot-bracket dos arquivos de saída e as processa com o RNAplot, componente do pacote ViennaRNA (LORENZ et al., 2011), gerando arquivos SVG individuais para cada RNA não codificante. Essa funcionalidade, associada à versão web do MITOS2 (UseGalaxy), foi reproduzida localmente no pipeline, permitindo que os diagramas de estrutura secundária sejam gerados sem dependência de

serviços externos.

Entre as principais vantagens do MITOS2 destacam-se: (i) a automação completa da etapa de anotação, reduzindo a necessidade de curadoria manual extensiva; (ii) a compatibilidade com diferentes grupos taxonômicos de metazoários; e (iii) a produção de relatórios gráficos de fácil interpretação. Em estudos recentes de genômica mitocondrial comparativa, a anotação do MITOS2 é frequentemente complementada pela verificação de tRNAs com tRNAscan-SE, ferramenta especializada que utiliza modelos de covariância otimizados para a predição de RNAs transportadores (KUNDU et al., 2024; SHI et al., 2024). Essa combinação MITOS2 + tRNAscan-SE tem sido empregada em estudos recentes da área. No presente pipeline, o MITOS2 é utilizado como ferramenta única de anotação, dado que seus próprios modelos de covariância (via Infernal) já incorporam predição de tRNAs com alta sensibilidade; a integração opcional de tRNAscan-SE como módulo de verificação adicional constitui uma perspectiva futura. Por outro lado, como limitações, pode apresentar divergências em regiões com estruturas gênicas incomuns — como o caso do gene ND3 em aves, que apresenta um **frameshift insertion** (inserção de um nucleotídeo que desloca o quadro de leitura do código genético, alterando a sequência de aminoácidos traduzida daquele ponto em diante), documentado por Mindell, Sorenson e Dimcheff (1998), levando o MITOS2 a reportar o gene como dois **ORFs** (*Open Reading Frames* — quadros abertos de leitura, trechos de DNA que potencialmente codificam proteínas) distintos (nad3_0 e nad3_1) em vez de um único CDS (*Coding Sequence* — sequência codificante) com `join()`. Esse tipo de situação requer validação complementar e tratamento específico na conversão para formatos de submissão ao GenBank.

4.5.6 Docker

No pipeline proposto, cada ferramenta foi encapsulada em um container Docker, assegurando que todas as dependências fossem executadas em ambientes controlados e consistentes (MERKEL, 2014). O pipeline utiliza cinco imagens Docker distintas, cada uma correspondendo a um estágio do processamento, conforme apresentado na Tabela 5.

Tabela 5 – Imagens Docker utilizadas no pipeline.

Imagem	Base	Ferramenta	Dockerfile
mitogenome-pipeline/sra-tools:1.0	ubuntu:22.04	SRA-Toolkit 3.0.10	docker/sra-tools/
mitogenome-pipeline/fastqc:1.0	ubuntu:22.04	FastQC 0.12.1	docker/fastqc/
mitogenome-pipeline/trim-galore:1.0	ubuntu:22.04	Trim Galore 0.6.10 + Cutadapt 4.6	docker/trim-galore/
mitogenome-pipeline/novoplasty:1.0	ubuntu:22.04	NOVOPlasty 4.3.1	docker/novoplasty/
mitogenome-pipeline/mitos2:1.0	miniconda3:24.1.2-0	MITOS2 2.1.9 + ViennaRNA	docker/mitos2/

Essa abordagem eliminou a necessidade de configurações manuais complexas e garantiu que softwares como FastQC, Cutadapt, NOVOPlasty e MITOS2 operassem de forma uniforme em diferentes sistemas operacionais. Com isso, a montagem e a anotação

de mitogenomas tornam-se replicáveis em qualquer ambiente computacional que disponha do Docker instalado, ampliando a portabilidade do pipeline.

4.5.7 Nextflow

O **Nextflow** é um sistema de gerenciamento de *workflows* (*Workflow Management System*) voltado à construção de pipelines de processamento de dados, com foco particular em bioinformática (Di Tommaso et al., 2017). Sua proposta central é separar a **lógica do fluxo** (como os processos se conectam) da **execução** (em qual ambiente o código roda), permitindo que o mesmo pipeline seja executado em um notebook pessoal, em um *cluster* HPC ou em ambiente de nuvem sem alteração do código-fonte. Por sua importância central neste trabalho, esta seção apresenta seus componentes em detalhe.

DSL2 (Domain Specific Language version 2). A versão atual do Nextflow utiliza uma sintaxe declarativa chamada DSL2, baseada na linguagem Groovy. DSL2 introduziu a *modularidade*: processos podem ser definidos em arquivos separados (no pipeline, agrupados em **modules**/) e compostos em um *workflow* principal. Adicionalmente, ofereceu operadores funcionais para manipulação de fluxos de dados, aproximando o estilo de programação ao de *pipelines* Unix com *streams*. O resultado é a possibilidade de construir pipelines complexos como composição de blocos independentes, cada um responsável por uma etapa atômica e testável de forma isolada.

Anatomia de um *process*. A unidade fundamental do Nextflow é o *process*, que descreve uma tarefa computacional discreta. Um processo declara: **(i)** suas entradas (**input**), com tipos como **path** (arquivo), **val** (valor escalar) ou **tuple** (composto); **(ii)** suas saídas (**output**), declaradas com a mesma sintaxe; **(iii)** diretivas que controlam metadados e recursos — **tag** (rótulo para logs), **cpus** e **memory** (recursos alocados), **container** (imagem Docker a usar) e **publishDir** (onde os arquivos finais serão publicados); e **(iv)** o bloco **script**, que contém o código *shell* a ser executado dentro do container. Os processos não compartilham estado entre si: comunicam-se exclusivamente por meio de *channels*, garantindo isolamento e facilitando a paralelização.

Channels (canais). Os *channels* são as estruturas que conectam processos. Um *channel* é uma fila tipada e assíncrona de elementos, podendo conter um único valor (*value channel*) ou uma sequência de elementos (*queue channel*). A conexão entre processos é feita ligando a saída de um aos canais de entrada do seguinte. Operadores como **.map**, **.filter**, **.collect** e **.join** permitem transformações funcionais sobre os canais entre processos, ao estilo de *streams* em linguagens funcionais. Um exemplo concreto no pipeline desenvolvido é o filtro de circularização: a saída do processo **NOVOPLASTY** é encaminhada ao operador **.filter**, que deixa passar apenas arquivos cujo nome começa com **Circularized_assembly**, descartando montagens parciais antes da etapa de anotação.

Workflow principal. O bloco **workflow** é onde os processos e canais são com-

postos em um pipeline executável. No pipeline desenvolvido, o *workflow* principal (em `main.nf`) conecta as sete etapas, expressando a lógica condicional do Pilot QC (executado apenas quando `sra_max_reads` não é definido) e da habilitação opcional do MITOS2 (executado apenas quando `mitos2_db` aponta para um banco de dados válido). Essa expressão declarativa da lógica de controle elimina a necessidade de scripts de orquestração separados, mantendo toda a lógica do pipeline em um único lugar versionável.

Mecanismo `-resume` (cache por *hashing*). Uma das características mais valiosas do Nextflow é a retomada automática de execuções interrompidas. Cada *process* executado produz um diretório de trabalho identificado por um *hash* computado a partir dos seus inputs, parâmetros e versão do container. Em uma re-execução com a flag `-resume`, o Nextflow compara os hashes e, se inalterados, reutiliza os resultados previamente computados em vez de re-executar a etapa. O ganho prático é significativo: corrigir um erro em uma etapa final do pipeline e reexecutá-lo não exige refazer o *download* de dezenas de gigabytes do SRA, nem reprocessar a trimagem, por exemplo.

Integração com containers Docker. O Nextflow integra-se nativamente com Docker (e com outros gerenciadores de containers, como Singularity, Podman e Charliecloud, sem alteração do código do pipeline). A diretiva `container '<image>:<tag>'` declarada em cada *process* garante que ele seja executado dentro do container especificado, com versões fixas. Combinada com a estratégia de *pinning* das tags Docker — discutida em detalhe na seção anterior —, essa integração é o que viabiliza a reprodutibilidade do pipeline em qualquer ambiente.

Sistema de perfis (*profiles*). O sistema de perfis do Nextflow foi utilizado para parametrizar execuções distintas sem alterar o código-fonte. Cada espécie estudada possui um arquivo de configuração próprio (e.g., `conf/a_leari.config`) contendo os parâmetros específicos — acesso SRA, semente, tamanho esperado do genoma, código genético, número-alvo de *reads* —, que são carregados automaticamente ao invocar o perfil correspondente (`nextflow run main.nf -profile a_leari`). Para adicionar uma nova espécie ao pipeline, basta criar um novo arquivo de configuração em `conf/` e registrá-lo no `nextflow.config`, sem necessidade de modificar a lógica do pipeline em si — o que torna a ferramenta extensível por terceiros sem exigir compreensão da arquitetura interna.

4.5.8 GitHub

O GitHub é uma plataforma de hospedagem de código baseada no sistema de controle de versão Git, amplamente utilizada para o desenvolvimento colaborativo de software e projetos científicos. Para pipelines de bioinformática, a disponibilização em um repositório GitHub garante não apenas transparência, mas também acessibilidade e manutenção a longo prazo.

Neste trabalho, o GitHub foi utilizado como repositório público para disponibilizar

o pipeline desenvolvido, assegurando sua acessibilidade, versionamento e documentação adequada. Essa prática se alinha às diretrizes de ciência aberta e reforça o compromisso com a reprodutibilidade e a transparência metodológica. O repositório inclui: o código completo do *workflow* Nextflow, todos os Dockerfiles, scripts auxiliares, configurações de perfil por espécie, dados de semente (sequências cox1), documentação e guia de execução.

Adicionalmente, o sistema de branches do Git foi utilizado para preservar estados estáveis do pipeline: a branch **fase1-montagem** contém o estado validado da Fase 1 (apenas montagem, sem anotação), enquanto a branch **main** contém o pipeline completo com todas as etapas integradas.

4.6 AQUISIÇÃO E PREPARO DOS DADOS

A primeira etapa prática do pipeline consiste na aquisição e organização dos dados de sequenciamento que servirão de insumo para a montagem dos genomas mitocondriais. Para este trabalho, foram utilizados datasets públicos provenientes do Sequence Read Archive (SRA), repositório mantido pelo NCBI e reconhecido como um dos principais bancos internacionais de dados de sequenciamento de alto rendimento (LEINONEN; SUGAWARA; SHUMWAY, 2011). A escolha por dados públicos justifica-se pela sua ampla disponibilidade, pela diversidade de organismos representados e pela possibilidade de reproduzir e validar resultados obtidos em trabalhos prévios.

O acesso aos dados é realizado por meio do SRA-Toolkit v3.0.10 (encapsulado em container Docker), por meio de dois comandos sequenciais: **prefetch**, responsável pelo download do arquivo **.sra** compactado, e **fastq-dump -X** ou **fasterq-dump**, que convertem o arquivo para o formato FASTQ paired-end — o primeiro quando há limite de leituras definido, o segundo quando se deseja processar o dataset integralmente. Implementou-se também a estratégia de retries automáticos (até 2 tentativas) para lidar com instabilidades de rede, comuns em downloads de datasets grandes do NCBI.

Como estudo de caso principal, foi utilizado o dataset SRR28399504 referente ao genoma de *Anodorhynchus leari*, gerado por sequenciamento paired-end na plataforma Illumina HiSeq X Ten (Iridian Genomes, 2024), com leituras de 150 pares de bases e um total de 118,5 milhões de pares. Para validação do pipeline, foi utilizado o dataset SRR36182901 referente a *Diploprion bifasciatus* (peixe-sabão barrado), gerado em plataforma NovaSeq X Plus com leituras de 151 bp.

4.7 ANÁLISE PILOTO DE QUALIDADE (PILOT QC)

Uma inovação incorporada ao pipeline é o módulo de análise piloto de qualidade, que soluciona um problema prático recorrente em montagens de organelas: a determinação do volume adequado de dados a serem processados. Em datasets de sequenciamento

de genoma total, a proporção de leituras mitocondriais pode representar apenas uma pequena fração do total (DIERCKXSENS; MARDULYN; SMITS, 2017), o que significa que processar integralmente um dataset de 100 GB resultaria em centenas de gigabytes de dados nucleares irrelevantes para a montagem do mitogenoma. Além da ineficiência computacional, esse volume torna a análise impraticável em computadores pessoais: um notebook com 256 GB de SSD e 16 GB de RAM não comportaria os arquivos temporários gerados pela conversão e processamento de 87 GB de FASTQs brutos. O Pilot QC resolve esse problema logo na primeira etapa, reduzindo drasticamente o volume de dados antes que qualquer processamento pesado ocorra.

O módulo Pilot QC opera da seguinte forma: quando o parâmetro `sra_max_reads` não é definido pelo usuário, o pipeline baixa automaticamente uma subamostra de 500.000 leituras (aproximadamente 500 MB) utilizando o `fastq-dump -X`, que limita a extração na origem sem necessidade de transferir o dataset completo. Essa mesma estratégia de extração limitada por `fastq-dump -X` é empregada pelo módulo `SRA_DOWNLOAD` quando `sra_max_reads` está definido, garantindo consistência e eficiência de armazenamento em todo o pipeline. Essa subamostra é então submetida ao script `scripts/pilot_qc.sh`, um analisador desenvolvido inteiramente em Bash que opera diretamente sobre os arquivos FASTQ sem dependências externas além de `awk` e `grep`. O script extrai três métricas-chave:

- a) **Proporção de bases com qualidade $\geq Q30$** , indicando a qualidade geral das leituras;
- b) **Proporção de leituras com adaptador Illumina TruSeq residual**, estimando a perda efetiva no trimming;
- c) **Fração mitocondrial estimada**, calculada por correspondência de k-mers da sequência semente contra as leituras piloto.

A partir dessas métricas, o script responde a uma pergunta prática: *quantas leituras devem ser baixadas do SRA para atingir, com folga, uma cobertura-alvo de $500\times$ sobre o mitogenoma?* A resposta é construída em duas etapas. Primeiro determina-se quantas leituras **mitocondriais** são necessárias para essa cobertura; em seguida, infla-se esse valor para compensar a fração diminuta de mtDNA em datasets WGS e as perdas previstas no pré-processamento.

4.7.1 Etapa 1 — Leituras Mitocondriais Necessárias

A cobertura C é, por definição, o número médio de vezes em que cada base do genoma é lida. Para cobrir um genoma de tamanho G com cobertura C_{alvo} , é preciso obter $C_{alvo} \times G$ bases sequenciadas. Como cada par de leituras paired-end contribui com

$2 \times L$ bases (onde L é o comprimento médio de leitura), o número de pares de leitura mitocondriais é dado por:

$$R_{mito} = \frac{C_{alvo} \times G}{L \times 2} \quad (4.2)$$

Aplicando ao caso de *A. leari* ($C_{alvo} = 500\times$, $G \approx 16.500$ bp, $L = 150$ bp), bastam $R_{mito} \approx 27.500$ pares de leituras estritamente mitocondriais para atingir a cobertura-alvo — um valor surpreendentemente pequeno, dado o tamanho compacto do mitogenoma.

4.7.2 Etapa 2 — Leituras Totais a Baixar

Como o sequenciamento é **WGS** (*whole-genome shotgun*), apenas uma fração diminuta das leituras corresponde efetivamente ao mtDNA (tipicamente entre 0,01% e 1%); o restante é DNA nuclear, ignorado pela montagem mitocondrial. Além disso, parte das leituras baixadas será descartada no controle de qualidade. O número total de pares a baixar é então:

$$R_{total} = \frac{R_{mito} \times F_{Q30} \times F_{adapter}}{f_{mito}} \times 1,5 \quad (4.3)$$

Cada termo cumpre um papel específico:


- a) o **denominador** f_{mito} (fração mitocondrial estimada via correspondência de k-mers entre a semente *cox1* e a subamostra piloto) realiza a expansão dominante: dividir por $f_{mito} = 0,0005$, por exemplo, equivale a multiplicar por 2.000, refletindo a diluição do mtDNA no genoma total;
- b) os **fatores de correção** F_{Q30} e $F_{adapter}$ inflam o resultado proporcionalmente às perdas esperadas no *trimming*: quando a proporção de bases Q30 é alta (próxima de 95%), $F_{Q30} \approx 1$; quando a qualidade é mais baixa, ou quando a presença de adaptadores residuais é elevada, ambos os fatores crescem para compensar as leituras que serão descartadas;
- c) a **margem de segurança** de 1,5 atua como buffer contra subestimação de f_{mito} pelo piloto e contra eventos imprevistos como contaminação ou variação local de cobertura, evitando uma re-execução completa do pipeline caso a primeira tentativa não circularize.

Os valores específicos atribuídos a F_{Q30} , $F_{adapter}$, à margem de 1,5 e à cobertura-alvo de $500\times$ são **empíricos**: foram calibrados pela observação de execuções sucessivas durante o desenvolvimento, mantendo-os no menor valor que ainda garantia circularização confiável. Esses parâmetros estão centralizados no início do script `pilot_qc.sh` e podem ser revisados em iterações futuras à medida que mais datasets sejam processados pelo

pipeline. O resultado final é confinado ao intervalo [5M; 25M] pares por dois motivos práticos: abaixo de 5M, mesmo datasets com fração mitocondrial alta podem não fornecer cobertura suficiente; acima de 25M, o ganho marginal não compensa o tempo de *download* adicional. Esse valor calculado é então passado automaticamente ao módulo de *download* principal, que extrai diretamente apenas o número apurado de pares via `fastq-dump -X`.

Caso o usuário opte por definir manualmente o `sra_max_reads` via parâmetro de linha de comando, a etapa Pilot QC é automaticamente pulada, preservando a flexibilidade para cenários em que o pesquisador já possui conhecimento prévio sobre seus dados.

Figura 11 – Fluxograma de decisão do Pilot QC: análise de Q30%, taxa de adaptadores e fração mitocondrial estimada para cálculo automático do número ideal de leituras, com caps entre 5M e 25M.



Fonte: Elaborado pelo autor (2026).

O fluxo decisório do Pilot QC é detalhado na Figura 11 e evidencia que o módulo opera exclusivamente sobre uma subamostra de 500K leituras, evitando o download completo do dataset antes de determinar seus parâmetros de qualidade. As três métricas extraídas — porcentagem de bases Q30, taxa de adaptadores e fração mitocondrial estimada — alimentam as equações do fator de ajuste, resultando em um número de leituras automaticamente calibrado entre 5 e 25 milhões.

Cabe registrar que, nos três estudos de caso executados neste trabalho, o cálculo bruto da Equação 4.3 ultrapassou o teto de 25 milhões em todos os datasets, resultando em recomendações idênticas para perfis distintos. Esse comportamento, embora seguro, reflete uma propriedade estrutural da fórmula — discriminativa apenas para datasets com $f_{mito} \gtrsim 0,2\%$, intervalo atípico para WGS de vertebrados. Uma proposta de **modelo refinado** (com inversão da pergunta da fórmula e calibração empírica) foi desenvolvida e está descrita como perspectiva futura no Capítulo 7, mantida fora desta versão para preservar a coerência metodológica dos estudos de caso.

4.8 CONTROLE DE QUALIDADE E PRÉ-PROCESSAMENTO

Após a aquisição e organização dos dados de sequenciamento, a etapa seguinte do pipeline consiste na avaliação da qualidade das leituras e na aplicação de procedimentos de filtragem. Essa fase é essencial para assegurar que apenas dados confiáveis avancem para a montagem do genoma mitocondrial, evitando que artefatos técnicos comprometam a acurácia do resultado final.

O primeiro passo é a execução do FastQC v0.12.1, que gera relatórios interativos em HTML contendo métricas fundamentais para a avaliação da qualidade das leituras. Em seguida, é aplicado o Trim Galore v0.6.10 (que integra o Cutadapt v4.6), com parâmetros de qualidade Phred mínimo de 20 e comprimento mínimo de leitura de 50 bp para remoção de adaptadores e bases de baixa qualidade. No módulo implementado, o número de threads de CPU foi deliberadamente limitado a 2 para evitar ultrapassar a alocação de CPU no container, dado que o Trim Galore gera internamente threads adicionais para compressão (pigz) e para o próprio Cutadapt.

Além de aumentar a confiabilidade biológica das leituras, o pré-processamento contribui significativamente para a redução do volume de dados. Na execução para *A. leari*, por exemplo, o Trim Galore detectou adaptadores Illumina TruSeq em 81,4% das leituras, e após o trimming, 71,9% das bases foram mantidas — uma redução de volume de $\sim 28\%$.

Cabe observar que o pipeline não executa uma segunda análise FastQC após a trimagem. Embora essa prática seja adotada por alguns protocolos de QC genômico, ela foi deliberadamente omitida neste contexto por três razões: (i) o Trim Galore já produz um relatório detalhado com estatísticas de trimagem (bases removidas, leituras descartadas, taxa de adaptadores remanescentes); (ii) a qualidade dos dados é avaliada de forma complementar *a posteriori*, pela circularização bem-sucedida do mitogenoma e pela anotação íntegra dos 37 genes — evidências funcionais complementares às métricas de QC intermediárias; e (iii) a omissão desta etapa reduz o tempo de execução total sem comprometer a confiabilidade dos resultados, conforme demonstrado nos estudos de caso apresentados no Capítulo 5.

4.9 MONTAGEM DO MITOGENOMA

A montagem do genoma mitocondrial constitui a etapa central do pipeline, pois é nela que se obtém a sequência circular completa que serve de base para a anotação funcional e análises comparativas. Para essa finalidade é utilizado o NOVOPlasty v4.3.1, um dos montadores mais consolidados para organelas (DIERCKXSENS; MARDULYN; SMITS, 2017).

No pipeline implementado, o módulo NOVOPlasty incorpora diversas melhorias em relação ao uso padrão da ferramenta:


- a) **Múltiplos k-mers:** o parâmetro `novoplasty_kmers` permite definir uma lista de valores de k-mer a serem tentados em sequência (e.g., '39,33'). O pipeline experimenta cada valor até obter a **circularização** — condição em que as duas extremidades da sequência em extensão se encontram, sinalizando que o mitogenoma completo foi reconstruído (conforme descrito no Capítulo 2 e ilustrado na Figura 4);
- b) **Re-seeding automático:** para cada k-mer, caso a primeira execução não circularize, o maior contig obtido é automaticamente extraído e utilizado como nova semente em até 5 iterações (configurável);
- c) **Liberação de espaço:** após a montagem, os arquivos FASTQ trimados são automaticamente deletados para economizar espaço em disco, comportamento crucial para execuções com dados volumosos.

A seleção dos valores de k-mer segue as recomendações do próprio NOVOPlasty (DIERCKXSENS; MARDULYN; SMITS, 2017), que aceita valores ímpares no intervalo de 21 a 39. Valores maiores de k-mer (como 39) favorecem a **especificidade** da montagem — cada k-mer é mais longo e, portanto, menos ambíguo, reduzindo o risco de quimeras e extensões incorretas. Por outro lado, valores menores (como 33) aumentam a **sensibilidade**, permitindo extensões em regiões de menor cobertura ou maior divergência entre a semente e o genoma-alvo. Assim, a estratégia adotada neste pipeline inicia pelo valor máximo (39), que produz montagens mais confiáveis quando a cobertura e a qualidade dos dados são adequadas, e recorre ao valor menor (33) apenas se a circularização não for alcançada na primeira tentativa. Para *A. leari*, a circularização ocorreu na primeira tentativa com k-mer 39, indicando que a cobertura de 176× e a qualidade do HiSeq X Ten foram suficientes para o valor mais restritivo. Já para *D. bifasciatus*, a circularização ocorreu com k-mer 33, possivelmente refletindo diferenças na cobertura ou na composição nucleotídica do dataset. Essa estratégia iterativa é sintetizada na Figura 12.

A Figura 12 mostra que o pipeline tenta inicialmente o k-mer mais alto (k=39), que oferece maior especificidade na resolução de regiões repetitivas. Caso a circularização não seja obtida, o pipeline reduz automaticamente para k=33, que recruta mais leituras

ao custo de menor especificidade. Nos testes realizados, *A. leari* circularizou na primeira tentativa ($k=39$), enquanto *D. bifasciatus* necessitou do *fallback* para $k=33$.

Figura 12 – Diagrama da lógica iterativa de k-mers: tentativa com $k=39$ (alta especificidade) seguida de *fallback* para $k=33$ (maior sensibilidade) quando a circularização não é alcançada.



Fonte: Elaborado pelo autor (2026).

Obtenção da semente (seed). O NOVOPlasty requer uma sequência inicial conhecida para ancorar a extensão. A estratégia adotada neste trabalho consiste em: (i) identificar no NCBI uma espécie congênere ou filogeneticamente próxima que pos-

sua mitogenoma completo depositado; (ii) extrair o gene *cox1* dessa referência, por ser o marcador mitocondrial mais conservado e amplamente disponível; e (iii) salvar a região em formato FASTA. Para *A. leari*, foi utilizado o gene *cox1* de *A. hyacinthinus* (NC_082165.1, posições 5359–6906, 1.548 bp), espécie congênere cuja proximidade filogenética garante homologia suficiente para o *seed-and-extend* funcionar eficazmente. Para *D. bifasciatus*, foi utilizado o próprio *cox1* da referência publicada (PZ143763.1, 1.560 bp). O repositório do pipeline inclui um guia detalhado para obtenção de sementes (`data/seeds/COMO_OBTER_SEMESTE.md`) e exemplos para diferentes espécies de grupos taxonômicos variados.

Seleção do intervalo de tamanho (`genome_range`). O NOVOPlasty utiliza um intervalo esperado de tamanho do genoma para descartar extensões espúrias. A determinação desse intervalo segue a mesma lógica da semente: busca-se no NCBI o tamanho do mitogenoma de referência da espécie congênere mais próxima e aplica-se uma margem de ± 1.500 – 2.000 bp para acomodar variação interespecífica. Para *A. leari*, a referência *A. hyacinthinus* (16.999 bp) resultou no intervalo 15.500–18.500 bp; para *D. bifasciatus*, a referência PZ143763.1 (16.805 bp) resultou em 15.000–18.500 bp.

Parâmetro `insert_size`. O parâmetro `insert_size = 300` é informado ao NOVOPlasty como estimativa inicial conservadora, típica de bibliotecas Illumina paired-end. A opção `Insert size auto = yes` habilita o auto-ajuste: durante a montagem, o NOVOPlasty calcula o inserto real alinhando as leituras pareadas contra a sequência em extensão. Para *A. leari*, o inserto medido foi de 210 bp (registrado no log de saída do NOVOPlasty), aproximadamente 30% inferior à estimativa inicial. Essa divergência é esperada e benigna, pois o valor refinado é utilizado nas etapas subsequentes da montagem. O inserto curto também explica o alto percentual de *read-through* observado pelo FastQC (Seção 5.3): bibliotecas com insertos menores que o comprimento das leituras (150 bp) produzem mais reads contaminados por adaptador, pois o sequenciador percorre todo o inserto e captura bases adicionais do adaptador ligado à extremidade.

4.10 ANOTAÇÃO FUNCIONAL

Concluída a etapa de montagem, procede-se à anotação funcional do genoma mitocondrial reconstruído, utilizando o MITOS2 v2.1.9 com o banco de dados RefSeq89m. A anotação é executada automaticamente pelo pipeline quando o parâmetro `mitos2_db` está configurado, sendo condicional para permitir que a Fase 1 (montagem) opere independentemente.

O módulo MITOS2 recebe como entrada o arquivo FASTA da montagem circularizada e produz como saída: arquivo GFF3 com coordenadas dos genes, tabelas BED, sequências proteicas preditas (FAA), mapa linear do genoma (PNG) e plots de qualidade (PDF). Adicionalmente, o pipeline gera automaticamente diagramas SVG da estrutura

secundária prevista para cada tRNA e rRNA identificado, utilizando o programa RNAPlot do pacote ViennaRNA.

O código genético é parametrizado (`genetic_code = 2` para vertebrados mitocondriais, `genetic_code = 5` para invertebrados), permitindo que o mesmo pipeline seja utilizado para diferentes grupos taxonômicos sem modificação de código.

4.11 COMPILAÇÃO DOS ENTREGÁVEIS

Uma funcionalidade diferenciada do pipeline é a compilação automática de todos os produtos da análise em uma pasta organizada de entregáveis (`summary/`), pronta para apresentação acadêmica ou submissão a bancos de dados. Essa etapa é executada pelo módulo `COMPILE_SUMMARY`, que integra três scripts Python:

- a) **`gff2genbank.py`** — Converte a anotação GFF3 do MITOS2 para o formato feature table (`.tbl`) do GenBank, com tratamento especial para o frameshift do ND3 em aves, tartarugas e crocodilianos (uso de `join()` e `/exception=ribosomal slippage`);
- b) **`generate_genbank.py`** — Gera o GenBank Flat File (`.gbk`) e o mapa circular do genoma (SVG e PDF) via Biopython GenomeDiagram (COCK et al., 2009);
- c) **`compile_summary.py`** — Reúne e organiza todos os arquivos em uma estrutura numerada.

Os entregáveis gerados pelo pipeline são apresentados na Tabela 6.

Tabela 6 – Categorias de entregáveis gerados automaticamente pelo pipeline.

#	Arquivo	Conteúdo
01	<code>01_genome_assembly.fasta</code>	Mitogenoma circularizado completo
02	<code>02_coding_genes_nt.fasta</code>	13 CDS em nucleotídeos
03	<code>03_coding_genes_aa.fasta</code>	13 CDS em aminoácidos
04	<code>04_ribosomal_genes.fasta</code>	12S + 16S rRNA
05	<code>05_transport_genes.fasta</code>	22 tRNAs
06	<code>06_gene_positions.tsv</code>	Posição física de todos os genes
07	<code>07_start_stop_codons.tsv</code>	Start/Stop codons dos CDS
08	<code>08_trna_anticodons.tsv</code>	Anticódon dos tRNAs
09	<code>09_circular_map.svg/pdf</code>	Mapa circular colorido por grupo funcional

Tabela 6 – Categorias de entregáveis (continuação).

#	Arquivo	Conteúdo
10	<code>10_annotation.gff</code>	Anotação GFF3 completa
11	<code>structure_svgs/</code>	22 SVGs de tRNA + 2 SVGs de rRNA
12	<code>genbank_submission/</code>	.gbk + .tbl + .fsa para GenBank
13	<code>13_gene_order.txt</code>	Ordem gênica linear
14	<code>quality_plots/</code>	Plots de qualidade do MITOS2

Todos os scripts são genéricos — recebem o nome da espécie como parâmetro (`--organism`) e derivam automaticamente o identificador de sequência (e.g., “*Anodorhynchus leari*” → seqid `A_leari`), tornando o pipeline reutilizável para qualquer táxon.

4.12 AUTOMAÇÃO E REPRODUTIBILIDADE


A automação do pipeline e a padronização de sua execução representam os principais diferenciais desta proposta em relação a abordagens convencionais de montagem de genomas mitocondriais. Mais do que reunir ferramentas em sequência, busca-se disponibilizar um fluxo de trabalho que possa ser aplicado por diferentes grupos de pesquisa em distintos ambientes computacionais, assegurando consistência analítica, transparência metodológica e facilidade de reutilização. A estrutura de dados e as interfaces de transferência entre containers — isto é, **como** os arquivos produzidos por uma etapa são consumidos pela seguinte sem haver ambiguidade ou perda de informação — foi descrita em detalhe na Seção 4.2.1, incluindo o dicionário de dados completo (Tabela 2) e a especificação dos formatos intermediários e finais.

Para atingir esse objetivo, cada etapa do pipeline foi encapsulada em containers Docker, garantindo que as ferramentas operem em ambientes controlados e reproduzíveis, independentemente do sistema em que forem executadas (MERKEL, 2014). A orquestração pelo Nextflow automatiza a execução dos processos, gerencia dependências e possibilita paralelização quando aplicável. O sistema ainda permite a retomada da análise a partir do ponto de falha (via `-resume`), evitando reprocessamento desnecessário e aumentando a eficiência computacional (Di Tommaso et al., 2017).

Todo o código-fonte do *workflow* está disponibilizado em repositório público no GitHub, acompanhado de documentação detalhada, guia de execução e exemplos de uso. Essa prática de ciência aberta não apenas reforça a transparência metodológica, mas também incentiva a adaptação e o aprimoramento do pipeline por outros pesquisadores, em consonância com iniciativas comunitárias como o nf-core (EWELS et al., 2020).

Figura 13 – Três camadas de reprodutibilidade do pipeline: (1) código-fonte no GitHub, (2) ambiente isolado via Docker com versões fixadas, (3) orquestração via Nextflow DSL2.

Arquitetura de reprodutibilidade do pipeline



Fonte: Elaborado pelo autor (2026).

A Figura 13 ilustra as três camadas de reprodutibilidade implementadas no pipeline. Elas são complementares e funcionam de forma concêntrica: a camada externa (código-fonte no GitHub) garante a acessibilidade e o versionamento; a camada intermediária (Docker com versões fixadas) garante a consistência do ambiente de execução; e a camada interna (Nextflow DSL2) garante a orquestração determinística das etapas. Juntas, essas camadas favorecem que diferentes pesquisadores reproduzam a execução do pipeline e obtenham resultados consistentes, independentemente do sistema operacional ou da configuração local.

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta os resultados obtidos com a aplicação do pipeline desenvolvido, organizados segundo as etapas do fluxo de trabalho. Diferentemente da versão anterior deste trabalho, que apresentava resultados esperados de natureza projetiva, os dados aqui descritos são produtos reais de execuções completas do pipeline, validando sua funcionalidade e robustez.

5.1 EXECUÇÕES REALIZADAS

O pipeline foi executado para três espécies, com objetivos complementares. A Tabela 7 sintetiza os parâmetros e configurações utilizados em cada execução.


Tabela 7 – Parâmetros de execução do pipeline para as três espécies analisadas.

Parâmetro	<i>Anodorhynchus leari</i>	<i>Diploprion bifasciatus</i>	<i>Anodorhynchus hyacinthinus</i>
Objetivo	Objeto principal do TCC	Validação do pipeline	Validação cruzada
Dataset SRA	SRR28399504	SRR36182901	SRR36400750
Plataforma	Illumina HiSeq X Ten	NovaSeq X Plus	NovaSeq X
Tipo de dados	WGS	WGS	Metagenômico
Spots SRA / leitura	118,5M × 150 bp	12,0M × 151 bp	145,8M × 150 bp
Semente	cox1 <i>A. hyacinthinus</i> (NC_082165.1, 1.548 bp)	cox1 <i>D. bifasciatus</i> (PZ143763.1, 1.560 bp)	cox1 <i>A. leari</i> (montagem do pipeline, 1.548 bp)
genome_range	15.500–18.500 bp	15.000–18.500 bp	15.500–18.500 bp
K-mers	39, 33	33	39, 33
Código genético	2 (vertebrado)	2 (vertebrado)	2 (vertebrado)
MITOS2	Sim (RefSeq89m)	Não (perfil de teste)	Sim (RefSeq89m)
Perfil	-profile a_leari	-profile test	-profile a_hyacinthinus

5.2 AQUISIÇÃO E PREPARO DOS DADOS

Para *A. leari*, o download via `prefetch` obteve o arquivo `.sra` de 11 GB. O módulo `SRA_DOWNLOAD` utilizou o `fastq-dump -X 25000000` para extrair diretamente apenas os 25 milhões de spots (pares de leituras) recomendados pelo Pilot QC, gerando dois arquivos FASTQ de aproximadamente 7,4 GB cada (R1 e R2) — sem necessidade de converter o dataset completo de 118,5M spots. O Pilot QC, ativado automaticamente por não haver `sra_max_reads` definido no perfil, analisou 500K spots piloto e recomendou 25M spots (25M pares; 50M reads paired-end) como volume final para atingir a cobertura-alvo dentro do limite configurado no script. A Figura 14 ilustra essa redução de volume e a composição das bases após o pré-processamento.

Figura 14 – Redução de volume em cada etapa do pipeline para *A. leari*: tamanho dos arquivos por etapa (esquerda) e composição de bases após trimming (direita).



Fonte: Elaborado pelo autor (2026).

Na Figura 14, o painel esquerdo evidencia a redução progressiva do volume de dados em cada etapa do pipeline, desde os 87 GB teóricos do dataset completo até os 17 KB da montagem circularizada — uma redução de aproximadamente 5 milhões de vezes. Destaca-se que, com a extração direta via `fastq-dump -X`, o pipeline gera apenas ~14,8 GB de FASTQs (25M pares; 50M reads paired-end) em vez dos ~87 GB que seriam produzidos pela conversão integral. O painel direito confirma a distribuição equilibrada das quatro bases nucleotídicas (A, T, G, C) após a trimagem, indicando ausência de viés composicional que pudesse comprometer a montagem.

Para *D. bifasciatus*, o dataset compacto (12M spots SRA, ~1,2 GB) foi processado integralmente sem necessidade de truncagem, utilizando como semente o gene *cox1* da própria referência publicada (PZ143763.1, 1.560 bp) e `genome_range` de 15.000–18.500 bp.

5.3 CONTROLE DE QUALIDADE E PRÉ-PROCESSAMENTO

Os relatórios do FastQC para *A. leari* foram analisados como controle de qualidade prévio à montagem. As Figuras 15 e 16 apresentam, respectivamente, os painéis de qualidade *per-base* (acima) e de conteúdo de adaptadores (abaixo) para as leituras R1 e R2. Antes da apresentação dos resultados, descreve-se a anatomia desses painéis para fundamentar sua interpretação.

Anatomia do painel de qualidade. O painel de qualidade *per-base* sintetiza, em um único *boxplot*, a distribuição do **escore de qualidade Phred** (Q) por posição da leitura. Para cada posição, são exibidos a média (linha azul), o intervalo interquartil — IQR (caixas amarelas) — e os percentis 10 e 90 (bigodes). Três faixas coloridas de fundo demarcam regiões interpretativas: verde ($Q \geq 28$, alta qualidade), amarelo ($20 \leq Q < 28$, intermediária) e vermelho ($Q < 20$, baixa). O escore Q é definido em escala logarítmica da probabilidade de erro de chamada de base (EWING et al., 1998): $Q = -10\log_{10} P$, em que Q_{20} corresponde a 1 erro em 100 bases (1%), Q_{30} a 1 em 1.000 (0,1%) e Q_{40} a 1 em 10.000 (0,01%).


Anatomia do painel de adaptador. O painel de conteúdo de adaptador apresenta, para cada posição da leitura, a porcentagem de leituras que carregam, naquela posição, sequência homóloga aos adaptadores conhecidos do kit Illumina (TruSeq Universal, Small RNA 3'/5', Nextera) ou a homopolímeros (PolyA, PolyG). O crescimento monótono das curvas é assinatura de *read-through*: ocorre quando o tamanho do inserto da biblioteca é menor que o comprimento da leitura (150 bp), de modo que o sequenciador, após percorrer todo o fragmento de DNA-alvo, continua sintetizando e captura bases do adaptador ligado à extremidade. A Tabela 8 sintetiza o significado de cada elemento visual dos dois painéis.

Tabela 8 – Elementos visuais dos painéis FastQC e seu significado.

Elemento	Significado
Painel de qualidade <i>per-base</i>	
Eixo X	Posição na leitura, em pares de bases (1 a 150 bp)
Eixo Y	Escore de qualidade Phred (Q), de 0 a 40
Linha azul	Qualidade média por posição
Caixa amarela	Intervalo interquartil (IQR): quartis Q1 (25%) e Q3 (75%)
Bigodes (linhas verticais)	Percentis 10 e 90 da distribuição
Faixa verde de fundo	$Q \geq 28$ — qualidade alta
Faixa amarela de fundo	$20 \leq Q < 28$ — qualidade intermediária
Faixa vermelha de fundo	$Q < 20$ — qualidade baixa
Painel de conteúdo de adaptador	
Eixo X	Posição na leitura, em pares de bases
Eixo Y	Porcentagem de leituras com adaptador detectado naquela posição
Linha vinho	Illumina Universal Adapter (TruSeq)
Linha azul-marinho	Illumina Small RNA 3' Adapter
Linha verde	Illumina Small RNA 5' Adapter
Linha amarela	Nextera Transposase Sequence
Linha ciano	PolyA
Linha rosa	PolyG (artefato de química de dois canais)


Fonte: Elaborado pelo autor (2026), com base em Andrews (2010).

Figura 15 – Relatórios FastQC da leitura R1 (*A. leari*): qualidade *per-base* (acima) e conteúdo de adaptadores (abaixo).



Fonte: FastQC / Elaborado pelo autor (2026).

Figura 16 – Relatórios FastQC da leitura R2 (*A. leari*): qualidade *per-base* (acima) e conteúdo de adaptadores (abaixo).



Fonte: FastQC / Elaborado pelo autor (2026).

Leitura dos resultados de qualidade. Os painéis superiores das Figuras 15 e 16 exibem o padrão típico do sequenciamento por síntese (SBS) Illumina: qualidade média

estável e elevada ($Q \approx 39$) nos primeiros 90 ciclos, com IQRs estreitos e integralmente contidos na faixa verde, seguida de decaimento gradual a partir da posição ~ 100 . Esse decaimento decorre do acúmulo de *phasing/pre-phasing* entre *clusters* — moléculas que se adiantam ou atrasam em relação à reação predominante, gerando ruído de sinal. Mesmo no extremo 3', a média mantém-se em $Q \approx 33$ (R1) e $Q \approx 34,5$ (R2), correspondendo a probabilidades de erro inferiores a 0,1%. Os bigodes inferiores que descem à faixa amarela e vermelha nos últimos 30 ciclos indicam, contudo, que uma fração minoritária das leituras tem qualidade comprometida na cauda — justificando o trimming por qualidade ($Q \geq 20$) implementado pelo Trim Galore.

Leitura do conteúdo de adaptador. Nos painéis inferiores das mesmas figuras, o **Illumina Universal Adapter** (curva vinho) é a única classe de adaptador detectada acima de níveis residuais, atingindo $\sim 63\%$ das leituras nos últimos ciclos em ambas as orientações — consistente com a **incidência de adaptador** de 81,4% reportada pelo Trim Galore — métrica que contabiliza a fração de *reads* contendo pelo menos um nucleotídeo de adaptador detectável, e não a fração de bases removidas. Adicionalmente, R1 apresenta contaminação por **PolyG** (curva rosa, $\sim 27\%$ no extremo 3'), artefato característico da química de **dois canais** do HiSeq X Ten: na ausência de sinal fluorescente, o sequenciador interpreta a base como G. Em R2 essa contaminação é menos pronunciada ($\sim 15\%$), refletindo heterogeneidade entre as leituras pareadas no decaimento de sinal. Tanto adaptadores quanto homopolímeros de G são removidos pelo Trim Galore (em conjunção com Cutadapt), prevenindo que *k-mers* contaminados sejam incorporados aos extensores do NOVOPlasty e introduzam quimeras ou falsas extensões na montagem. A taxa de retenção de 71,9% das bases após o *trimming* — combinada à detecção de adaptador em 81,4% das *reads* — é compatível com uma biblioteca de insertos curtos, característica de preparações para HiSeq X Ten, em que os fragmentos frequentemente ultrapassam o comprimento das leituras.

A não-execução de um segundo FastQC após o Trim Galore é uma decisão de design deliberada, fundamentada em dois argumentos. **Primeiro**, o próprio Trim Galore emite relatório detalhado com as métricas pós-*trimming* equivalentes às do FastQC (bases removidas por qualidade, leituras descartadas por comprimento mínimo, taxa residual de adaptador), tornando redundante uma segunda execução do FastQC para o propósito de verificação. **Segundo**, a validação definitiva da qualidade dos dados não é dada por métricas intermediárias, mas pelo **desfecho funcional** do pipeline: a circularização bem-sucedida pelo NOVOPlasty e a anotação íntegra dos 37 genes pelo MITOS2 constituem evidências de qualidade mais robustas que qualquer relatório de QC — um pipeline que produz mitogenoma circular com conjunto gênico completo necessariamente operou sobre leituras de qualidade adequada. Essa abordagem segue o princípio de evitar etapas redundantes em pipelines científicos quando o desfecho final fornece a validação requerida (WILSON et al., 2014).

5.4 MONTAGEM DO MITOGENOMA

A montagem pelo NOVOPlasty resultou em genomas mitocondriais circularizados para as espécies analisadas. A Tabela 9 apresenta as métricas de montagem obtidas.

Tabela 9 – Métricas de montagem do mitogenoma para as três espécies analisadas.

Métrica	<i>A. leari</i>	<i>D. bifasciatus</i>	<i>A. hyacinthinus</i>
Tamanho	16.986 bp	~16.800 bp	16.999 bp
Circularização	Sim	Sim	Sim
K-mer ótimo	39	33	39
Cobertura média	176×	não medida	144×
Reads alinhadas	19.906 / 11.842.862 (0,17%)	—	16.238 / 11.708 (0,14%)
Reads montadas	12.432	—	11.060
Read length (fixo, do sequenciador)	150 bp	151 bp	150 bp
Insert size: parâmetro inicial → medido	300 bp → 210 bp	—	300 bp → 223 bp
Referência	16.999 bp (<i>A. hyacinthinus</i>) — Δ 13 bp	16.805 bp (PZ143763.1) — Δ ~5 bp	16.999 bp (OR209186.1) — 0 bp, 19 SNPs

Para *D. bifasciatus*, o dataset compacto (12M spots SRA, ~1,2 GB) foi processado integralmente sem truncagem; a circularização ocorreu na primeira tentativa com k-mer 33. O papel desta espécie no estudo é estritamente o de **espécie-controle**: validar que o pipeline reconstrói corretamente uma sequência previamente conhecida (PZ143763.1) antes de aplicá-lo a uma espécie sem referência (*A. leari*). Para esse propósito, a Fase 1 do pipeline — montagem por *seed-and-extend* até circularização — é suficiente, pois a verificação de correção pode ser feita por alinhamento (BLAST) contra a referência publicada, sem necessidade de anotação funcional. Por isso, o perfil de teste foi deliberadamente configurado sem o parâmetro `mitos2_db`, refletindo a separação modular entre Fase 1 (montagem) e Fase 2 (anotação). Essa separação é também preservada no controle de versão do repositório: a `branch fase1-montagem` mantém o pipeline funcional apenas com a Fase 1, atendendo a pesquisadores cujo interesse seja exclusivamente a montagem (e.g., análises filogenéticas baseadas em alinhamentos diretos), sem a sobrecarga das dependências e do banco de dados do MITOS2.

O resultado de *A. leari* merece destaque: o genoma montado de 16.986 bp difere em apenas 13 pares de bases do mitogenoma de referência de *A. hyacinthinus* (16.999 bp, NC_082165.1), demonstrando alta congruência interespecífica esperada para o gênero *Anodorhynchus*. A cobertura média de 176×, associada à circularização e ao tamanho esperado do mitogenoma, é compatível com uma montagem robusta baseada em NOVOPlasty (DIERCKXSENS; MARDULYN; SMITS, 2017), conferindo alta confiabilidade ao resultado.

A proporção de leituras mitocondriais de 0,17% é condizente com a estimativa teórica para dados de genoma total de aves, onde o número de cópias mitocondriais por célula é tipicamente na ordem de centenas a milhares (BOORE, 1999), mas o genoma nuclear ($\sim 1,2$ Gb em psitacídeos) é muito maior que o mitocondrial (~ 17 kb).

A Tabela 9 reporta dois comprimentos distintos que não devem ser confundidos: o **read length** (150 bp) é o tamanho de cada leitura individual, fixo pela tecnologia HiSeq X Ten e lido diretamente do arquivo FASTQ; o **insert size** (300 bp inicial $\rightarrow$ 210 bp medido) é o tamanho do fragmento de DNA inserido entre os adaptadores durante a preparação da biblioteca. O parâmetro inicial `insert_size = 300` é uma estimativa conservadora declarada em `conf/a_leari.config`; durante a montagem, o NOVOPlasty refina esse valor para 210 bp alinhando os pares contra a sequência em extensão (recurso `Insert size auto = yes`). Como o insert real (210 bp) é menor que o dobro do read length ($2 \times 150 = 300$ bp), os reads pareados ultrapassam o fragmento e percorrem parcialmente o adaptador, fenômeno chamado *read-through* (detalhado no Cap. 4) que explica a alta incidência de adaptador (81,4%) observada na seção seguinte.

O log do NOVOPlasty reportou uma fração de subamostragem (*subsampling fraction*) de 27,1%, indicando que o algoritmo carregou aproximadamente 27,1% das leituras pós-trimming disponíveis para a etapa de montagem, totalizando 11.842.862 *reads* efetivamente processados (somando R1 e R2). Esse comportamento reflete a eficiência do *seed-and-extend*: como o NOVOPlasty constrói o genoma iterativamente a partir da semente, ele pode alcançar a montagem completa sem necessidade de processar todas as leituras disponíveis, resultando em economia computacional proporcional à fração não processada. O mapa circular do mitogenoma montado é apresentado e analisado em detalhe no cap. 6 (Figura 22).

5.5 ANOTAÇÃO FUNCIONAL

A anotação pelo MITOS2 identificou o conjunto completo de genes esperado para um genoma mitocondrial de ave, conforme apresentado na Tabela 10.

Tabela 10 – Conteúdo gênico do mitogenoma de *A. leari* anotado pelo MITOS2.

Tipo	Qtd.	Genes
CDS	13	nad1, nad2, nad3, nad4, nad4l, nad5, nad6, cox1, cox2, cox3, atp6, atp8, cob
tRNA	22	tRNA-Phe, tRNA-Val, tRNA-Leu1, tRNA-Ile, tRNA-Gln, tRNA-Met, tRNA-Trp, tRNA-Ala, tRNA-Asn, tRNA-Cys, tRNA-Tyr, tRNA-Ser1, tRNA-Asp, tRNA-Lys, tRNA-Gly, tRNA-Arg, tRNA-His, tRNA-Ser2, tRNA-Leu2, tRNA-Glu, tRNA-Thr, tRNA-Pro
rRNA	2	rrnS (12S), rrnL (16S)
Origem de replicação	2	OH_0, OH_1

A ordem gênica identificada é compatível com o padrão conservado de Psittaciformes, corroborando a confiabilidade da montagem. A comparação com a anotação de *A. hyacinthinus* (NC_082165.1) confirmou a conservação da organização gênica dentro do gênero. A completude e a consistência da anotação — 13 CDS, 22 tRNAs com anticódons corretos, 2 rRNAs nas posições esperadas e nenhum gene truncado ou duplicado — servem como validação biológica indireta da montagem: um genoma incorretamente circularizado ou contendo inserções e deleções artificiais produziria genes com códons de parada prematuros, tRNAs com estruturas secundárias anômalas ou regiões intergênicas atipicamente longas — nenhum dos quais foi observado.

5.5.1 Caso Especial — Frameshift do ND3

Um aspecto biologicamente relevante revelado pela anotação é o tratamento do gene ND3. O MITOS2 reportou este gene como dois ORFs distintos (*nad3_0* e *nad3_1*) com sobreposição de 5 bp, refletindo o *frameshift insertion* documentado por Mindell, Sorenson e Dimcheff (1998) em genomas mitocondriais de aves, tartarugas e crocodilianos — e estendido posteriormente para outros vertebrados não-mamíferos. Esse fenômeno, em que uma inserção de ~1 nucleotídeo altera o quadro de leitura no interior do gene, é corrigido *in vivo* por mecanismos de *programmed ribosomal frameshift* ou edição do mRNA. Na referência *A. hyacinthinus* (NC_082165.1), o ND3 é anotado com `join()`:

```
CDS    join(9504..9677,9679..9854)
        /gene="ND3"
        /note="frameshift mechanism unknown (Mindell et al., 1998)"
```

Para a conversão dos resultados ao formato GenBank Flat File, os scripts `gff2genbank.py` e `generate_genbank.py` do pipeline detectam automaticamente a presença de *nad3_0* e *nad3_1* e os unificam em um único CDS com `join()`, aplicando o qualificador `/exception=ribosomal slippage`. Quando a sobreposição reportada

pelo MITOS2 é detectada e o código genético configurado é o vertebrado mitocondrial (`transl_table=2`), as coordenadas são automaticamente ajustadas para o *skip* canônico de 1 nucleotídeo — representação adotada pelo GenBank para esse fenômeno em aves, tartarugas e crocodilianos —, evitando que a sobreposição artefactual da predição se propague ao arquivo de submissão. Quando a espécie não apresenta esse *frameshift* (e.g., invertebrados), o ND3 é anotado normalmente como um CDS contínuo.

As estruturas secundárias dos 22 tRNAs e 2 rRNAs são analisadas em detalhe no Cap. 6 (Figura 24). Destaca-se que todos os tRNAs apresentam a estrutura canônica em trevo (*cloverleaf*), exceto o tRNA-Ser(AGY), que exibe ausência do braço DHU — padrão conservado em metazoários. A geração automática dessas estruturas pelo pipeline, integrando MITOS2 e RNAplot, constitui um diferencial em relação às ferramentas analisadas no Capítulo 3, que não incluem predição de estruturas secundárias.

5.6 COMPILAÇÃO DOS ENTREGÁVEIS E FORMATO GENBANK

O módulo COMPILE_SUMMARY reuniu automaticamente todos os produtos da análise em uma pasta organizada com 14 categorias de entregáveis, conforme detalhado na Tabela 6. Destaca-se a geração automática do GenBank Flat File (`.gbk`), que é o formato padrão exigido pelo NCBI para submissão de genomas. O arquivo gerado para *A. leari* contém:

Código-fonte 5.1 – Trecho do GenBank Flat File gerado pelo pipeline para *A. leari*.

LOCUS	A_leari	16986 bp	DNA	circular	VRT 14-APR-2026
DEFINITION	Anodorhynchus leari mitochondrion, complete genome.				
ACCESSION	A_leari				
VERSION	A_leari				
FEATURES	Location/Qualifiers				
source	1..16986 /organism="Anodorhynchus leari" /organelle="mitochondrion" /mol_type="genomic DNA"				
...					
CDS	join(10919..11092,11094..11267) /gene="ND3" /product="NADH dehydrogenase subunit 3" /transl_table=2 /exception="ribosomal slippage" /note="programmed frameshift; frameshift mechanism unknown (Mindell et al., 1998, Mol. Biol. Evol., 15:1568-1571)"				

```

...
ORIGIN
      1 gtttacgcta taaagcgcta gatataactg ...
//

```

Esse formato pode ser diretamente submetido ao GenBank via `table2asn` ou carregado em ferramentas de visualização como OGDRAW para geração de mapas circulares de alta qualidade.

5.7 ANÁLISE DE DESEMPENHO E EFICIÊNCIA COMPUTACIONAL

A avaliação de desempenho de um pipeline bioinformático é essencial para determinar sua viabilidade prática em diferentes cenários de uso — desde laptops pessoais até servidores de computação em nuvem. Em bioinformática, pipelines frequentemente processam volumes massivos de dados (dezenas a centenas de gigabytes), e compreender onde o tempo e os recursos computacionais são consumidos permite identificar gargalos, dimensionar infraestrutura adequada e estimar custos operacionais. Essa análise é particularmente relevante para laboratórios com recursos limitados, que precisam avaliar se dispõem de hardware suficiente antes de iniciar uma execução.

Nesta seção, são apresentadas métricas detalhadas de execução do pipeline para *A. leari*, incluindo tempo, consumo de CPU, memória RAM e operações de entrada/saída (I/O) — isto é, volume de dados lidos e escritos em disco — por etapa. A partir dessas métricas, discutem-se a eficiência de cada módulo, a identificação de gargalos, o impacto do pré-processamento na qualidade da montagem, e o custo estimado de execução em infraestrutura de nuvem.


A execução foi realizada em um laptop com processador Intel Core i7-1165G7 (4 núcleos físicos, 8 threads via *hyperthreading*, frequência base de 2,80 GHz), 16 GB de memória RAM DDR4 e armazenamento em estado sólido (SSD NVMe). O tempo total decorrido — também chamado *wall-clock time*, que mede o tempo real percebido pelo usuário, incluindo esperas por I/O e rede — foi de **29 minutos e 29 segundos**, com consumo acumulado de **2,1 horas de CPU** (tempo efetivo de processamento somado de todos os núcleos). A Tabela 11 apresenta as métricas detalhadas por etapa.

Tabela 11 – Métricas de desempenho por etapa do pipeline (execução *A. leari*, 25M spots; 50M reads paired-end).

Etapas	Tempo (min)	% da soma	CPU (%)	RAM pico (GB)	I/O leitura	I/O escrita
SRA_PILOT	2,2	6,5%	9%	0,15	7,2 GB	744 MB
SRA_DOWNLOAD	15,7	47,5%	19%	0,10	12,9 GB	31,6 GB
FASTQC	3,6	10,8%	200%	1,10	20,9 GB	3,9 MB
TRIM_GALORE	5,8	17,6%	217%	0,12	83,1 GB	74,8 GB
NOVOPLASTY	2,0	6,1%	101%	6,80	8,6 GB	43 KB
MITOS2	3,8	11,4%	103%	0,47	158 MB	43 MB
Soma das etapas	33,0	100%	—	—	—	—

O valor de 33,0 minutos corresponde à soma das durações individuais registradas no arquivo *trace*; por haver etapas executadas em paralelo, especialmente FASTQC e Trim Galore, ele não deve ser interpretado como tempo real de execução. O tempo *wall-clock* confirmado pelo relatório do Nextflow foi de 29 minutos e 29 segundos.

Figura 17 – Tempo de execução por etapa do pipeline para *A. leari*, com anotação da porcentagem do tempo total e classificação por tipo de operação (I/O-bound vs CPU-bound).



Fonte: Elaborado pelo autor (2026).

A distribuição do tempo por etapa é visualizada na Figura 17 e evidencia que o gargalo dominante é o download do SRA (47,5% da soma das durações registradas), uma etapa limitada pela largura de banda da rede e não pela capacidade computacional local. As etapas de processamento intensivo (Trim Galore e NOVOPlasty) representam, conjuntamente, apenas 24% dessa soma, demonstrando que a montagem de mitogenomas não exige alto poder de processamento quando o volume de dados é adequadamente reduzido pelo Pilot QC.

5.7.1 Gargalo de I/O: Download e Conversão SRA

O download do SRA é o gargalo dominante, consumindo **47,5% da soma das durações registradas** (15,7 minutos). A etapa engloba duas operações sequenciais: `prefetch` (download do arquivo `.sra` comprimido, ~11 GB) e `fastq-dump -X 25000000` (extração direta dos primeiros 25M spots para FASTQ, gerando ~14,8 GB). O volume de escrita de 31,6 GB reportado no *trace* do Nextflow corresponde à soma de todas as gravações em disco realizadas pelos processos da etapa — aproximadamente 11 GB do *cache* local do `.sra` criado pelo `prefetch`, ~14,8 GB dos dois arquivos FASTQ finais (R1 e R2) e ~5,8 GB de buffers e arquivos temporários gerados pelo `fastq-dump` durante a descompressão. Esse total (12,9 GB lidos + 31,6 GB escritos) é ainda significativamente inferior ao que seria produzido pela conversão integral do dataset de 118,5M spots (~87 GB de FASTQ). A adoção do `fastq-dump -X`, que extrai diretamente apenas os spots necessários, evita a gravação desnecessária e reduz tanto o tempo quanto o consumo de armazenamento.

Esse comportamento reforça a importância do módulo Pilot QC, que utiliza `fastq-dump -X 500000` para amostrar apenas os primeiros 500K spots diretamente da origem (sem download completo), consumindo apenas 2,2 minutos e 744 MB. Sem o Pilot, o usuário precisaria decidir arbitrariamente quantos spots extrair, arriscando sub ou superamostragem.

5.7.2 Eficiência do Pré-processamento

O Trim Galore consumiu 5,8 minutos (17,6% da soma das durações registradas), processando 50 milhões de reads (25M pares). A **incidência de adaptador** foi de 81,4% (R1) — ou seja, 81,4% das *reads* contêm pelo menos um nucleotídeo de adaptador detectável, métrica que não deve ser confundida com a fração de bases efetivamente removidas. A remoção de bases por qualidade foi inferior a 1% (37,5 Mbp em R1). Do total de 25M pares, 1.853.399 (7,41%) foram removidos por ficarem abaixo de 50 bp após trimming — indicando dímeros de adaptador. O volume de bases sequenciadas foi reduzido de 7,5 Gbp brutos para 5,39 Gbp filtrados (71,9% de retenção em bases), correspondendo a aproximadamente ~5,4 GB em arquivos FASTQ em disco (cf. Tabela 12). **Cabe distinguir as duas unidades:** Gbp (gigabase pair) mede o conteúdo de informação genética em pares de bases, enquanto GB (gigabyte) mede o tamanho do arquivo no disco; a aproximação numérica entre 5,39 Gbp e 5,4 GB é coincidência decorrente da compressão `gzip` aplicada pelo Trim Galore, que comprime ~2 bytes/base de um FASTQ não comprimido para ~1 byte/base no formato `.fq.gz` — razão pela qual os 5,39 Gbp pós-*trimming* produzem arquivos de ~5,4 GB em vez dos ~10,8 GB que ocupariam se descomprimidos.

Uma questão pertinente é: **o trimming é necessário ou é perda de tempo?** Neste caso, os dados indicam que a etapa foi justificada: com 81,4% das *reads* apresen-

tando adaptador Illumina TruSeq em alguma posição, executar a montagem sem trimming poderia gerar k-mers quiméricos (parte sequência biológica, parte adaptador sintético) e dificultar a extensão correta das sobreposições no algoritmo *seed-and-extend*. Os 5,8 minutos de trimming ($\sim 18\%$ da soma das durações registradas) reduzem o risco de artefatos de montagem que poderiam resultar em falha de circularização ou contigs espúrios. Em contraste, a montagem pós-trimming completou em apenas 2 minutos, com circularização na primeira tentativa (DIERCKXSENS; MARDULYN; SMITS, 2017).

O FASTQC rodou em paralelo com o Trim Galore (ambos consomem os mesmos FASTQs), não adicionando tempo ao caminho crítico. O pico de memória do FASTQC (1,1 GB) é significativo para máquinas com pouca RAM, mas justificável pela geração de relatórios de qualidade essenciais para verificação posterior.

5.7.3 Consumo de Memória do NOVOPlasty

O NOVOPlasty apresentou o maior consumo de memória entre todas as etapas: **6,8 GB de RAM** (pico). Esse consumo é diretamente proporcional ao volume de leituras de entrada: com 25M pares extraídos (23,1M pares após trimming), a construção do *hash* de k-mers em memória resulta em um pico próximo ao limite de computadores com 8 GB de RAM. O NOVOPlasty, escrito em Perl, não possui gerenciamento granular de memória, e o parâmetro `Max memory` (configurado automaticamente como 7 GB com base na RAM disponível) serve apenas como limite superior sugerido, não como restrição efetiva.

A fração “subsampling” de 27,1% reportada no log indica que o NOVOPlasty subamostrou internamente os dados de entrada, processando efetivamente $\sim 3,2$ M reads dos 11,8M disponíveis. Mesmo com essa sub-amostragem, a cobertura final de $176\times$, associada à circularização completa, confere alta confiabilidade à montagem.

Recomendação prática: a execução foi confortável na máquina testada com 16 GB de RAM. Em máquinas com 8 GB, o pipeline tende a ser viável, mas com margem reduzida, pois o pico de 6,8 GB de RAM do NOVOPlasty se aproxima do limite de 7 GB auto-detectado.

5.7.4 Cascata de Redução de Dados

Uma análise particularmente reveladora é a redução progressiva do volume de dados ao longo do pipeline. A Tabela 12 apresenta essa cascata de redução.

Tabela 12 – Cascata de redução de dados ao longo do pipeline.

Etapa	Volume em disco	Fator de redução	Acumulado
SRA completo (118,5M spots)	~87 GB	—	1×
Após <code>fastq-dump -X</code> (25M spots/pares)	~14,8 GB	5,9×	5,9×
Após trimming (23,1M pares)	~5,4 GB	2,7×	16,1×
Montagem circularizada	17 KB	317.000×	~5.100.000×
Summary (todos entregáveis)	1,6 MB	—	~54.000×

O dado original (87 GB de FASTQ bruto) é reduzido em mais de **cinco milhões de vezes** até a montagem final (17 KB). Essa cascata demonstra que a maior parte do sequenciamento WGS é irrelevante para o genoma mitocondrial — apenas 0,17% das reads alinham ao mitogenoma. A existência do Pilot QC como primeira etapa evita o download desnecessário: em vez de baixar os 87 GB completos, o pipeline determina automaticamente que 25M spots/pares (~14,8 GB) são suficientes, extraíndo-os diretamente com `fastq-dump -X` sem necessidade de conversão integral.

O salto mais expressivo ocorre na etapa de montagem, em que o NOVOPlasty seleciona, dentre milhões de leituras, apenas aquelas que pertencem ao genoma mitocondrial — reduzindo 5,4 GB de leituras trimadas a um genoma de 17 KB. Essa redução de mais de cinco milhões de vezes viabiliza a execução completa do pipeline em um notebook com 8 GB de RAM.

5.7.5 Pico de Armazenamento e Custo Computacional

Um aspecto frequentemente negligenciado em pipelines bioinformáticos é o **consumo de armazenamento durante a execução**, que pode ser significativamente maior que o tamanho dos resultados finais. Isso ocorre porque as etapas intermediárias geram arquivos temporários volumosos (FASTQs descomprimidos, arquivos de cache) que são consumidos pelas etapas seguintes e depois descartados.

No caso da execução para *A. leari*, o pico de uso de disco foi de **~16 GB** no diretório de trabalho, dominado pela etapa SRA_DOWNLOAD (~14,8 GB de FASTQs descomprimidos e cache `.sra`). Em contraste, ao final da execução, os resultados úteis ocupam apenas **~67 MB** em `results/`. Os arquivos intermediários podem ser removidos com o comando `nextflow clean`, liberando o espaço ocupado. Essa diferença de ~240× entre o pico de armazenamento e os resultados finais é uma característica importante a considerar ao dimensionar a infraestrutura.

Custo computacional em hardware doméstico. Todo o pipeline foi executado em um notebook pessoal com processador de 4 núcleos físicos (8 *threads* via *hyperthreading*), 16 GB de RAM e disco SSD convencional. Os requisitos computacionais reais observados foram:

- a) **processamento:** 29 minutos e 29 segundos de tempo real (*wall-clock*). O uso máximo simultâneo de CPU ocorreu quando o FASTQC ($\sim 200\%$ de CPU = ~ 2 *threads*) e o Trim Galore ($\sim 217\% = \sim 2,2$ *threads*) executaram em paralelo, totalizando aproximadamente 4 *threads* efetivas. Os demais processos rodam sequencialmente; o NOVOPlasty, processo mais crítico em CPU para a montagem, utiliza apenas 1 *thread* ($\sim 101\%$ de CPU);
- b) **armazenamento:** ~ 16 GB de pico no diretório de trabalho, reduzidos a ~ 67 MB de resultados finais após limpeza dos arquivos temporários. Um disco com pelo menos 30 GB livres é suficiente com margem de segurança;
- c) **memória RAM:** pico observado de 6,8 GB durante a etapa NOVOPlasty. A configuração padrão do pipeline solicita até 12 GB ao Nextflow para essa etapa (parâmetro `memory` declarado no `nextflow.config`), o que torna 16 GB de RAM o requisito recomendado para acomodar com folga o pico de uso, o Docker Engine, o sistema operacional e processos concorrentes. Máquinas com 8 GB de RAM total podem enfrentar limitações ao alocar o container do NOVOPlasty com a configuração padrão;
- d) **rede:** o download do arquivo SRA (~ 11 GB) foi o principal consumidor de banda, com duração variável conforme a velocidade da conexão.

Esses requisitos demonstram que **a montagem e anotação de mitogenomas pode ser realizada sem infraestrutura computacional especializada nas condições testadas**. Um notebook com 4 núcleos, 16 GB de RAM, disco SSD e acesso à internet é suficiente para executar o pipeline completo em cerca de 30 minutos. Essa acessibilidade é particularmente relevante para estudantes e grupos de pesquisa com recursos limitados, que podem reproduzir os resultados deste trabalho sem investimento adicional em servidores ou *clusters*.

5.7.6 Caminho Crítico e Otimização Implementada

O **caminho crítico** de um pipeline — ou seja, a sequência de etapas dependentes que determina o tempo mínimo de execução — é: SRA_PILOT $\rightarrow$ SRA_DOWNLOAD $\rightarrow$ TRIM_GALORE $\rightarrow$ NOVOPLASTY $\rightarrow$ MITOS2 $\rightarrow$ COMPILE_SUMMARY. Etapas que executam em paralelo, como o FASTQC (que processa os mesmos FASTQs que o Trim Galore ao mesmo tempo), **não adicionam tempo ao caminho crítico**, exceto quando excedem a duração da etapa paralela. No caso observado, o FASTQC (3,6 min) completou antes do Trim Galore (5,8 min) e, portanto, não impactou o tempo total.

A análise do caminho crítico revela que **aproximadamente 73% do tempo real de execução** (21,5 de 29,5 min) é consumido por apenas duas etapas: download SRA

(15,7 min) e trimming (5,8 min). A montagem em si — o objetivo central do pipeline — leva apenas 2,0 minutos, demonstrando que o gargalo real não é computacional, mas de transferência e transformação de dados.

A otimização implementada — substituição do `fasterq-dump` + truncamento por `fastq-dump -X`, combinada com a redução automática do volume de spots/pares pelo Pilot QC — é uma decisão arquitetural com impacto direto no desempenho. Sem essa otimização, o pipeline precisaria converter integralmente o arquivo `.sra` de 118,5M spots para FASTQ (~87 GB) antes de truncar, gerando centenas de gigabytes de escrita em disco e aumentando significativamente o tempo de download. Com o `fastq-dump -X`, apenas os 25M pares necessários são extraídos diretamente, reduzindo a escrita em disco para 31,6 GB e o tempo de download para 15,7 min.

5.7.7 Síntese da Análise de Desempenho

A análise de desempenho revelou três conclusões principais sobre o comportamento computacional do pipeline:

O gargalo é I/O, não processamento. Das sete etapas do pipeline, a montagem do mitogenoma — objetivo central do trabalho — consome apenas 2,0 min. O restante é dominado por operações de transferência e transformação de dados: o download SRA é a maior duração individual (15,7 min), seguido pelo trimming (5,8 min). Em termos práticos, isso significa que melhorias na velocidade de rede ou na estratégia de amostragem têm impacto muito maior no tempo total do que otimizações no algoritmo de montagem.

A etapa de trimming justifica seu custo. Apesar de consumir 5,8 minutos, o trimming não é dispensável: 81,4% das *reads* apresentavam adaptadores em alguma posição, que se mantidos, poderiam gerar extensões quiméricas no grafo do NOVOPlasty. Os 5,8 minutos investidos previnem falhas de circularização que exigiriam re-execução completa do pipeline — um custo muito superior.

Sem as estratégias implementadas no pipeline, a montagem de um mitogenoma a partir de dados públicos seria substancialmente menos acessível em hardware doméstico. O dataset original de *A. leari* (SRR28399504) contém 118,5 milhões de spots (pares de leituras), que, quando convertidos para o formato FASTQ, ocupam aproximadamente 87 GB de espaço em disco. Carregar e processar esse volume na íntegra — como seria necessário em uma abordagem manual sem truncamento — exigiria armazenamento temporário elevado (leitura, escrita intermediária e saída), além de memória RAM proporcional ao volume de dados nos estágios de trimming e montagem. Em notebooks convencionais com SSD limitado, essa carga poderia tornar a execução impraticável ou exigir limpeza manual frequente, servidor dedicado ou infraestrutura de computação em nuvem.

O pipeline resolve esse problema por meio de uma cadeia de reduções progressi-

vas que viabilizam a execução em hardware modesto. O **Pilot QC** analisa uma amostra mínima (500 mil spots, ~500 MB) e calcula quantos spots são necessários para atingir a cobertura-alvo, evitando o download do dataset inteiro. O **fastq-dump -X** extrai diretamente apenas os 25 milhões de spots necessários (25M pares; 50M reads paired-end), reduzindo o volume de 87 GB para ~14,8 GB sem necessidade de conversão integral do arquivo SRA. O **trimming** remove adaptadores e bases de baixa qualidade, reduzindo para ~5,4 GB de dados úteis. Finalmente, o **NOVOPlasty** sub-amostra internamente e opera apenas sobre as leituras que alinham à semente, consumindo uma fração do total. O resultado: de 87 GB de dados brutos, o pipeline extrai um mitogenoma de **17 KB** — uma redução de aproximadamente 5 milhões de vezes.

Essa cadeia de decisões é o que torna possível executar o ciclo completo — do dado bruto público ao mitogenoma anotado com 14 categorias de entregáveis — em 29 minutos e 29 segundos, em um notebook com 4 núcleos e 16 GB de RAM, sem recorrer a servidores ou *clusters* especializados. Considerando o pico observado de 6,8 GB de RAM durante o NOVOPlasty e a alocação de 12 GB declarada para essa etapa no **nextflow.config**, **16 GB de RAM é o requisito recomendado** para garantir margem confortável ao Docker, ao sistema operacional e a processos concorrentes. A viabilidade em hardware doméstico é particularmente relevante para estudantes de graduação e pesquisadores em instituições com recursos computacionais limitados, que de outra forma dependeriam de acesso a servidores ou *clusters* para realizar análises genômicas.

5.8 DISCUSSÃO SOBRE A ROBUSTEZ DA ABORDAGEM

A execução bem-sucedida do pipeline para três espécies distintas — duas aves congêneres (Psittaciformes) e um peixe (Perciformes) —, utilizando datasets de plataformas diferentes (HiSeq X Ten, NovaSeq X Plus e NovaSeq X) e tipos de dados distintos (WGS e metagenômico), demonstra a generalização da abordagem. A obtenção de genomas circularizados em todos os casos, com o conjunto completo de 37 genes identificados nos casos anotados, valida tanto o fluxo de montagem quanto a integração de ferramentas.

A cobertura de 176× obtida para *A. leari* a partir de apenas 0,17% de leituras mitocondriais entre as efetivamente carregadas pelo NOVOPlasty (19.906 *reads* alinhados de 11.842.862 processados, somando R1 e R2) demonstra que o DNA mitocondrial é eficientemente recuperado mesmo quando representa uma fração diminuta do total de dados, confirmando as observações da literatura (DIERCKXSENS; MARDULYN; SMITS, 2017).

A combinação metodológica adotada neste trabalho — NOVOPlasty para montagem e MITOS2 para anotação — alinha-se a ferramentas amplamente empregadas na literatura recente de genômica mitocondrial, ainda que combinadas com diferentes alternativas em cada estudo. O NOVOPlasty é uma ferramenta consolidada para montagem

de organelas a partir de leituras curtas (DIERCKXSENS; MARDULYN; SMITS, 2017). O MITOS, por sua vez, é adotado de forma recorrente para anotação em táxons distintos, incluindo lagartos (ZHAN et al., 2024), peixes (KUNDU et al., 2024), moluscos (TAO et al., 2024) e insetos (SHI et al., 2024). Essa convergência independente em torno do MITOS — com grupos de pesquisa de diferentes países e táxons adotando a mesma ferramenta de anotação — constitui validação externa da escolha implementada no pipeline e reforça a confiabilidade das decisões de projeto.

A lógica iterativa de montagem com re-seeding automático e múltiplos k-mers mostrou-se eficaz, circularizando na primeira tentativa (k-mer 39) para *A. leari*, na primeira tentativa (k-mer 33) para *D. bifasciatus* e na primeira tentativa (k-mer 39) para *A. hyacinthinus*. Essa robustez é particularmente relevante para cenários em que a *seed* disponível é de uma espécie distante, ou quando regiões repetitivas dificultam a circularização.

O módulo Pilot QC foi validado por meio da execução do script `pilot_qc.sh` sobre uma subamostra de 500.000 spots de *A. leari*, extraída do dataset SRR28399504. A análise piloto detectou qualidade Q30 de 86,5%, taxa de adaptador de 66,4% e fração mitocondrial estimada de 0,050% (via correspondência de k-mers com a semente *cox1*, com piso conservador aplicado pelo script). Decompondo o cálculo: a partir de 28.333 reads mitocondriais necessários (para $500\times$ de cobertura em ~ 17 kb), os fatores de qualidade ($F_{Q30} = 1,156$) e de adaptador ($F_{adapter} = 1,249$) inflam para 40.908 reads ajustados — contribuição modesta de $\sim 40\%$. O fator dominante é o divisor pela fração mitocondrial: $40.908/0,0005 = 81,8$ milhões de reads, que com a margem de segurança de $1,5\times$ resulta em 122,7 milhões. **É essa diluição extrema do mtDNA na biblioteca WGS — e não a qualidade Q30, que está boa — que faz o cálculo ultrapassar o teto.** A recomendação final é limitada a 25 milhões de spots (25M pares; 50M reads paired-end) pelo *cap* configurado no script, resultado coerente com os $176\times$ de cobertura efetivamente obtidos na execução principal. Como o perfil `a_leari` não define o parâmetro `sra_max_reads`, o Pilot QC é executado automaticamente a cada *run* desse perfil, dispensando intervenção manual para estimar o volume adequado de dados a baixar. Esse comportamento é útil principalmente em cenários onde não se dispõe de estimativa prévia da fração mitocondrial do dataset — como em espécies cuja proporção de mtDNA na biblioteca de sequenciamento ainda não foi reportada na literatura.

Em comparação com os trabalhos relacionados, o pipeline desenvolvido apresenta vantagens claras em termos de reprodutibilidade, portabilidade e acessibilidade computacional. Enquanto o MitoHiFi (ULIANO-SILVA et al., 2023) utiliza Conda para gerenciamento de dependências, sujeito a variações de ambiente, e o MITObim (HAHN; BACHMANN; CHEVREUX, 2013) e o GetOrganelle (JIN et al., 2020) dependem de configuração manual, o pipeline aqui proposto encapsula todas as ferramentas em containers Docker com versões fixadas e orquestra sua execução via Nextflow, favorecendo resul-

tados consistentes em diferentes ambientes. Adicionalmente, as soluções existentes não incorporam mecanismos de redução automática do volume de dados, pressupondo que o usuário disponha de infraestrutura com armazenamento e memória suficientes para processar datasets completos — requisito que pode limitar seu uso em computadores pessoais. O pipeline aqui proposto, ao integrar o Pilot QC e a extração seletiva com `fastq-dump -X`, reduz essa barreira e permite que o ciclo completo — do dado bruto ao mitogenoma anotado — seja executado em um notebook convencional. A adição da Fase 2 (anotação funcional com MITOS2 e geração automática de entregáveis em formato GenBank) vai além do que a maioria dos pipelines de montagem de organelas oferece, cobrindo o ciclo completo desde o dado bruto até a submissão ao banco de dados.

Os resultados metodológicos apresentados neste capítulo demonstram que o pipeline é funcional, eficiente e acessível.


5.8.1 Análise Comparativa Quantitativa: Radar de Desempenho

Para complementar a comparação qualitativa apresentada anteriormente, a Figura 18 apresenta uma visualização em gráfico radar que sintetiza o desempenho relativo de cada ferramenta em cinco eixos qualitativos, pontuados em escala de 1 a 5 conforme os critérios da Tabela 13. Essa pontuação foi atribuída com base nas informações publicadas nos artigos originais de cada ferramenta e na análise direta da documentação e dos repositórios oficiais.

Tabela 13 – Critérios de pontuação do gráfico radar comparativo (escala 1–5).

Eixo	Critério de pontuação
Reprodutibilidade	Nível de isolamento do ambiente: 1 = instalação manual; 2 = Conda; 3 = Conda + versões fixadas; 4 = Docker ou Singularity; 5 = Docker + <i>workflow manager</i> com versões fixadas
Compleitude do fluxo	Número de etapas cobertas: 1 = apenas montagem; 2 = montagem + anotação parcial; 3 = montagem + anotação completa; 4 = inclui visualização ou conversão de formatos; 5 = fluxo completo (aquisição → montagem → anotação → entregáveis GenBank)
Acessibilidade computacional	Requisitos de hardware: 1 = requer cluster/HPC; 2 = servidor dedicado recomendado; 3 = desktop padrão; 4 = desktop com dados reduzidos manualmente; 5 = notebook com redução automática de dados
Automação	Grau de intervenção do usuário: 1 = configuração manual extensiva; 2 = scripts isolados; 3 = pipeline com parâmetros manuais; 4 = pipeline com defaults razoáveis; 5 = execução com um único comando + decisões automáticas (Pilot QC, fallback k-mer)
Generalidade taxonômica	Escopo de organismos: 1 = uma espécie (e.g., humano); 2 = um grupo taxonômico restrito; 3 = metazoários; 4 = metazoários + outros eucariotos; 5 = qualquer organismo com genoma mitocondrial

Figura 18 – Gráfico radar comparando as ferramentas analisadas em cinco eixos: completude do fluxo, reprodutibilidade, acessibilidade computacional, automação e generalidade taxonômica. A pontuação de cada eixo segue os critérios da Tabela 13.



Fonte: Elaborado pelo autor (2026).

Conforme ilustrado na Figura 18, o pipeline proposto neste trabalho (representado em vermelho) apresenta maior pontuação em quatro dos cinco eixos avaliados — reprodutibilidade, completude do fluxo, automação e acessibilidade computacional —, atingindo a pontuação máxima (5) em cada um deles, enquanto as demais ferramentas concentram-se predominantemente na faixa de 1 a 3. O competidor mais próximo varia

conforme o eixo considerado: o MitoHiFi alcança 4 em automação, o MToolBox atinge 3 em completude, e o GetOrganelle e o NOVOPlasty obtêm 4 em generalidade taxonômica — justamente o único eixo em que este trabalho não lidera, com pontuação 3 (escopo restrito a metazoários). Essa diferença, contudo, decorre de uma escolha deliberada de projeto: ao concentrar o pipeline em genomas mitocondriais de metazoários, foi possível otimizar cada etapa — do Pilot QC à geração do GenBank Flat File — para esse grupo taxonômico, em vez de buscar uma generalidade que diluísse a profundidade do fluxo. O padrão visual resultante sugere que, enquanto as demais ferramentas formam polígonos compactos e irregulares no interior do gráfico, o pipeline proposto projeta-se de forma ampla em quase todos os eixos, evidenciando graficamente sua proposta de integração, reprodutibilidade e acessibilidade.

5.9 VALIDAÇÃO CRUZADA COM *ANODORHYNCHUS HYACINTHINUS*

A terceira execução do pipeline constituiu um teste de **validação cruzada**: a montagem do mitogenoma de *A. hyacinthinus* a partir de um dataset metagenômico (SRR36400750), utilizando como semente o gene *cox1* extraído da montagem de *A. leari* — inversamente ao que foi feito na execução principal, em que a semente de *A. leari* veio de *A. hyacinthinus*. Essa configuração recíproca permite avaliar o comportamento do pipeline com sementes de espécies congêneres em ambas as direções, e a existência de um mitogenoma de referência depositado no GenBank (OR209186.1, 16.999 bp) viabiliza comparação quantitativa nucleotídeo a nucleotídeo.

5.9.1 Desafio: Dataset Metagenômico de Grande Escala

O dataset SRR36400750 apresenta dois desafios adicionais em relação às execuções anteriores. Primeiro, o **volume**: 145,8 milhões de spots (291,7M reads), totalizando 44 Gbases — o maior dataset processado pelo pipeline. Segundo, a **natureza metagenômica**: o DNA foi extraído de fluido pericárdico da ave, contendo uma mistura de DNA do hospedeiro, DNA bacteriano e potencialmente DNA viral, o que implica uma fração mitocondrial ainda menor do que em dados WGS convencionais. Esse cenário testa a capacidade do NOVOPlasty de isolar e montar o genoma mitocondrial a partir de um fundo genômico complexo e heterogêneo.

A execução revelou uma limitação importante no módulo de download original do pipeline, que utilizava **fasterq-dump** para converter o arquivo **.sra** integralmente para FASTQ antes de truncar com **head**. Para um dataset de 145,8M spots, essa abordagem gerava ~124 GB de arquivos FASTQ intermediários — excedendo o armazenamento disponível. O problema foi corrigido pela adoção de **fastq-dump -X** quando o parâmetro

`sra_max_reads` está definido, que extrai diretamente apenas os primeiros N spots do arquivo `.sra` sem necessidade de gravação integral (Seção 5.9.3).

5.9.2 Comparação com a Referência NCBI

A montagem pelo NOVOPlasty produziu um genoma circularizado de **16.999 bp** — *tamanho idêntico* à referência OR209186.1 — com cobertura média de **144×**, a partir de 16.238 *reads* alinhadas (0,14% das 11.708.434 leituras processadas após *trimming*) e 11.060 efetivamente montadas. O *insert size* medido pelo NOVOPlasty foi de 223 bp (parâmetro inicial: 300 bp), valor próximo ao observado para *A. leari* (210 bp) e consistente com o padrão de bibliotecas Illumina de insertos curtos. A comparação nucleotídeo a nucleotídeo requereu o alinhamento por rotação, uma vez que o mitogenoma é circular e o NOVOPlasty inicia a linearização em uma posição arbitrária determinada pela semente. A montagem obtida inicia na posição 15.572 da referência NCBI, correspondente à região de controle (D-loop), enquanto a sequência de referência inicia no tRNA-Phe — refletindo convenções distintas de linearização. A Tabela 14 apresenta os resultados da comparação.

Tabela 14 – Comparação nucleotídeo a nucleotídeo entre a montagem do pipeline e a referência NCBI para *A. hyacinthinus*.

Métrica	Nossa Montagem	Referência NCBI (OR209186.1)
Tamanho total	16.999 bp	16.999 bp
Coordenada inicial	Posição 15.572 (D-loop)	Posição 1 (tRNA-Phe)
Diferença de tamanho		0 bp
Offset de rotação		15.571 bp
<i>Comparação posição a posição (após alinhamento por rotação):</i>		
Bases idênticas	16.979 / 16.999	(99,882%)
Mismatches reais (incompatíveis)		19
Diferenças por ambiguidade (compatíveis)		1
Identidade efetiva (excluindo ambiguidades)	16.980 / 16.999	(99,888%)


Das 19 diferenças nucleotídicas observadas, 11 concentram-se na região de controle (D-loop, posições 15.572–16.999 da referência) — a região mais variável do genoma mitocondrial, onde a taxa de mutação é sabidamente 2–5 vezes superior às regiões codificantes (AQUADRO; GREENBERG, 1983). As 8 diferenças restantes distribuem-se ao longo dos ~15 kb de genes codificantes e são predominantemente transições ($A \leftrightarrow G$ ou $C \leftrightarrow T$), padrão consistente com **variação intraespecífica** entre indivíduos distintos da mesma espécie, e não com erros de montagem. A única diferença por ambiguidade (NCBI=T, montagem=Y na posição 15.730) indica incerteza de sequenciamento na referência original.

Esse resultado — 99,888% de identidade com uma referência independente, com diferenças concentradas na região hipervariável e consistentes com polimorfismo intraes-

pecífico — constitui uma **validação quantitativa forte do pipeline**: a montagem de novo a partir de dados metagenômicos reproduz, nucleotídeo a nucleotídeo, uma sequência obtida por outro grupo de pesquisa com metodologia, amostras e plataformas distintas.

Figura 19 – Mapa circular de polimorfismos de *A. hyacinthinus* (montagem vs. referência NCBI OR209186.1). Círculos vermelhos indicam SNPs na D-loop (11/19) e azuis em regiões codificantes (8/19). O triângulo amarelo (≈ 15.730) destaca a única ambiguidade detectada (NCBI=T, montagem=Y). A concentração de variantes na D-loop é consistente com a elevada taxa evolutiva característica dessa região.

Mapa circular do mitogenoma: montagem do pipeline vs. referência NCBI



Fonte: Elaborado pelo autor (2026).

A Figura 19 apresenta a distribuição espacial dos polimorfismos ao longo do mito-

genoma. Nela, o anel externo representa os genes do mitogenoma, coloridos por complexo funcional, enquanto o anel interno exibe a posição de cada polimorfismo detectado. A assimetria na distribuição dos SNPs é visualmente evidente: os 11 marcadores vermelhos (D-loop) agrupam-se em um arco restrito correspondente a menos de 10% do genoma, enquanto os 8 marcadores azuis (genes codificantes e rRNAs) distribuem-se ao longo dos ~90% restantes. Em meio ao arco vermelho da D-loop, é possível identificar o único **triângulo amarelo** (posição ≈ 15.730), distinto pela forma triangular em contraste com os círculos vermelhos e azuis: ele assinala a posição em que a referência NCBI apresenta o código de ambiguidade T enquanto a montagem reporta Y, compatível com incerteza de sequenciamento residual na sequência original. Essa concentração na região de controle é biologicamente esperada: a D-loop não codifica proteínas nem RNAs funcionais e, portanto, está sujeita a menor pressão seletiva purificadora, acumulando mutações a uma taxa 2–5 vezes superior às regiões codificantes (AQUADRO; GREENBERG, 1983). A presença de apenas 8 SNPs dispersos em ~15 kb de sequência codificante — todos transições (A $\leftrightarrow$ G ou C $\leftrightarrow$ T) compatíveis com polimorfismo intraespecífico — confirma que essas diferenças refletem variação natural entre indivíduos e não artefatos de montagem.

5.9.3 Otimização do Módulo de Download para Datasets de Grande Escala

A execução com o dataset metagenômico de 145,8M spots revelou um gargalo no módulo `SRA_DOWNLOAD`: o `fasterq-dump`, embora mais rápido que o `fastq-dump` por ser multi-thread, não oferece opção nativa para limitar o número de spots extraídos. A abordagem anterior — extrair todo o dataset e truncar com `head` — era viável para datasets de 118,5M spots (~87 GB de FASTQ), mas impraticável para 145,8M spots (~124 GB), que excediam o armazenamento disponível.

A solução implementada utiliza condicionalmente o `fastq-dump` com a flag `-X` (`maxSpotId`) quando `sra_max_reads` está definido, extraindo diretamente apenas os primeiros N spots do arquivo `.sra`. Embora o `fastq-dump` seja single-thread, a redução do volume processado (25M spots vs. 145,8M) compensa amplamente a perda de paralelismo: a extração processa apenas 17% dos dados, com uso de disco proporcional (~14–15 GB de FASTQ, cerca de ~7 GB por arquivo/mate, em vez de ~124 GB). Quando `sra_max_reads` não está definido (i.e., sem limite), o pipeline continua utilizando o `fasterq-dump` multi-thread para máximo desempenho. Essa otimização é especialmente relevante para datasets metagenômicos de grande escala, cada vez mais comuns em repositórios públicos.

5.9.4 Significado da Validação Cruzada

A execução com *A. hyacinthinus* valida o pipeline em três dimensões complementares:

- a) **correção biológica:** a montagem reproduz uma referência independente com 99,888% de identidade, com diferenças explicáveis por variação natural;
- b) **robustez operacional:** o pipeline processa com sucesso um dataset metagenômico de grande escala (145,8M spots), demonstrando capacidade de isolar o genoma mitocondrial de um fundo genômico complexo;
- c) **reciprocidade de sementes:** a semente de *A. leari* funciona para montar *A. hyacinthinus* (e vice-versa), validando a estratégia de uso de sementes congêneres quando a espécie-alvo não possui sequência de referência própria.

O capítulo seguinte dedica-se integralmente à espécie-alvo deste trabalho — *A. leari* —, explorando em profundidade o mitogenoma obtido, sua organização gênica e as implicações para a conservação da espécie.

6 O MITOGENOMA DA ARARA-AZUL-DE-LEAR

Este capítulo apresenta a caracterização biológica completa do mitogenoma da arara-azul-de-lear (*Anodorhynchus leari*), montado e anotado pelo pipeline descrito nos capítulos anteriores. A análise abrange a contextualização da espécie, a composição nucleotídica, os genes codificadores de proteínas, os RNAs transportadores e ribossomais, a organização gênica comparada e as implicações para a conservação.

6.1 A ESPÉCIE

Anodorhynchus leari (Bonaparte, 1856) é um psitacídeo de grande porte endêmico do bioma Caatinga, no nordeste do Brasil. Pertencente à ordem Psittaciformes, família Psittacidae, gênero *Anodorhynchus*, a espécie compartilha o gênero com apenas duas outras araras: a arara-azul-grande (*A. hyacinthinus*) e a provavelmente extinta arara-azul-pequena (*A. glaucus*) (COLLAR, 1997). A descoberta formal da espécie para a ciência ocorreu em 1856, mas sua área de ocorrência em vida livre só foi localizada por Helmut Sick em 1978, no Raso da Catarina, norte do estado da Bahia (SICK; TEIXEIRA, 1980).

A distribuição geográfica de *A. leari* é extremamente restrita. A espécie ocorre em uma área de aproximadamente 1.500 km² no semiárido baiano, com núcleos populacionais concentrados nas regiões de Toca Velha e Serra Branca, nos municípios de Canudos, Jeremoabo e Euclides da Cunha (ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022). Os indivíduos nidificam em paredões de arenito, onde escavam cavidades para reprodução, e se alimentam predominantemente de frutos de palmeira licuri (*Syagrus coronata*), estabelecendo uma relação ecológica de forte dependência (SICK; TEIXEIRA, 1980; ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022).

A população em vida livre foi estimada em 2.273 indivíduos no censo simultâneo conduzido em 2022 pelo CEMAVE/ICMBio — 2.254 no Raso da Catarina (BA) e 19 no Boqueirão da Onça (FAVORETTO, 2022) —, representando uma recuperação significativa em relação aos cerca de 200 indivíduos registrados na década de 1980 (SICK; TEIXEIRA, 1980; ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022). A espécie é classificada como **Em Perigo** (EN) pela União Internacional para a Conservação da Natureza (IUCN) e consta no Plano de Ação Nacional para a Conservação da Arara-azul-de-lear (PAN Arara-azul-de-lear) (ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022).

As principais ameaças à sobrevivência da espécie incluem: (i) o tráfico ilegal de filhotes para o comércio de animais de estimação, historicamente a pressão mais severa, com indivíduos alcançando valores extremamente elevados no mercado internacional (ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022); (ii) a degradação e fragmentação do habitat, particularmente pela remoção de palmeiras licuri para extração de cera e uso da terra para pecuária; (iii) a baixa variabilidade genética resultante do gargalo populacional histórico, que aumenta a vulnerabilidade a doenças e reduz a capacidade adaptativa; e (iv) a área de distribuição extremamente restrita, que torna a espécie vulnerável a eventos estocásticos como secas prolongadas ou **epizootias** (surto de doenças infecciosas que acometem populações animais, análogos a epidemias em humanos) (ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022).

Neste contexto, a genômica de conservação utiliza dados moleculares para subsidiar decisões de manejo de espécies ameaçadas, como a avaliação da diversidade genética remanescente, a identificação de unidades evolutivamente significativas e o desenvolvimento de marcadores para identificação forense de espécimes apreendidos do tráfico. O sequenciamento do mitogenoma completo de *A. leari* representa uma contribuição direta para esse campo.

A Figura 20 ilustra a distribuição geográfica da espécie, evidenciando o caráter extremamente restrito de sua ocorrência na região semiárida do nordeste brasileiro.

Figura 20 – Mapa da distribuição geográfica de *Anodorhynchus leari* no nordeste do Brasil. Em roxo: área de ocorrência durante o ano todo; em amarelo: registros em passagem.



Fonte: Adaptado de Cephas (2022) (CC BY-SA 4.0), com base em BirdLife International / IUCN Red List (2020).

A Figura 21 apresenta um exemplar da espécie fotografado em seu habitat natural

no município de Canudos, Bahia.

Figura 21 – *Anodorhynchus leari* fotografada em seu ambiente natural em Canudos, Bahia, Brasil.



Fonte: Quental (2014) (CC BY 2.0), via Wikimedia Commons.

6.2 CARACTERIZAÇÃO GERAL DO MITOGENOMA

O mitogenoma de *A. leari* possui 16.986 pares de bases (bp) e topologia circular, conforme esperado para genomas mitocondriais de metazoários (BOORE, 1999). O genoma contém 37 genes — 13 genes codificadores de proteínas (CDS), 22 genes de RNA transportador (tRNA), 2 genes de RNA ribossomal (rRNA) — além da região controle (D-loop).

A composição nucleotídica do mitogenoma é apresentada na Tabela 15.

Tabela 15 – Composição nucleotídica do mitogenoma de *A. leari*.

Base	Quantidade	Proporção (%)
A	5.153	30,3
T	3.978	23,4
G	2.373	14,0
C	5.474	32,2
Ambíguas IUPAC (M/R/Y)	8	0,05
Total	16.986	100,0

O conteúdo GC do mitogenoma é de 46,2%. A sequência contém oito posições ambíguas IUPAC (M/R/Y); por isso, os índices de assimetria abaixo foram calculados apenas com bases não ambíguas. Em mitogenomas, o DNA de fita dupla circular possui duas fitas historicamente denominadas **fita pesada** (H-strand, do inglês *heavy*) e **fita leve** (L-strand, *light*), nomenclatura baseada na diferença de densidade observada em ultracentrifugação. A assimetria composicional entre as fitas é quantificada por duas métricas: o **AT-skew**, calculado como $(A - T)/(A + T)$, e o **GC-skew**, calculado como $(G - C)/(G + C)$. Os índices de assimetria composicional refletem o viés de fita (*strand bias*) característico de genomas mitocondriais:

- a) **AT-skew** = $\frac{A-T}{A+T} = \frac{5.153-3.978}{5.153+3.978} = +0,129$ (predominância de adenina sobre timina no *strand* depositado);
- b) **GC-skew** = $\frac{G-C}{G+C} = \frac{2.373-5.474}{2.373+5.474} = -0,395$ (predominância de citosina sobre guanina no mesmo *strand*).

Esses valores são compatíveis com o viés de fita característico de genomas mitocondriais. A exposição diferencial das fitas durante a replicação está associada a taxas distintas de substituição entre classes de bases, produzindo padrões recorrentes de AT-skew e GC-skew (BOORE, 1999).

A comparação dos índices de assimetria com outras espécies analisadas na literatura demonstra a consistência desses padrões. A raia *Potamotrygon leopoldi* apresenta AT-skew de +0,13 e GC-skew de -0,40 (GUERREIRO et al., 2025), valores praticamente idênticos aos de *A. leari*. Já espécies filogeneticamente mais distantes exibem variações: o peixe *Cephalopholis taeniops* (garoupa africana) apresenta AT-skew de +0,052 e GC-skew de -0,277 (KUNDU et al., 2024), enquanto o anuro *Dryophytes japonicus* (hilídeo) apresenta AT-skew de -0,001 e GC-skew de -0,273 (HONG et al., 2024). A semelhança entre *A. leari* e *P. leopoldi* indica que padrões semelhantes de assimetria composicional podem ocorrer em linhagens evolutivamente distantes.


O conteúdo gênico do mitogenoma é sumarizado na Tabela 16.

Tabela 16 – Conteúdo gênico do mitogenoma de *A. leari*.

Categoria	Quantidade	Detalhes
CDS	13	ND1–6, ND4L, COX1–3, ATP6, ATP8, CYTB
tRNA	22	Um por aminoácido; leucina e serina possuem dois isoceptores cada
rRNA	2	12S rRNA (rrnS, 970 bp) e 16S rRNA (rrnL, 1.572 bp)
Segmentos D-loop/OH	2	OH_0 (262 bp) e OH_1 (47 bp)

Figura 22 – Mapa circular do mitogenoma de *A. leari* (16.986 bp), com a posição dos 37 genes coloridos por categoria funcional. Gerado automaticamente pelo pipeline via Biopython GenomeDiagram.

Mapa circular do mitogenoma da arara-azul-de-lear (*Anodorhynchus leari*)



Fonte: Elaborado pelo autor (2026).

A região controle (D-loop) é uma região não codificante que contém os promotores para replicação e transcrição do DNA mitocondrial (BOORE, 1999). Por não sofrer as mesmas pressões seletivas que os genes codificadores, apresenta a maior taxa de variação entre todas as regiões do mitogenoma, sendo particularmente útil para estudos de diversidade genética intrapopulacional.

A Figura 22 apresenta o mapa circular completo do mitogenoma de *A. leari*, gerado automaticamente pelo pipeline. Neste mapa circular, os genes codificadores de proteínas (azul), tRNAs (verde) e rRNAs (vermelho) estão distribuídos ao longo de toda a molécula de 16.986 bp. A maioria dos genes é transcrita a partir da fita pesada (anel externo), com exceção do gene ND6 e de oito tRNAs, transcritos pela fita leve (anel interno). A região controle (D-loop), próxima à transição circular entre tRNA-Glu e tRNA-Phe, aparece como o segmento não codificante de tamanho mais significativo, consistente com o padrão conservado em Psittaciformes.

6.3 GENES CODIFICADORES DE PROTEÍNAS

O mitogenoma de *A. leari* codifica 13 genes de proteínas, correspondentes a subunidades de quatro dos cinco complexos da **cadeia respiratória mitocondrial** — a sequência de cinco grandes complexos proteicos (numerados I a V) localizados na membrana interna da mitocôndria, responsáveis por converter a energia dos alimentos em ATP por meio da fosforilação oxidativa:

- a) **Complexo I** (NADH desidrogenase): ND1, ND2, ND3, ND4, ND4L, ND5, ND6 — sete subunidades;
- b) **Complexo III** (citocromo *b*): CYTB — uma subunidade;
- c) **Complexo IV** (citocromo *c* oxidase): COX1, COX2, COX3 — três subunidades;
- d) **Complexo V** (ATP sintase): ATP6, ATP8 — duas subunidades.

O Complexo II (succinato desidrogenase) é ausente em todos os genomas mitocondriais de metazoários, sendo codificado exclusivamente pelo genoma nuclear (BOORE, 1999). Dos 13 genes, 12 são codificados na fita pesada (H-strand), enquanto o ND6 é o único gene codificador na fita leve (L-strand) — padrão universal em mitogenomas aviários (DESJARDINS; MORAIS, 1990).

A Tabela 17 apresenta os códons de início e parada, bem como os tamanhos de cada gene codificador.

Tabela 17 – Códonos de início e parada dos genes codificadores de proteínas de *A. leari*.

Gene	Início	Parada	Tamanho (bp)	Tamanho (aa)
ND1	ATG	TA(+A)	974	324
ND2	ATA	TAA	1.041	347
COX1	GTG	AGG	1.548	516
COX2	ATG	TAA	684	228
ATP8	ATG	TAA	168	56
ATP6	ATG	TAA	684	228
COX3	ATG	T(+AA)	784	261
ND4L	ATG	TAA	297	99
ND4	ATG	T(+AA)	1.378	459
ND5	ATA	TAA	1.809	603
CYTB	ATG	TAA	1.140	380
ND6	ATG	TAG	513	171
ND3	ATA	<i>ver nota</i>	348*	116*

* O ND3 é anotado como CDS com `join()` e `/exception="ribosomal slippage"`; por isso, o campo de parada não deve ser interpretado como um códon de parada convencional (ver Seção 6.3.3).

Três padrões são observados nos códonos dos genes codificadores:

(i) O códon de início ATG é o mais frequente, utilizado por 9 dos 13 genes. Os códonos alternativos ATA (ND2, ND5, ND3) e GTG (COX1) são aceitos no código genético mitocondrial de vertebrados. As mitocôndrias utilizam um código genético ligeiramente diferente do padrão universal: ATA codifica metionina (em vez de isoleucina), TGA codifica triptofano (em vez de parada), e AGA/AGG funcionam como códonos de parada (em vez de arginina) (ANDERSON et al., 1981; BOORE, 1999). Esse código corresponde à Tabela 2 do NCBI (*Vertebrate Mitochondrial Code*).

(ii) Três genes (ND1, COX3 e ND4) apresentam códonos de parada incompletos, terminando em “TA” ou “T”. Esse fenômeno é consequência do processamento do mRNA policistrônico mitocondrial: a clivagem pós-transcricional do transcrito primário, seguida de poliadenilação, completa o códon de parada TAA pela adição de resíduos de adenina na extremidade 3’ do mRNA (ANDERSON et al., 1981).

(iii) O gene ND6, único na fita leve, utiliza o códon de parada TAG, distinto do padrão TAA predominante nos demais genes.

6.3.1 Análise Ka/Ks

A razão Ka/Ks (também denominada dN/dS) é a razão entre substituições não sinônimas (K_a , que alteram o aminoácido) e substituições sinônimas (K_s , silenciosas). Valores de Ka/Ks < 1 indicam seleção purificadora (pressão para manter a sequência

proteica), $Ka/Ks > 1$ indica seleção positiva (favorecimento de mudanças), e $Ka/Ks = 1$ indica evolução neutra.

Um padrão consistente emerge da literatura: nos estudos consultados, os PCGs mitocondriais geralmente apresentam $Ka/Ks < 1$, abrangendo répteis, peixes, moluscos e insetos (ZHAN et al., 2024; GUERREIRO et al., 2025; SHI et al., 2024; KUNDU et al., 2024; ZHOU et al., 2024; TAO et al., 2024). O gene COX1 tende a figurar entre os mais conservados, refletindo as restrições funcionais severas sobre a subunidade catalítica do Complexo IV. Em contraste, ATP8 frequentemente aparece entre os genes mais variáveis, compatível com seu pequeno tamanho e menor número de sítios funcionalmente críticos. Em Planorbidae (caramujos), Tao et al. (2024) reportaram $Ka/Ks > 1$ para ATP8 em alguns gêneros, sugerindo seleção positiva pontual.

Para *A. leari*, a conservação de COX1 é evidenciada pela alta identidade com *A. hyacinthinus*, mas o cálculo formal de Ka/Ks requer alinhamentos múltiplos de cada gene em pelo menos três sequências congêneres ou de gêneros próximos. No caso do gênero *Anodorhynchus*, a análise idealmente incluiria as três espécies conhecidas — *A. leari*, *A. hyacinthinus* e *A. glaucus*, esta última provavelmente extinta e sem mitogenoma de referência publicado —, eventualmente complementadas por grupos externos de gêneros próximos como *Cyanopsitta* ou *Ara*, e a aplicação de modelos de códon como os implementados no *codeml*/PAML (YANG, 2007). Como apenas dois mitogenomas completos do gênero estão atualmente disponíveis (*A. leari*, obtido neste trabalho, e *A. hyacinthinus*, NC_082165.1), uma análise robusta de seleção exige a obtenção prévia dos demais mitogenomas — esforço que constitui projeto autônomo, fora do escopo deste TCC, mas viabilizado pelo pipeline aqui apresentado.

6.3.2 Uso de Códon (RSCU)

O *Relative Synonymous Codon Usage* (RSCU) quantifica a preferência entre códonos sinônimos para um mesmo aminoácido. Em genomas mitocondriais, há um viés sistemático em favor de códonos com adenina ou timina na terceira posição. Shi et al. (2024) demonstraram que esse viés é direcionado por seleção natural, e não apenas por pressão mutacional. O padrão é menos extremo em vertebrados, porém detectável (KUNDU et al., 2024; GUERREIRO et al., 2025). A construção da tabela de RSCU para *A. leari* é matematicamente direta a partir da sequência codificante anotada, porém seu valor científico depende de comparações com amostras representativas de Psittaciformes para identificar singularidades versus padrões compartilhados na ordem. Como a maior parte dessas análises comparativas requer mitogenomas adicionais ainda não disponíveis no GenBank para parentes próximos, optou-se por delimitar este TCC à caracterização estrutural e funcional do mitogenoma — objeto direto da pergunta de pesquisa —, mantendo a análise comparativa de uso de códonos como desdobramento natural em trabalhos futuros que

combinem este mitogenoma a outros que venham a ser depositados.

6.3.3 O *Frameshift* do ND3: Uma Assinatura Evolutiva Conservada

O gene ND3 apresenta uma característica incomum compartilhada por aves, tartarugas e crocodilianos: um *frameshift* (mudança de quadro de leitura) que divide o gene em dois quadros abertos de leitura (ORFs) sobrepostos.

6.3.3.1 Descoberta

O *frameshift* do ND3 foi identificado por Mindell, Sorenson e Dimcheff (1998) em 46 espécies de aves, uma tartaruga (*Chrysemys picta*) e um jacaré (*Alligator mississippiensis*). Após o nucleotídeo 174 a partir do códon de início, uma inserção de um único nucleotídeo desloca o quadro de leitura em +1. Isso divide o gene em dois ORFs: o primeiro codifica 58 aminoácidos (posições 1–174) e o segundo codifica também 58 aminoácidos no quadro deslocado. O MITOS2 anotou essa estrutura como **nad3_0** (174 bp) e **nad3_1** (180 bp) com sobreposição de 5 bp no sítio de deslizamento — resultado plenamente consistente com a literatura.

6.3.3.2 Mecanismo Molecular

Duas hipóteses explicam como a proteína ND3 funcional é traduzida apesar da mudança de quadro de leitura:

- a) ***programmed +1 ribosomal frameshifting (+1 PRF)***: o ribossomo desliza um nucleotídeo adiante (+1) no sítio de *frameshift*, continuando a tradução no novo quadro de leitura. Esse mecanismo difere do −1 PRF descrito em retrovírus como o HIV-1 (JACKS et al., 1988), em que sequências escorregadias (*slippery sequences*) do tipo X_XXY_YYH e pseudonós a jusante induzem o deslizamento reverso (BRIERLEY, 1995; ATKINS et al., 2016). No +1 PRF, a pausa ribossomal ocorre pela escassez de tRNAs raros complementares ao códon no sítio A, favorecendo cineticamente o deslizamento para frente (HARGER; MESKAUSKAS; DINMAN, 2002);
- b) **edição pós-transcricional do mRNA**: o nucleotídeo extra é removido por edição do mRNA antes da tradução, restaurando o quadro de leitura original. Evidências para esse mecanismo foram obtidas em estudos de cDNA de tartarugas (RUSSELL; BECKENBACH, 2008).

Ambos os mecanismos podem coexistir como redundância funcional, garantindo a produção da proteína ND3 funcional.

6.3.3.3 Distribuição Taxonômica

O *frameshift* do ND3 está presente em aves, tartarugas e crocodilianos. Russell e Beckenbach (2008) ampliaram esse panorama ao sequenciar o mitogenoma da tartaruga *Trachemys scripta* e discutir evidências adicionais em quelônios (grupo que reúne tartarugas marinhas, cágados de água doce e jabutis terrestres), mostrando que esses animais exibem uma diversidade incomum de eventos de recodificação mitocondrial. No conjunto de evidências reunido pelos autores, mutações de *frameshift* já haviam sido documentadas em seis sítios separados, distribuídos em três genes diferentes, sendo que o sítio N3-174 é amplo em aves e tartarugas, enquanto vários outros parecem restritos a linhagens particulares e provavelmente recentes. Além disso, os autores identificaram em *Chelodina parkeri* (tartaruga-de-pescoço-de-cobra-de-Parker, cágado de água doce endêmico da Papua-Nova Guiné) um caso aparente de redefinição de códon, indicando que o sistema de tradução mitocondrial de tartarugas, cágados e jabutis tolera não apenas *frameshifting*, mas também recodificação de códons. Esse padrão sugere que o *frameshifting* não exerce um papel regulatório geral, mas pode ser tolerado em contextos específicos de sequência por um sistema traducional permissivo (RUSSELL; BECKENBACH, 2008).

O *frameshift* está ausente em mamíferos, anfíbios e na maioria dos peixes. A distribuição relatada em aves, tartarugas e crocodilianos sugere que o evento é antigo nesses grupos, embora a inferência exata sobre sua origem filogenética dependa de amostragem taxonômica mais ampla (MINDELL; SORENSON; DIMCHEFF, 1998; RUSSELL; BECKENBACH, 2008). A conservação do padrão em aves indica que o mecanismo de **recodificação traducional** (seja por *frameshifting* ribossomal programado, edição pós-transcricional do mRNA ou ambos) é evolutivamente estável: a inserção de um nucleotídeo que provocaria normalmente a interrupção da tradução é recodificada de forma confiável em centenas de espécies de aves analisadas (MINDELL; SORENSON; DIMCHEFF, 1998; RUSSELL; BECKENBACH, 2008), demonstrando que a maquinaria traducional mitocondrial dessas linhagens é robusta o suficiente para sustentar a produção de ND3 funcional independentemente do quadro de leitura aparentemente disruptivo na sequência de DNA.

Figura 23 – Diagrama esquemático do *frameshift* do gene ND3: a inserção de um nucleotídeo na posição 174 desloca o quadro de leitura em +1, dividindo o gene em dois ORFs (nad3_0 e nad3_1).

Frameshift programado (+1) do gene ND3 — mecanismo

1. Sem o salto, a leitura sai do quadro correto

O gene ND3 tem um nucleotídeo "extra" na posição 175.
Lendo a sequência linearmente, todos os codons após esse ponto saem errados.

nucleotídeo "extra" (pos 175)

166	169	172	175	178	181	184	187														
T	T	C	T	T	C	C	T	C	A	G	T	A	G	C	C	A	T	C	C	T	A
TTC → F			TTC → F			CTC → L			AGT → S			AGC → S			CAT → H			CCT → P			

→ Resultado:

A partir da posição 175, todos os codons saem deslocados (S, S, H, P...) ao invés do correto (V, A, I, L...). Proteína não-funcional.

2. O ribossomo dá um salto de +1 e mantém o quadro correto

O deslizamento ribossomal programado (+1 PRF) faz o ribossomo pular o nucleotídeo da posição 175. Os codons voltam ao quadro biologicamente correto.

+1 slip

166	169	172	175	178	181	184	187														
T	T	C	T	T	C	C	T	C	A	G	T	A	G	C	C	A	T	C	C	T	A
TTC → F			TTC → F			CTC → L			GTA → V			GCC → A			ATC → I			CTA → L			

→ Resultado:

Após o slip, os codons voltam ao quadro correto (V, A, I, L...).
Mecanismo conservado em aves, tartarugas e crocodilianos (~250 Ma; Mindell et al., 1998).

Sequência: ND3 de *A. leari* (este trabalho), gene pos 166-187. Código genético mitocondrial de vertebrados (transl_table=2).

Fonte: Elaborado pelo autor (2026).

6.3.3.4 Resultado em *A. leari*

O MITOS2 detectou automaticamente o *frameshift* como `nad3_0 + nad3_1`, consistente com a anotação de *A. hyacinthinus* (NC_082165.1), onde o ND3 é anotado como:

```
CDS    join(9504..9677,9679..9854)
      /gene="ND3"
```

O script `gff2genbank.py` do pipeline utiliza `join()` com o qualificador `/exception="ribosomal slippage"`, conforme as diretrizes do NCBI para submissão ao GenBank. Quando o código genético configurado é o vertebrado mitocondrial (`transl_table=2`), as coordenadas reportadas com sobreposição pelo MITOS2 são automaticamente ajustadas para o *skip* canônico de 1 nucleotídeo (gap de uma base entre os exons), padrão de representação adotado pelo GenBank para o *frameshift* do ND3 em aves, tartarugas e crocodilianos.

6.4 RNAS TRANSPORTADORES E RIBOSSOMAIS

O mitogenoma de *A. leari* contém 22 genes de tRNA, codificando transportadores para os 20 aminoácidos padrão. Dois aminoácidos — leucina e serina — possuem dois tRNAs cada, chamados **isoaceptores** (tRNAs diferentes que carregam o mesmo aminoácido, mas reconhecem códonos distintos): tRNA-Leu(UUR) e tRNA-Leu(CUN); tRNA-Ser(UCN) e tRNA-Ser(AGY). As siglas entre parênteses indicam os códonos reconhecidos por cada isoaceptor. Essa configuração com 22 tRNAs é universal em mitogenomas de metazoários. Dos 22 tRNAs, 14 são codificados na fita pesada e 8 na fita leve.

A Tabela 18 apresenta as características de cada tRNA, ordenados pela posição na sequência circular do mitogenoma (coluna #). A coluna **Fita** indica em qual das duas fitas o gene é codificado: H (*heavy*, fita pesada) ou L (*light*, fita leve); as linhas estão coloridas de acordo com a fita correspondente. As demais colunas apresentam o tamanho, o **anticódon** — a trinca de nucleotídeos no tRNA que se parecia com o códon correspondente no mRNA durante a tradução — e o aminoácido transportado. Os anticódonos são apresentados na direção 5'→3' da molécula de tRNA; por serem complementares, leem-se na direção oposta ao códon do mRNA.

Tabela 18 – Genes de tRNA do mitogenoma de *A. leari*. As linhas em azul claro correspondem a tRNAs codificados na fita pesada (H, 14 genes) e as linhas em laranja claro a tRNAs codificados na fita leve (L, 8 genes).

#	Fita	tRNA	Tamanho (bp)	Anticódon	Aminoácido
1	H	tRNA-Phe	67	GAA	Fenilalanina
2	H	tRNA-Val	69	TAC	Valina

Tabela 18 – Genes de tRNA do mitogenoma de *A. leari* (continuação).


#	Fita	tRNA	Tamanho (bp)	Anticódon	Aminoácido
3	H	tRNA-Leu(UUR)	74	TAA	Leucina
4	H	tRNA-Ile	71	GAT	Isoleucina
5	L	tRNA-Gln	70	TTG	Glutamina
6	H	tRNA-Met	68	CAT	Metionina
7	H	tRNA-Trp	70	TCA	Triptofano
8	L	tRNA-Ala	68	TGC	Alanina
9	L	tRNA-Asn	73	GTT	Asparagina
10	L	tRNA-Cys	66	GCA	Cisteína
11	L	tRNA-Tyr	70	GTA	Tirosina
12	L	tRNA-Ser(UCN)	75	TGA	Serina
13	H	tRNA-Asp	68	GTC	Aspartato
14	H	tRNA-Lys	68	TTT	Lisina
15	H	tRNA-Gly	68	TCC	Glicina
16	H	tRNA-Arg	69	TCG	Arginina
17	H	tRNA-His	68	GTG	Histidina
18	H	tRNA-Ser(AGY)	65	GCT	Serina
19	H	tRNA-Leu(CUN)	70	TAG	Leucina
20	H	tRNA-Thr	67	TGT	Treonina
21	L	tRNA-Pro	68	TGG	Prolina
22	L	tRNA-Glu	68	TTC	Glutamato

Os tRNAs mitocondriais variam de 65 a 75 bp (média de 69 bp). Todos apresentam a **estrutura secundária canônica em trevo** (*cloverleaf*), exibida na Figura 24 e visualizável também em contexto genômico no mapa circular da Figura 22 (anel verde). Essas estruturas foram preditas por RNAplot/ViennaRNA (LORENZ et al., 2011) a partir dos modelos de covariância do MITOS2. Nessa conformação, a molécula de tRNA dobra-se sobre si mesma formando quatro “braços” que lembram uma folha de trevo: o **braço aceptor** (onde o aminoácido se liga covalentemente à extremidade 3’ da molécula), o **braço do anticódon** (que reconhece o códon do mRNA), o **braço TΨC** — cujo nome deriva da tríade conservada de nucleotídeos modificados **T** (ribotimidina, derivada da metilação de uracila), **Ψ** (pseudouridina, isômero estrutural da uridina) e **C** (citidina) presente em sua alça, envolvido na interação com o ribossomo — e o **braço DHU** (nomeado pela presença de diidrouridina, um nucleotídeo modificado, e envolvido na estabilidade estrutural).

Uma exceção notável é o tRNA-Ser(AGY), que carece do braço DHU, adotando uma conformação simplificada em formato “D”. Essa anomalia estrutural não é uma peculiaridade de *A. leari* nem das aves em geral: trata-se de uma característica amplamente

observada em metazoários (BOORE, 1999). Entre os estudos recentes consultados neste trabalho que descrevem explicitamente a estrutura secundária dos tRNAs mitocondriais, a ausência do braço DHU no tRNA-Ser(AGY) (também denominado trnS1) é reportada em moluscos bivalves (LI et al., 2023), afídeos (SHI et al., 2024), caramujos planorbídeos (TAO et al., 2024) e teleósteos (KUNDU et al., 2024), abrangendo linhagens divergentes de metazoários. Essa recorrência indica que a ausência do braço DHU não implica disfunção ou erro de anotação. A presença desse padrão no mitogenoma de *A. leari* corrobora a integridade da anotação realizada pelo pipeline.

Figura 24 – Estruturas secundárias em trevo dos 22 tRNAs e 2 rRNAs do mitogenoma de *A. leari*, preditas pelo MITOS2/RNAPlot. O tRNA-Ser(AGY) carece do braço DHU, conformação amplamente observada em metazoários.



Fonte: Elaborado pelo autor (2026).

O mitogenoma contém dois genes de rRNA: o 12S (rrnS, 970 bp) e o 16S (rrnL, 1.572 bp), localizados entre os genes tRNA-Phe e tRNA-Leu(UUR), separados pelo tRNA-Val. Essa organização é compatível com o padrão conservado em mitogenomas de vertebrados (BOORE, 1999). Os ribossomos mitocondriais (mitorribossomos) possuem coeficiente de sedimentação de 55S, com a subunidade menor (28S) contendo o rRNA 12S e a subunidade maior (39S) contendo o rRNA 16S (ANDERSON et al., 1981).

6.5 ORGANIZAÇÃO GÊNICA E COMPARAÇÃO COM *A. HYACINTHINUS*

A ordem gênica do mitogenoma de *A. leari* segue o padrão neognata (*standard avian gene order*), descrito por Desjardins e Morais (1990):

D-loop — trnF — rrnS — trnV — rrnL — trnL2 — nad1 — trnI — trnQ⁽⁻⁾ — trnM — nad2 — trnW — trnA⁽⁻⁾ — trnN⁽⁻⁾ — trnC⁽⁻⁾ — trnY⁽⁻⁾ — cox1 — trnS2⁽⁻⁾ — trnD — cox2 — trnK — atp8 — atp6 — cox3 — trnG — nad3 — trnR — nad4l — nad4 — trnH — trnS1 — trnL1 — nad5 — cob — trnT — trnP⁽⁻⁾ — nad6⁽⁻⁾ — trnE⁽⁻⁾ — D-loop

onde o sobrescrito ⁽⁻⁾ indica genes codificados na fita leve (L-strand).

A comparação direta com o congênere *A. hyacinthinus* (NC_082165.1, 16.999 bp) é apresentada na Tabela 19.

Tabela 19 – Comparação entre os mitogenomas de *A. leari* e *A. hyacinthinus*.

Característica	<i>A. leari</i>	<i>A. hyacinthinus</i>
Tamanho total	16.986 bp	16.999 bp
Diferença	—	Δ 13 bp
CDS	13	13
tRNAs	22	22
rRNAs	2	2
Ordem gênica	Padrão aviário	Padrão aviário
<i>Frameshift</i> ND3	Presente	Presente
CDS na fita L	ND6	ND6

A diferença de tamanho de apenas 13 bp (~0,08%) entre os dois mitogenomas é compatível com alta similaridade estrutural entre as espécies, mas não deve ser interpretada como divergência nucleotídica total. A proximidade filogenética do gênero *Anodorhynchus* é consistente com estimativas de separação no Plioceno (TAVARES et al., 2006). Os mitogenomas são sintênicos — apresentam a mesma organização estrutural, sem rearranjos detectáveis.

A alta similaridade entre os dois congêneres possui implicações diretas para a conservação. Ye et al. (2024) demonstraram que o gene COX1 isoladamente é insuficiente para discriminar espécies proximamente relacionadas de tubarões do gênero *Scoliodon*, sendo necessária a análise de múltiplos genes ou do mitogenoma completo. Essa observação é relevante para *Anodorhynchus*: dada a alta similaridade estrutural entre *A. leari* e *A. hyacinthinus*, marcadores conservados como COX1 e CYTB podem não ser suficientes para discriminação forense sem validação empírica específica.



6.5.1 O D-loop como Marcador Diferencial

A região controle (D-loop) apresenta a maior variação inter e intraespecífica no mitogenoma. Em tubarões *Scoliodon*, Ye et al. (2024) demonstraram a utilidade dessa região para discriminação interespecífica. Em raias *Potamotrygon*, Guerreiro et al. (2025) identificaram repetições em tandem na região controle, enquanto em afídeos, Shi et al. (2024) observaram variação geográfica no comprimento do D-loop (650–1.109 bp). A comparação detalhada dos D-loops de *A. leari* e *A. hyacinthinus* — incluindo domínios conservados (*Conserved Central Domains*, CCDs), blocos de sequência conservados (*Conserved Sequence Blocks*, CSBs) e repetições em tandem — constitui uma perspectiva futura estratégica para a identificação de marcadores forenses diferenciadores entre as duas espécies.

A Figura 25 apresenta o diagrama de sintenia dos dois mitogenomas, evidenciando a conservação da ordem e do tamanho dos genes ao longo de toda a molécula. O painel inferior destaca, em escala, a diferença de 81 bp na região controle total (D-loop), concentrada principalmente no segmento OH₀ (65 bp dos 81). Curiosamente, embora *A. leari* possua um D-loop 81 bp **maior** que o de *A. hyacinthinus*, o seu genoma total é 13 bp **menor** (16.986 *vs.* 16.999 bp): isso implica que as demais regiões do mitogenoma de *A. leari* são, somadas, 94 bp menores que as de *A. hyacinthinus*, compensando a expansão do D-loop. Em outras palavras, a variação de tamanho está fortemente concentrada na região controle, enquanto os genes codificadores, tRNAs e rRNAs permanecem altamente conservados em comprimento.

especies. O painel inferior compara o D-loop (*OH₀*) das duas espécies em escala, evidenciando uma diferença de 61 bp na região controle total, concentrada principalmente no segmento *OH₀* (65 bp dos 81).

Diagrama de Sintenia — Mitogenomas de Anodorhynchus



6.6 PERSPECTIVAS PARA A GENÉTICA DE CONSERVAÇÃO

A disponibilidade do mitogenoma completo de *A. leari* não constitui, por si só, um instrumento de conservação: trata-se de um insumo molecular que, articulado a estudos posteriores envolvendo amostras populacionais, análises comparativas e protocolos de campo, pode subsidiar aplicações em três frentes complementares discutidas a seguir — identificação forense, avaliação de diversidade genética e filogeografia. Cada uma dessas aplicações é apresentada como **linha de investigação viabilizada** pela montagem aqui obtida, não como resultado conclusivo deste TCC.

Antes de discutir essas aplicações, é necessário definir os conceitos fundamentais da genética de conservação empregados nesta análise:

- a) **haplótipo**: variante genética definida por mutações específicas, compartilhada por um grupo de indivíduos que a herdou de um ancestral comum. No DNA mitocondrial, cada haplótipo representa uma linhagem materna distinta;
- b) **diversidade nucleotídica** (π): proporção média de nucleotídeos diferentes entre dois indivíduos de uma mesma população. Valores baixos indicam baixa variação genética, típica de populações que sofreram gargalos populacionais;
- c) **depressão endogâmica** (*inbreeding depression*): redução da aptidão biológica (*fitness*) — sobrevivência, fertilidade, resistência a doenças — causada pelo acúmulo de **alelos** (variantes alternativas de um mesmo gene) deletérios recessivos quando indivíduos aparentados se reproduzem entre si — situação inevitável em populações muito pequenas;
- d) **filogeografia**: disciplina que estuda a distribuição geográfica de linhagens genéticas (haplótipos) dentro de uma espécie ou grupo de espécies, buscando reconstruir os processos históricos (glaciações, fragmentação de habitat, dispersão) que moldaram essa distribuição;
- e) **relógio molecular**: estimativa de tempos de divergência entre espécies com base na taxa de acúmulo de mutações ao longo do tempo;
- f) **especiação**: processo pelo qual uma população ancestral se divide em espécies distintas, reprodutivamente isoladas.

6.6.1 Identificação Forense

O tráfico ilegal de filhotes constitui uma das principais ameaças a *A. leari*. Um paralelo pode ser traçado com a raia de água doce *Potamotrygon leopoldi* (GUERREIRO et al., 2025), cujo mitogenoma de 17.504 bp revelou sinais de seleção positiva nos genes

ND1, ND4, ND5, COX1 e COX2, associados à adaptação ao ambiente de água doce. Esse estudo demonstra como o mitogenoma completo permite investigar não apenas identidade taxonômica, mas também processos adaptativos — uma possibilidade que se abre para *A. leari* em relação às pressões ambientais do semiárido baiano.

O mitogenoma completo viabiliza a criação de marcadores de **código de barras de DNA** (*DNA barcoding*) — técnica que utiliza uma sequência curta e padronizada de DNA como identificador taxonômico, de forma análoga a um código de barras comercial (HEBERT et al., 2003). O conceito de DNA barcoding surgiu como resposta ao progressivo declínio da expertise taxonômica tradicional: conforme argumentam Hebert et al. (2003), a capacidade de identificação biológica baseada em morfologia está em colapso, e a única perspectiva sustentável para uma capacidade de identificação em larga escala reside na construção de sistemas que empreguem sequências de DNA como “códigos de barras” de táxons, sendo o gene COI (citocromo *c* oxidase I) o núcleo de um sistema global de bioidentificação para animais. Os genes COX1 (1.548 bp) e CYTB (1.140 bp) representam a primeira abordagem para laboratórios forenses. Todavia, o COX1 isoladamente é insuficiente para espécies proximamente relacionadas (YE et al., 2024). Modelos de aprendizado de máquina (*Random Forest*, SVM, MLP) poderiam ser testados, em estudos futuros, com os 13 genes codificadores ou combinações de marcadores para avaliar a discriminação entre *A. leari* e *A. hyacinthinus* em amostras como ovos, penas, tecidos ou indivíduos em cativeiro.

6.6.2 Avaliação de Diversidade Genética

A população de *A. leari* sofreu um severo gargalo demográfico entre as décadas de 1970 e 1990, quando foi reduzida a aproximadamente 200 indivíduos (SICK; TEIXEIRA, 1980; ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022). Gargalos dessa magnitude reduzem drasticamente a variabilidade genética, aumentando a vulnerabilidade a doenças e a depressão endogâmica. A sequência mitocondrial completa permite o sequenciamento da região D-loop de múltiplos indivíduos para estimar o número de haplótipos circulantes, a diversidade nucleotídica (π) e o grau de **estruturação genética** (diferenciação entre subpopulações que trocam poucos migrantes) entre os núcleos de Toca Velha e Serra Branca. Esses dados constituem insumos diretos para o Plano de Ação Nacional (ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade, 2022) e para decisões de manejo, como translocações entre populações e programas de reprodução em cativeiro.

6.6.3 Filogeografia e Evolução do Gênero

O mitogenoma completo possibilita **análises filogenéticas** robustas — reconstruções das relações de parentesco evolutivo entre espécies, representadas em diagramas

ramificados chamados árvores filogenéticas —, baseadas em múltiplos genes simultaneamente, dentro de Psittaciformes. Em conjunto com sequências de outros Psittaciformes e **calibrações externas** apropriadas, esse recurso pode contribuir para estimar tempos de divergência. Calibrar um relógio molecular significa converter a quantidade de mutações acumuladas em ramos de uma árvore filogenética para um eixo temporal absoluto (em milhões de anos), o que requer pontos de ancoragem externos: tipicamente, datações de fósseis atribuídos com segurança a um clado, idades de eventos biogeográficos (como a formação de istmos ou separações continentais) ou taxas de substituição previamente publicadas para grupos próximos. Sem essas âncoras, a filogenia indica apenas relações topológicas (quem é parente mais próximo de quem), e não permite afirmar há quanto tempo essas separações ocorreram. Aplicada a *Anodorhynchus*, essa abordagem viabiliza estimativas de quando as três espécies do gênero (*A. leari*, *A. hyacinthinus* e a provavelmente extinta *A. glaucus*) divergiram, complementando a inferência morfológica de Tavares et al. (2006) sobre a separação dessas linhagens no Plioceno, e permitindo compreender a **biogeografia histórica** — o estudo de como eventos geológicos e climáticos do passado moldaram a distribuição atual das espécies — e os processos de especiação na Caatinga.

6.6.4 Aplicabilidade a Outras Espécies Ameaçadas

Embora as três aplicações discutidas anteriormente refiram-se especificamente a *A. leari*, a contribuição do pipeline transcende esse caso particular. Por ser agnóstico ao táxon dentro de metazoários e exigir apenas um identificador SRA e uma sequência de *cox1* de espécie congênere ou próxima, o mesmo fluxo pode ser aplicado a outras espécies ameaçadas brasileiras cujos mitogenomas permaneçam não publicados ou subutilizados na literatura, desde que existam dados públicos adequados e uma semente mitocondrial compatível. Exemplos potenciais incluem outras aves ameaçadas, tartarugas marinhas, mamíferos aquáticos e anfíbios endêmicos com dados de sequenciamento disponíveis em repositórios públicos. A combinação entre o crescimento exponencial de depósitos no SRA e o custo decrescente do sequenciamento WGS configura uma janela de oportunidade ampla para que esforços de genômica de conservação se beneficiem diretamente da infraestrutura proposta neste trabalho, sem necessidade de adaptações de código.

6.7 DISPONIBILIDADE DOS DADOS

Os dados gerados neste trabalho estão disponíveis nos seguintes formatos:

- a) **GenBank Flat File** (*A_leari.gbk*): formato padrão do NCBI, pronto para submissão. Contém todos os 37 genes anotados, com `join()` e `/exception="ribosomal`

`slippage`" para o *frameshift* do ND3;

- b) **Feature Table** (`A_leari.tbl`) e **FASTA formatado** (`A_leari.fsa`): para processamento pela ferramenta `table2asn` do NCBI;
- c) **repositório GitHub**: todo o código-fonte — Dockerfiles, módulos Nextflow, scripts de análise e configurações de perfil — está disponível publicamente para reprodutibilidade completa;
- d) **imagens Docker no GHCR**: as cinco imagens dos containers utilizados pelo pipeline (SRA-Toolkit, FastQC, Trim Galore, NOVOPlasty e MITOS2) estão publicadas no *GitHub Container Registry* (`ghcr.io/matheus-sobreira/mitogenome-pipeline`), com tag de versão 1.0 explícita, garantindo que a infraestrutura computacional referenciada no `nextflow.config` permaneça obtível e idêntica ao longo do tempo.


A disponibilidade pública contribui para a democratização do acesso à bioinformática, permitindo que outros grupos de pesquisa reproduzam as análises ou apliquem o pipeline a outras espécies — aves, peixes, invertebrados ou qualquer metazoário — necessitando apenas de um acesso SRA e uma sequência-semente de gene mitocondrial. A generalização do pipeline foi verificada pela execução bem-sucedida em dois táxons distintos (Psittaciformes e Perciformes), reforçando a aderência aos princípios FAIR (*Findable, Accessible, Interoperable, and Reusable*) discutidos na Seção 2.2: os artefatos do pipeline (containers Docker versionados, módulos Nextflow, scripts e configurações) são encontráveis e acessíveis publicamente no repositório, interoperáveis por usarem formatos abertos padronizados (FASTQ, FASTA, GFF3, GenBank) e reutilizáveis sem adaptação de código para outros táxons de metazoários.

7 CONSIDERAÇÕES FINAIS

Este capítulo reúne as considerações finais sobre o trabalho desenvolvido, destacando as principais contribuições, as limitações identificadas e as perspectivas para trabalhos futuros. O objetivo central — propor e implementar um pipeline de bioinformática para montagem e anotação automatizada de mitogenomas, com aplicação a *Anodorhynchus leari* — foi atingido em todas as suas dimensões: técnica, biológica e de reprodutibilidade.

A Figura 26 sintetiza o percurso completo do trabalho desenvolvido, desde os dados brutos até os entregáveis finais.

Figura 26 – Infográfico-resumo do trabalho: do problema inicial (87 GB de dados brutos), passando pelas 7 etapas do pipeline, até o resultado final (16.986 bp circularizado, 37 genes, GenBank-ready) e as 6 contribuições originais. A validação cruzada com *A. hyacinthinus* (99,888% de identidade com a referência NCBI) reforça a confiabilidade da abordagem.



Fonte: Elaborado pelo autor (2026).

Conforme representado na Figura 26, o pipeline transforma 87 GB de dados brutos de sequenciamento em um mitogenoma anotado de 16.986 bp contendo 37 genes, por meio de sete etapas automatizadas. O infográfico destaca as seis contribuições originais deste trabalho: a integração completa do fluxo analítico, a containerização com Docker, a orquestração via Nextflow, o módulo Pilot QC para redução automática de dados, a geração de entregáveis em formato GenBank e a viabilidade de execução em hardware doméstico.

O presente trabalho teve como objetivo propor e implementar um pipeline de bioinformática voltado à montagem e anotação funcional de genomas mitocondriais, concebido segundo princípios de automação, reprodutibilidade, ciência aberta e acessibilidade computacional. A integração de ferramentas consolidadas — SRA-Toolkit (LEINONEN; SUGAWARA; SHUMWAY, 2011), FastQC (ANDREWS, 2010), Trim Galore (Babraham Bioinformatics, 2019) com Cutadapt (MARTIN, 2011), NOVOPlasty (DIERCKXSENS; MARDULYN; SMITS, 2017), MITOS2 (DONATH et al., 2019), ViennaRNA (LORENZ et al., 2011) e Biopython (COCK et al., 2009) — em um fluxo containerizado (Docker) e orquestrado por meio do Nextflow (Di Tommaso et al., 2017) constitui a principal contribuição metodológica desta proposta, ao oferecer uma solução transparente, portátil e replicável para análises genômicas.

Um resultado particularmente significativo deste trabalho é a demonstração de que a montagem e anotação completa de mitogenomas a partir de dados públicos é viável em hardware doméstico. O dataset original utilizado totaliza 87 GB de leituras brutas — volume que, sem as estratégias de redução implementadas, exigiria centenas de gigabytes de armazenamento temporário e servidores dedicados. A cadeia de reduções progressivas incorporada ao pipeline (Pilot QC, extração seletiva com `fastq-dump -X, trimming`) reduz esse volume em aproximadamente 5 milhões de vezes, viabilizando a execução em notebook com 16 GB de RAM em cerca de 30 minutos. Essa acessibilidade é especialmente relevante para estudantes, pesquisadores iniciantes e instituições com recursos computacionais limitados, que anteriormente dependeriam de acesso a servidores ou *clusters* para realizar análises genômicas equivalentes.

Do ponto de vista biológico, o pipeline foi aplicado com sucesso a três espécies: *A. leari* (16.986 bp circularizado, 176× de cobertura, 37 genes), a espécie de validação *Diploprion bifasciatus* (circularizado) e a arara-azul-grande (*A. hyacinthinus*, 16.999 bp circularizado a partir de dados metagenômicos, com 144× de cobertura). Esta última execução fornece uma validação quantitativa do pipeline: a montagem *de novo* reproduziu a referência NCBI (OR209186.1) com 99,888% de identidade nucleotídica, com as 19 diferenças concentradas na região hipervariável (D-loop) e consistentes com polimorfismo intraespecífico. A reciprocidade de sementes — *A. leari* montada com semente de *A. hyacinthinus* e vice-versa — valida a estratégia de uso de sequências congêneres quando a espécie-alvo não possui referência própria. Conforme detalhado no Capítulo 6, a caracteri-

zação completa do mitogenoma de *A. leari* revelou composição nucleotídica, organização gênica e assinaturas moleculares (como o *frameshift* do ND3) consistentes com a espécie congênere *A. hyacinthinus*, confirmando a qualidade da montagem e a aplicabilidade dos dados para estudos de conservação, identificação forense e filogeografia.

Dentre as contribuições originais do pipeline, destacam-se:

- a) o módulo **Pilot QC** — contribuição original deste trabalho, não identificada nas ferramentas comparadas no Capítulo 3 —, que determina automaticamente o volume de dados necessário para atingir a **cobertura desejada**, entendida como o número médio de vezes em que cada posição do mitogenoma é representada por leituras (tipicamente $\geq 30\times$ para mitogenomas circulares, conforme prática consolidada na literatura), evitando o processamento de centenas de gigabytes desnecessários e viabilizando a execução em computadores com armazenamento limitado;
- b) a cadeia de reduções progressivas ($\text{Pilot QC} \rightarrow \text{fastq-dump -X} \rightarrow \text{trimming}$) que transforma 87 GB de dados brutos em um mitogenoma de 17 KB, reduzindo a dependência de servidores dedicados nas condições testadas;
- c) a lógica iterativa de montagem com *re-seeding* automático e múltiplos *k-mers*;
- d) a geração automática de estruturas secundárias de tRNAs e rRNAs via RNAplot/-ViennaRNA, funcionalidade não disponibilizada como entregável automático nas demais ferramentas analisadas no Capítulo 3;
- e) a conversão automática para GenBank Flat File com tratamento canônico do *frameshift* do ND3 (ajuste automático para *skip* de 1 nucleotídeo em vertebrados, conforme a convenção adotada pelo NCBI para aves, tartarugas e crocodilianos); e
- f) a compilação automática de 14 categorias de entregáveis em pasta organizada.

Uma consequência direta dessas contribuições é que o impacto deste trabalho ultrapassa o caso particular de *A. leari*. Por ser agnóstico ao táxon dentro de metazoários, o pipeline constitui uma plataforma reutilizável para a genômica de conservação em escala: o mesmo fluxo pode ser adaptado a diferentes espécies com dados adequados no SRA e uma semente mitocondrial compatível. Exemplos potenciais incluem outras aves ameaçadas, tartarugas marinhas, mamíferos aquáticos e anfíbios endêmicos com dados de sequenciamento disponíveis em repositórios públicos. Em um cenário em que muitos datasets públicos de espécies ameaçadas ou de interesse conservacionista permanecem subutilizados, disponibilizar uma infraestrutura reprodutível e executável em hardware doméstico transforma a viabilidade prática desses estudos — e é, possivelmente, o legado mais escalável deste TCC.

Apesar de seu potencial, algumas limitações precisam ser reconhecidas. O sucesso da montagem depende da qualidade da *seed* inicial e da profundidade de cobertura dos dados de sequenciamento. A anotação do MITOS2, embora automatizada, pode requerer curadoria manual em casos de estruturas gênicas atípicas (como o *frameshift* do ND3). Adicionalmente, o tamanho das imagens Docker pode representar uma barreira em ambientes com espaço de armazenamento limitado.

Como perspectivas futuras, propõem-se:

- a) a submissão do mitogenoma de *A. leari* ao GenBank;
- b) a integração de análises filogenéticas automáticas ao pipeline (MAFFT + RAxML/IQ-TREE);
- c) a geração automática de tabelas de RSCU (*Relative Synonymous Codon Usage*) e de razão Ka/Ks para análise de pressão seletiva sobre os genes codificadores — análises que se tornaram padrão em estudos recentes de genômica mitocondrial (ZHAN et al., 2024; KUNDU et al., 2024; SHI et al., 2024);
- d) a integração de tRNAscan-SE como módulo opcional de verificação dos tRNAs preditos pelo MITOS2, seguindo a prática metodológica adotada em estudos recentes (KUNDU et al., 2024; SHI et al., 2024);
- e) a geração de gráficos de sintenia comparativa entre espécies congêneres;
- f) a avaliação da adequação do pipeline aos padrões do nf-core como possível recurso comunitário;
- g) a implementação de uma **Fase 3 do pipeline dedicada à chamada de variantes** (SNPs e INDELs) e à detecção de heteroplasmia, mediante o alinhamento das leituras pré-processadas contra o mitogenoma montado (com *bwa-mem* ou *minimap2*) seguido de chamada de variantes (com *bcftools* ou *GATK HaplotypeCaller*), produzindo um arquivo **VCF** como entregável adicional. Essa fase abriria caminho para aplicações em genética de populações — estimativa de diversidade nucleotídica (π) entre múltiplos indivíduos de *A. leari*, identificação de linhagens maternas e quantificação de heteroplasmia em tecidos distintos — fechando o ciclo *aquisição* → *montagem* → *anotação* → *análise comparativa* previsto na introdução; e
- h) o **refinamento da fórmula do Pilot QC**: nos três estudos de caso a recomendação saturou no teto de 25 milhões de pares, comportamento decorrente da combinação entre o piso conservador de $f_{mito} = 0,05\%$ e o regime de WGS de vertebrados (em que a fração mitocondrial real situa-se tipicamente abaixo desse piso). Uma reformulação que inverta a pergunta da fórmula — estimar a cobertura esperada para um dado orçamento N , em vez de exigir cobertura-alvo fixa — aliada a uma calibração

empírica baseada em *A. leari* e *A. hyacinthinus* permitiria recomendações discriminativas em datasets intermediários, reduzindo o volume baixado sem comprometer a confiabilidade da montagem.

Em síntese, o pipeline desenvolvido representa uma contribuição metodológica significativa para a bioinformática de organelas, ao unir rigor técnico, aplicabilidade biológica e boas práticas de reprodutibilidade computacional. Mais do que atender a um caso de estudo específico, constitui um recurso com potencial de ser reutilizado, adaptado e expandido por diferentes grupos de pesquisa, colaborando para a consolidação de uma ciência mais transparente, padronizada e sustentável.

REFERÊNCIAS

- ALBERTS, B. et al. *Molecular Biology of the Cell*. 7. ed. New York: W.W. Norton, 2022.
- ANDERSON, S. et al. Sequence and organization of the human mitochondrial genome. *Nature*, v. 290, p. 457–465, 1981.
- AQUADRO, C. F.; GREENBERG, B. D. Human mitochondrial DNA variation and evolution: analysis of nucleotide sequences from seven individuals. *Genetics*, v. 103, n. 2, p. 287–312, 1983.
- ARAÚJO, H. F. P. et al. *Anodorhynchus leari*. Sistema de Avaliação do Risco de Extinção da Biodiversidade — SALVE. Instituto Chico Mendes de Conservação da Biodiversidade — ICMBio, 2023. Disponível em: <<https://salve.icmbio.gov.br>>. DOI: 10.37002/salve.ficha.12161. Acesso em: 30 abr. 2026.
- FAVORETTO, G. *População da arara-azul-de-lear é estimada em 2.273 aves*. Fauna News, out. 2022. Reportagem sobre o censo simultâneo conduzido pelo CEMAVE/ICMBio em agosto de 2022 no Raso da Catarina (BA) e no Boqueirão da Onça (BA). Disponível em: <<https://faunanews.com.br/populacao-da-arara-azul-de-lear-e-estimada-em-2-273-aves/>>. Acesso em: 30 abr. 2026.
- ANDREWS, S. *FastQC: a quality control tool for high throughput sequence data*. 2010. Disponível em: <<https://www.bioinformatics.babraham.ac.uk/projects/fastqc/>>. Acesso em: 31 ago. 2025.
- ASAKAWA, S. et al. Nucleotide sequence and gene organization of the starfish *Asterina pectinifera* mitochondrial genome. *Genetics*, v. 140, n. 3, p. 1047–1060, 1995.
- ATKINS, J. F. et al. Ribosomal frameshifting and transcriptional slippage: from genetic steganography and cryptography to adventitious use. *Nucleic Acids Research*, v. 44, n. 15, p. 7007–7078, 2016.
- Babraham Bioinformatics. *Trim Galore!* 2019. Disponível em: <https://www.bioinformatics.babraham.ac.uk/projects/trim_galore/>. Acesso em: 31 ago. 2025.
- BAKER, M. 1,500 scientists lift the lid on reproducibility. *Nature*, v. 533, n. 7604, p. 452–454, 2016.
- BOORE, J. L. Animal mitochondrial genomes. *Nucleic Acids Research*, v. 27, n. 8, p. 1767–1780, 1999.

BRIERLEY, I. Ribosomal frameshifting on viral RNAs. *Journal of General Virology*, v. 76, n. 8, p. 1885–1892, 1995.

British Ecological Society. *A guide to reproducible code in ecology and evolution*. London: British Ecological Society, 2017.

CALABRESE, C. et al. MToolBox: a highly automated pipeline for heteroplasmy annotation and prioritization analysis of human mitochondrial variants in high-throughput sequencing. *Bioinformatics*, v. 30, n. 21, p. 3115–3117, 2014.

CEPHAS. *Anodorhynchus leari* map. Wikimedia Commons, jan. 2022. Licença Creative Commons Atribuição-CompartilhaIgual 4.0 Internacional (CC BY-SA 4.0). Dados de ocorrência: BirdLife International / IUCN Red List (2020). Disponível em: <https://commons.wikimedia.org/wiki/File:Anodorhynchus_leari_map.svg>. Acesso em: 4 maio 2026.

CHENG, H. et al. Haplotype-resolved *de novo* assembly using phased assembly graphs with hifiasm. *Nature Methods*, v. 18, n. 2, p. 170–175, 2021.

COCK, P. J. A. et al. Biopython: freely available Python tools for computational molecular biology and bioinformatics. *Bioinformatics*, v. 25, n. 11, p. 1422–1423, 2009.

COLLAR, N. J. Family Psittacidae (parrots). In: del Hoyo, J.; ELLIOTT, A.; SARGATAL, J. (Ed.). *Handbook of the Birds of the World*. Barcelona: Lynx Edicions, 1997. v. 4, p. 280–477.

DARWIN TREE OF LIFE PROJECT CONSORTIUM. Sequence locally, think globally: The Darwin Tree of Life Project. *Proceedings of the National Academy of Sciences*, v. 119, n. 4, p. e2115642118, 2022.

DESJARDINS, P.; MORAIS, R. Sequence and gene organization of the chicken mitochondrial genome: a novel gene order in higher vertebrates. *Journal of Molecular Biology*, v. 212, n. 4, p. 599–634, 1990.

Di Tommaso, P. et al. Nextflow enables reproducible computational workflows. *Nature Biotechnology*, v. 35, n. 4, p. 316–319, 2017.

DIERCKXSENS, N.; MARDULYN, P.; SMITS, G. NOVOPlasty: *de novo* assembly of organelle genomes from whole genome data. *Nucleic Acids Research*, v. 45, n. 4, p. e18, 2017.

DONATH, A. et al. Improved annotation of protein-coding gene boundaries in metazoan mitochondrial genomes. *Nucleic Acids Research*, v. 47, n. 20, p. 10543–10552, 2019.

- EKBLOM, R.; WOLF, J. B. W. A field guide to whole-genome sequencing, assembly and annotation. *Evolutionary Applications*, v. 7, n. 9, p. 1026–1042, 2014.
- EWELS, P. A. et al. The nf-core framework for community-curated bioinformatics pipelines. *Nature Biotechnology*, v. 38, n. 3, p. 276–278, 2020.
- EWING, B. et al. Base-calling of automated sequencer traces using phred. I. Accuracy assessment. *Genome Research*, v. 8, n. 3, p. 175–185, 1998.
- GRÜNING, B. et al. Practical computational reproducibility in the life sciences. *Cell Systems*, v. 6, n. 6, p. 631–635, 2018.
- GUERREIRO, S. L. M. et al. Analysis of the entire mitogenome of the threatened freshwater stingray *Potamotrygon leopoldi* (Myliobatiformes: Potamotrygonidae) and comprehensive phylogenetic assessment in the Xingu River, Brazilian Amazon. *International Journal of Molecular Sciences*, v. 26, p. 8252, 2025.
- HAHN, C.; BACHMANN, L.; CHEVREUX, B. Reconstructing mitochondrial genomes directly from genomic next-generation sequencing reads — a baiting and iterative mapping approach. *Nucleic Acids Research*, v. 41, n. 13, p. e129, 2013.
- HARGER, J. W.; MESKAUSKAS, A.; DINMAN, J. D. An “integrated model” of programmed ribosomal frameshifting. *Trends in Biochemical Sciences*, v. 27, n. 9, p. 448–454, 2002.
- HEBERT, P. D. N. et al. Biological identifications through DNA barcodes. *Proceedings of the Royal Society of London B*, v. 270, n. 1512, p. 313–321, 2003.
- HONG, Y.-H. et al. Differential mitochondrial genome expression of four hylid frog species under low-temperature stress and its relationship with amphibian temperature adaptation. *International Journal of Molecular Sciences*, v. 25, p. 5967, 2024.
- ICMBio — Instituto Chico Mendes de Conservação da Biodiversidade. *Plano de Ação Nacional para a Conservação da Arara-azul-de-lear*. Brasília, 2022.
- Iridian Genomes. *Anodorhynchus leari whole genome sequencing*. 2024. NCBI Sequence Read Archive, acesso SRR28399504. Disponível em: <<https://www.ncbi.nlm.nih.gov/sra/SRR28399504>>. Acesso em: 10 mar. 2026.
- JACKS, T. et al. Characterization of ribosomal frameshifting in HIV-1 *gag-pol* expression. *Nature*, v. 331, n. 6153, p. 280–283, 1988.
- JIN, J.-J. et al. GetOrganelle: a fast and versatile toolkit for accurate *de novo* assembly of organelle genomes. *Genome Biology*, v. 21, n. 1, p. 241, 2020.

- KUNDU, S. et al. Mitogenomic characterization and phylogenetic placement of African hind, *Cephalopholis taeniops*: shedding light on the evolution of groupers (Serranidae: Epinephelinae). *International Journal of Molecular Sciences*, v. 25, p. 1822, 2024.
- KÖSTER, J.; RAHMANN, S. Snakemake — a scalable bioinformatics workflow engine. *Bioinformatics*, v. 28, n. 19, p. 2520–2522, 2012.
- LARMAN, C.; BASILI, V. R. Iterative and incremental development: a brief history. *IEEE Computer*, v. 36, n. 6, p. 47–56, 2003.
- LEINONEN, R.; SUGAWARA, H.; SHUMWAY, M. The Sequence Read Archive. *Nucleic Acids Research*, v. 39, n. suppl. 1, p. D19–D21, 2011.
- LI, F. et al. The complete mitochondrial genomes of two rock scallops (Bivalvia: Spondylidae) indicate extensive gene rearrangements and adaptive evolution compared with Pectinidae. *International Journal of Molecular Sciences*, v. 24, p. 13844, 2023.
- LORENZ, R. et al. ViennaRNA Package 2.0. *Algorithms for Molecular Biology*, v. 6, p. 26, 2011.
- MARTIN, M. Cutadapt removes adapter sequences from high-throughput sequencing reads. *EMBnet.journal*, v. 17, n. 1, p. 10–12, 2011.
- MERKEL, D. Docker: lightweight Linux containers for consistent development and deployment. *Linux Journal*, n. 239, p. 2, 2014.
- MILLER, J. R.; KOREN, S.; SUTTON, G. Assembly algorithms for next-generation sequencing data. *Genomics*, v. 95, n. 6, p. 315–327, 2010.
- MINDELL, D. P.; SORENSON, M. D.; DIMCHEFF, D. E. An extra nucleotide is not translated in mitochondrial ND3 of some birds and turtles. *Molecular Biology and Evolution*, v. 15, n. 11, p. 1568–1571, 1998.
- NCBI — National Center for Biotechnology Information. *SRA Toolkit Documentation*. Bethesda: [s.n.], 2023. National Library of Medicine. Disponível em: <<https://github.com/ncbi/sra-tools>>. Acesso em: 10 mar. 2026.
- PENG, R. D. Reproducible research in computational science. *Science*, v. 334, n. 6060, p. 1226–1227, 2011.
- QUENTAL, J. *Lear's Macaw Anodorhynchus leari*. Flickr, via Wikimedia Commons, abr. 2014. Fotografia. Licença Creative Commons Atribuição 2.0 Genérica (CC BY 2.0). Local: Canudos, Bahia, Brasil. Disponível em: <<https://www.flickr.com/photos/jquental/13935238779/>>. Acesso em: 4 maio 2026.

- RHIE, A. et al. Towards complete and error-free genome assemblies of all vertebrate species. *Nature*, v. 592, n. 7856, p. 737–746, 2021.
- RUSSELL, R. D.; BECKENBACH, A. T. Recoding of translation in turtle mitochondrial genomes: programmed frameshift mutations and evidence of a modified genetic code. *Journal of Molecular Evolution*, v. 67, n. 6, p. 682–695, 2008.
- SANDVE, G. K. et al. Ten simple rules for reproducible computational research. *PLoS Computational Biology*, v. 9, n. 10, p. e1003285, 2013.
- SHI, A. et al. Characterization, codon usage pattern and phylogenetic implications of the waterlily aphid *Rhopalosiphum nymphaeae* (Hemiptera: Aphididae) mitochondrial genome. *International Journal of Molecular Sciences*, v. 25, p. 11336, 2024.
- SICK, H.; TEIXEIRA, D. M. Discovery of the home of the Indigo Macaw in Brazil. *American Birds*, v. 34, n. 2, 1980. Article 2. Disponível em: <https://digitalcommons.usf.edu/american_birds/vol34/iss2/2>.
- SOMMERVILLE, I. *Software Engineering*. 10. ed. Harlow: Pearson Education, 2016.
- TAO, K. et al. Comparative mitogenome analyses of fifteen ramshorn snails and insights into the phylogeny of Planorbidae (Gastropoda: Hygrophila). *International Journal of Molecular Sciences*, v. 25, p. 2279, 2024.
- TAVARES, E. S. et al. Phylogenetic relationships and historical biogeography of Neotropical parrots (Psittaciformes: Psittacidae: Arini) inferred from mitochondrial and nuclear DNA sequences. *Systematic Biology*, v. 55, n. 3, p. 454–470, 2006.
- ULIANO-SILVA, M. et al. MitoHiFi: a python pipeline for mitochondrial genome assembly from PacBio high fidelity reads. *BMC Bioinformatics*, v. 24, p. 288, 2023.
- WILKINSON, M. D. et al. The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, v. 3, p. 160018, 2016.
- WILSON, G. et al. Best practices for scientific computing. *PLoS Biology*, v. 12, n. 1, p. e1001745, 2014.
- YANG, Z. PAML 4: phylogenetic analysis by maximum likelihood. *Molecular Biology and Evolution*, v. 24, n. 8, p. 1586–1591, 2007.
- YE, P. et al. Potential cryptic diversity in the genus *Scoliodon* (Carcharhiniformes: Carcharhinidae): insights from mitochondrial genome sequencing. *International Journal of Molecular Sciences*, v. 25, p. 11851, 2024.

ZHAN, L. et al. The phylogenetic relationships of major lizard families using mitochondrial genomes and selection pressure analyses in Anguimorpha. *International Journal of Molecular Sciences*, v. 25, p. 8464, 2024.

ZHOU, Z. et al. The complete mitochondrial genome and phylogenetic analysis of the freshwater shellfish *Novaculina chinensis* (Bivalvia: Pharidae). *International Journal of Molecular Sciences*, v. 25, p. 67, 2024.

Apêndices

APÊNDICE A – DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL GENERATIVA

Em conformidade com a Política de Integridade na Atividade Científica do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), publicada em março de 2026, declara-se o uso de ferramentas de Inteligência Artificial Generativa (IAG) durante a elaboração deste trabalho, com a especificação a seguir.

FERRAMENTAS UTILIZADAS

- **GitHub Copilot Chat** (extensão do Visual Studio Code), com os modelos de linguagem *Claude Opus 4.6* e, posteriormente, *Claude Opus 4.7* (Anthropic).

FINALIDADES

A IAG foi empregada como ferramenta de apoio nas seguintes atividades:

1. Auxílio na revisão e estruturação textual de capítulos, incluindo sugestões de redação, organização de parágrafos e consistência terminológica;
2. Apoio à depuração e organização de *scripts* de bioinformática (Nextflow DSL2, *Dockerfiles*, Python e *shell*), bem como à elaboração de configurações reprodutíveis de execução do *pipeline*;
3. Discussão de alternativas metodológicas e identificação de inconsistências internas entre capítulos;
4. Geração de versões preliminares de elementos textuais (legendas, resumos, listas) posteriormente revisados e validados pelo autor.

VEDAÇÕES OBSERVADAS

- Nenhum conteúdo gerado por IAG foi submetido como se fosse de autoria exclusivamente humana sem revisão crítica;

- Toda referência bibliográfica sugerida pela IAG foi **verificada manualmente** junto às fontes primárias (DOI, periódico, ano, autoria) antes da inclusão;
- A IAG **não foi utilizada** para a elaboração de pareceres científicos, conforme orientação da política do CNPq;
- Decisões científicas, interpretação de resultados experimentais, análises estatísticas e conclusões são de responsabilidade exclusivamente humana.

RESPONSABILIDADE

O autor declara assumir, nos termos da Política de Integridade na Atividade Científica do CNPq, **responsabilidade integral** pelo conteúdo final apresentado neste trabalho, incluindo eventuais imprecisões, omissões ou inadequações que tenham passado despercebidas durante a revisão das contribuições geradas pelas ferramentas de IAG mencionadas.